



การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพ

นายธีรพงศ์ งามพร้อมวงศ์

วิทยานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

วิทยาศาสตรมหาบัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

บัณฑิตวิทยาลัย มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

ปีการศึกษา 2567

ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพ

นายธีรพงศ์ งามพร้อมวงศ์

วิทยานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาลัทธิ

วิทยาศาสตร์มหัศจรรย์

สาขาวิชาวิทยาการคอมพิวเตอร์

บัณฑิตวิทยาลัย มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

ปีการศึกษา 2567

ลิขสิทธิ์ของมหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ



ใบรับรองโครงงานวิทยานิพนธ์

บัณฑิตวิทยาลัย มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

เรื่อง การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพ

โดย นายธีรพงศ์ งามพร้อมวงศ์

ได้รับอนุมัติให้นับเป็นส่วนหนึ่งของการศึกษาตามหลักสูตรวิทยาศาสตรมหาบัณฑิต สาขาวิชา
วิทยาการคอมพิวเตอร์

..... คณบดีบัณฑิตวิทยาลัย / หัวหน้าภาควิชา

(ผู้ช่วยศาสตราจารย์ ดร.สุพจน์ จันทร์วิพัฒน์)

คณะกรรมการสอบวิทยานิพนธ์

..... ประธานกรรมการ

(ดร.มารุต บุรณรัช)

..... อาจารย์ที่ปรึกษา

(ผู้ช่วยศาสตราจารย์ ดร.ลือพล พิพานเมฆาภรณ์)

..... กรรมการ

(รองศาสตราจารย์ ดร.ธนภัทร์ อนุศาสน์อมรกุล)

ชื่อ : นายธีรพงศ์ งามพร้อมวงศ์
ชื่อวิทยานิพนธ์ : การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลา
สำหรับการจดจำคำพูดด้วยภาพ
สาขาวิชา : วิทยาการคอมพิวเตอร์
มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ
อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก : ผู้ช่วยศาสตราจารย์ ดร.ลือพล พิพานเมฆาภรณ์
ปีการศึกษา : 2567

บทคัดย่อ

การอ่านริมฝีปาก (lipreading) มุ่งเน้นการพัฒนาแบบจำลองที่มีประสิทธิภาพในการถอดรหัสคำพูดจากภาพการเคลื่อนไหวของริมฝีปาก ถึงแม้จะมีความก้าวหน้าอย่างต่อเนื่อง แต่ยังคงมีความท้าทายที่สำคัญ 2 ประการ คือ 1) ความซับซ้อนของแบบจำลอง (Model Complexity) แบบจำลองที่ซับซ้อนมักถูกสร้างขึ้นโดยมีจุดมุ่งหมายเพื่อเพิ่มความแม่นยำในการอ่านริมฝีปาก แต่ก็มีข้อเสียคือต้องใช้ทรัพยากรในการประมวลผลสูง ทำให้ไม่เหมาะสำหรับการใช้งานในอุปกรณ์พกพาหรือระบบที่มีข้อจำกัดด้านทรัพยากร 2) ความคล้ายคลึงในการขยับริมฝีปาก (Lip movement homophones) คำหลายคำมีการออกเสียงที่ใกล้เคียงกัน ทำให้ริมฝีปากขยับในลักษณะที่คล้ายคลึงกันมาก ตัวอย่างเช่น คำว่า "million" และ "millions" ซึ่งแบบจำลองต้องพยายามแยกแยะความแตกต่างจากข้อมูลภาพเพียงอย่างเดียว เพื่อแก้ไขปัญหาเหล่านี้ งานวิจัยนี้จึงมุ่งเน้นไปที่การพัฒนาแบบจำลองที่ไม่ซับซ้อนแต่ยังคงมีความแม่นยำสูง และสามารถแยกแยะความแตกต่างของการเคลื่อนไหวริมฝีปากที่มีความคล้ายคลึงกันได้ โดยใช้เทคนิคการเรียนรู้เชิงลึกแบบผสมผสานประกอบ CNN, RNN และ Attention เพื่อให้การอ่านริมฝีปากมีความสามารถนำไปใช้งานได้在实际การณ์จริงและมีประสิทธิภาพมากยิ่งขึ้น

(มีจำนวนทั้งสิ้น 76 หน้า)

คำสำคัญ : การจดจำคำพูดด้วยภาพ, การอ่านริมฝีปาก, การเรียนรู้เชิงลึก, ความสนใจเชิงพื้นที่

อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก

Name : Mr. Teerapong Ngampromwong
Thesis Title : Development of Spatio-temporal Deep Learning
Model for Visual speech recognition
Major Field : Computer Science
King Mongkut's University of Technology North
Bangkok
Thesis Advisor : Assistant Professor Luepol Pipanmekaporn, Ph.D.
Academic Year : 2024

ABSTRACT

Lipreading focuses on developing efficient models to decode spoken words from the motion of the lips. Despite continuous advancements, there remain two significant challenges: Model Complexity and Lip Movement Homophones. Complex models are often designed with the aim of increasing lipreading accuracy; however, this complexity comes at the cost of high computational resource requirements, rendering them unsuitable for use in portable devices or resource-constrained systems. Additionally, many words exhibit similar pronunciations, leading to lip movements that closely resemble one another; for instance, the words "million" and "millions" demonstrate such similarities, necessitating that models discern differences based solely on visual data. To address these issues, this research focuses on developing a streamlined yet highly accurate model capable of distinguishing between lip movements that closely resemble one another. This is achieved through the use of a hybrid deep learning approach that integrates Convolutional Neural Networks (CNN), Recurrent Neural Networks (RNN), and Attention mechanisms, with the aim of enhancing the applicability and efficiency of lipreading in real-world scenarios.

(Total 76 Pages)

Keywords: Visual Speech Recognition, Lipreading, Deep Learning, Spatial Attention

Advisor

กิตติกรรมประกาศ

ข้าพเจ้า นายธีรพงศ์ งามพร้อมวงศ์ ขอขอบพระคุณอย่างยิ่งต่อผู้ที่มีส่วนร่วมในการดำเนินงานและการสร้างสรรค์งานวิจัยเรื่อง "การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพ (Development of Spatio-temporal Deep Learning Model for Visual speech recognition)" ซึ่งเป็นส่วนหนึ่งของการศึกษาของข้าพเจ้า โดยมีผู้มีพระคุณหลายท่านที่ให้การสนับสนุนและช่วยเหลือในขั้นตอนต่าง ๆ ตั้งแต่เริ่มต้นจนสำเร็จ

ขอขอบพระคุณอาจารย์ ผู้ช่วยศาสตราจารย์ ดร.ลือพล พิพานเมฆาภรณ์ อาจารย์ที่ปรึกษาของข้าพเจ้า ที่ได้ให้คำแนะนำและความรู้ที่มีค่าตลอดระยะเวลาที่ทำการศึกษา รวมถึงแรงบันดาลใจในการวิจัยครั้งนี้

นอกจากนี้ ข้าพเจ้าขอขอบคุณเพื่อนนักศึกษา นางสาวอาชีซาร์ ลอดิง ที่ได้ให้ความช่วยเหลือเป็นอย่างดี นอกจากนี้ยังขอขอบคุณ BBC Research & Development ที่ให้การสนับสนุนทางด้านข้อมูลที่เป็นต่อการทำวิจัยครั้งนี้

สุดท้าย ข้าพเจ้าขอขอบคุณครอบครัวและคนที่รักที่เป็นกำลังใจและให้การสนับสนุนเสมอมาตลอดเส้นทางการศึกษา ช่วยทำให้ข้าพเจ้าเอาชนะอุปสรรคต่าง ๆ จนสามารถดำเนินการวิจัยนี้ให้สำเร็จลุล่วงไปได้

ธีรพงศ์ งามพร้อมวงศ์

สารบัญ

หน้า

บทคัดย่อภาษาไทย.....	ง
บทคัดย่อภาษาอังกฤษ.....	จ
กิตติกรรมประกาศ	ฉ
สารบัญ.....	ช
สารบัญตาราง.....	ฅ
สารบัญรูปภาพ.....	ญ
บทที่ 1 บทนำ.....	1
1.1 ความเป็นมาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์ของการวิจัย	2
1.3 ขอบเขตของการวิจัย	2
1.4 นิยามศัพท์เฉพาะ	2
1.5 ประโยชน์ที่คาดว่าจะได้รับ	3
บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง	4
2.1 การจดจำคำพูดจากภาพ (Visual speech recognition).....	4
2.2 งานวิจัยที่เกี่ยวข้อง.....	15
บทที่ 3 การออกแบบ.....	24
3.1 ศึกษางานวิจัยที่เกี่ยวข้อง	24
3.2 การออกแบบแบบจำลอง.....	26
3.3 การฝึกฝนแบบจำลอง (Training model).....	33
บทที่ 4 การทดลอง.....	35
4.1 ชุดข้อมูลและการเตรียมชุดข้อมูล	35
4.2 แบบจำลองเปรียบเทียบ (Baseline model).....	37
4.3 การพัฒนาแบบจำลองขั้นสุดท้าย	38
4.4 การทดสอบประสิทธิภาพ.....	40
4.5 ผลการทดลอง	43
บทที่ 5 สรุปผลการทดลอง	57
5.1 การทดลองตามชุดข้อมูล.....	57
5.2 การทดลองแบบปรับพารามิเตอร์ (Ablation study)	57

5.3 ปัญหาและอุปสรรค.....	58
บรรณานุกรม.....	59
ภาคผนวก ก.....	62
ประวัติผู้เขียน.....	76



สารบัญตาราง

หน้า

ตารางที่ 3-1 แสดงงานวิจัยที่เกี่ยวข้อง	24
ตารางที่ 4-1 แสดงองค์ประกอบของแบบจำลองขั้นสุดท้าย	38
ตารางที่ 4-2 แสดงรายละเอียดคุณสมบัติของเครื่องคอมพิวเตอร์	39
ตารางที่ 4-3 แสดง Confusion Matrix แบบ predict-actual	41
ตารางที่ 4-4 แสดงผลการทดลองกับชุดข้อมูล Homophones.....	43
ตารางที่ 4-5 แสดงผลการทดลองกับชุดข้อมูล Random	45
ตารางที่ 4-6 แสดงผลการทดลองกับชุดข้อมูล All	46
ตารางที่ 4-7 แสดงผลการทดลองเปรียบเทียบระหว่างชุดข้อมูลสี่และขาวดำ	48
ตารางที่ 4-8 แสดงผลการทดลองเปรียบเทียบจำนวน Unit ของ RNN.....	48
ตารางที่ 4-9 แสดงผลการทดลองเปรียบเทียบระหว่าง LSTM, GRU และ Bi-GRU	49
ตารางที่ 4-10 แสดงผลการทดลองเปรียบเทียบจำนวน Layer ของ RNN.....	50
ตารางที่ 4-11 แสดงผลการทดลองเปรียบเทียบจำนวน Unit ของ Attention	51
ตารางที่ 4-12 แสดงผลการทดลองเปรียบเทียบแบบจำลองขั้นสุดท้าย	52
ตารางที่ ก-1 ชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง (Homophones Dataset) จำนวน 78 คำ.....	67
ตารางที่ ก-2 ชุดข้อมูลแบบสุ่ม (Random Dataset) จำนวน 100 คำ.....	68
ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ.....	69

สารบัญรูปภาพ

หน้า

ภาพที่ 2-1 แสดงการสกัดบริเวณริมฝีปาก (ภาพที่ 1 (Wark et al., 1998))	5
ภาพที่ 2-2 แสดงคุณลักษณะแบบต่าง ๆ ของ Haar (ภาพที่ 1 (Xianghua et al., 2012)).....	5
ภาพที่ 2-3 แสดงอัลกอริทึม Snake ติดตามการเคลื่อนไหวของริมฝีปาก (ภาพที่ 8 (Kass et al., 1988))....	6
ภาพที่ 2-4 แสดงการสกัดคุณลักษณะจากบริเวณที่สนใจ (ROI) ของริมฝีปาก (ภาพที่ 2 (Potamianos et al., 2004)).....	7
ภาพที่ 2-5 แสดงการสกัดคุณลักษณะในการอ่านริมฝีปาก (ภาพที่ 1 (Ma et al., 2016)).....	7
ภาพที่ 2-6 แสดงข้อมูลทั้งแพทช์แบบรูปร่างอิสระ และชุดข้อมูลของจุด (ภาพที่ 1 (Cootes et al., 2001)) ..	8
ภาพที่ 2-7 แสดงวิธีการสกัดและจดจำคุณลักษณะโดยใช้เทคนิค (a) 2D CNN และ (b) 3D CNN.....	10
ภาพที่ 2-8 แสดงวิธีการสกัดและจดจำคุณลักษณะโดยใช้เทคนิค 3D+2D CNN.....	11
ภาพที่ 2-9 แสดงวิธีการสกัดและจดจำคุณลักษณะโดยใช้เทคนิค ViT (ภาพที่ 1 (Dosovitskiy et al., 2020))	15
ภาพที่ 3-1 แสดงกระบวนการออกแบบแบบจำลองที่นำเสนอ.....	26
ภาพที่ 3-2 แสดงการตรวจจับและสกัดริมฝีปาก	27
ภาพที่ 3-3 แสดงคุณลักษณะของริมฝีปาก จำนวน 40 จุด	28
ภาพที่ 3-4 การสกัดคุณลักษณะของริมฝีปาก	29
ภาพที่ 3-5 แสดงแบบจำลองการจดจำคำพูดด้วยภาพที่ผู้วิจัยนำเสนอ	30
ภาพที่ 3-6 แสดงโครงสร้างการเข้ารหัสข้อมูลเชิงพื้นที่.....	30
ภาพที่ 3-7 แสดงโครงสร้างการเข้ารหัสข้อมูลเชิงเวลา.....	31
ภาพที่ 3-8 แสดงการดำเนินการของ Spatial Attention.....	32
ภาพที่ 3-9 แสดงโครงสร้างขั้นแยกประเภท	33
ภาพที่ 4-1 แสดงจำนวนไฟล์แต่ละคำของชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง	35
ภาพที่ 4-2 แสดงจำนวนไฟล์แต่ละคำของชุดข้อมูลแบบสุ่ม	36
ภาพที่ 4-3 แสดงจำนวนไฟล์แต่ละคำของชุดข้อมูลทั้งหมด.....	36
ภาพที่ 4-4 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองที่นำเสนอ	40
ภาพที่ 4-5 แสดงกราฟ ROC สำหรับแบบจำลองที่นำเสนอเทียบกับแบบจำลอง Baseline บนชุดข้อมูล Homophones	44

ภาพที่ 4-6 แสดงกราฟ ROC สำหรับแบบจำลองที่นำเสนอเทียบกับแบบจำลอง Baseline บนชุดข้อมูล Random	45
ภาพที่ 4-7 แสดงกราฟ ROC สำหรับแบบจำลองที่นำเสนอเทียบกับแบบจำลอง Baseline บนชุดข้อมูล All.....	47
ภาพที่ 4-8 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง 2D CNN, GRU และ Attention	52
ภาพที่ 4-9 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง VGG16, Bi-GRU และ Attention.....	53
ภาพที่ 4-10 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง 3D+2D CNN, Bi-GRU และ Attention.....	53
ภาพที่ 4-11 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง 3D CNN, 2D CNN, Bi-GRU และ Attention.....	54
ภาพที่ 4-12 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง 3D CNN, 2D CNN, GRU และ Attention	54
ภาพที่ 4-13 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง 3D CNN, 2D CNN และ Bi-GRU	55
ภาพที่ 4-14 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสาน ระหว่าง 3D CNN, 2D CNN และ ViT-B16	55
ภาพที่ ก-1 Lip Reading in the Wild Agreement (LRW).....	62
ภาพที่ ก-2 แสดงแบบจำลอง 3D CNN ใน Baseline	63
ภาพที่ ก-3 แสดงแบบจำลอง 3D + 2D CNN และ Bi-GRU ใน Baseline	64
ภาพที่ ก-4 แสดงแบบจำลอง 2D CNN + GRU + Attention ใน Baseline	65
ภาพที่ ก-5 แสดงแบบจำลอง 3D + 2D CNN + ViT-B16 ใน Baseline	66

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

เทคโนโลยีการจดจำคำพูดจากภาพ (Visual speech recognition) หรือเรียกอีกอย่างว่าการอ่านปาก (Lip Reading) เป็นเทคนิคที่ใช้วิเคราะห์การเคลื่อนไหวของริมฝีปากเพื่อทำความเข้าใจคำพูดของผู้พูดโดยเทคโนโลยีนี้สามารถนำไปประยุกต์ใช้งานในหลายด้าน เช่น การช่วยเหลือผู้บกพร่องทางการได้ยิน การสื่อสารในสภาพแวดล้อมที่มีเสียงรบกวน หรือแม้แต่การสร้างคำบรรยายในสื่อเป็นต้น อย่างไรก็ตามการจดจำคำพูดด้วยภาพมีปัญหาคือการที่คำพูดที่ส่งผลต่อความแม่นยำหลายประการ อาทิ การออกเสียงบางคำอาจมีรูปแบบของการขยับริมฝีปากที่คล้ายคลึง (Homophones) กัน เช่น การออกเสียง "ABOUT" "AMONG" และ "AMOUNT" ในภาษาอังกฤษ ซึ่งส่งผลให้เกิดความสับสนยิ่งไปกว่านั้นความหลากหลายของรูปร่างและการเคลื่อนไหวของริมฝีปากของแต่ละบุคคล การพูดเร็วหรือช้า มุมกล้อง แสง เงา และคุณภาพของภาพที่นำมาวิเคราะห์ ก็อาจส่งผลกระทบต่อการทำงานของระบบการเคลื่อนไหวของริมฝีปากได้

ปัจจุบันงานวิจัยที่เกี่ยวข้องกับการจดจำคำพูดจากภาพ มักใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) เป็นหลัก เนื่องจากความแม่นยำในการแยกแยะรูปแบบที่ซับซ้อนและความทนทานของโครงข่ายประสาทเทียมเชิงลึก (Deep Neural Network) โดยสามารถแบ่งกลุ่มของเทคนิคการเรียนรู้เชิงลึกออกเป็น 3 หลักการ ได้แก่

1.1.1 เทคนิคการค้นหาคุณลักษณะเชิงพื้นที่ (Spatial Feature Extraction) ซึ่งจะมุ่งเน้นการวิเคราะห์ภาพริมฝีปากเพื่อตรวจจับรูปแบบเฉพาะ

1.1.2 เทคนิคการค้นหาคุณลักษณะเชิงพื้นที่และเวลา (Spatial-temporal Feature Extraction) ซึ่งจะมุ่งเน้นการรวมข้อมูลจากภาพเพื่อตรวจจับการเปลี่ยนแปลงที่เกิดขึ้นตามลำดับเวลา

1.1.3 เทคนิคการผสานข้อมูลหลายรูปแบบ (Multimodal Fusion) ซึ่งจะใช้ข้อมูลจากหลายแหล่ง เช่น เสียงพูด ภาพใบหน้า เพื่อเพิ่มประสิทธิภาพความแม่นยำ ถึงแม้ว่างานวิจัยเหล่านี้จะสามารถวิเคราะห์การเคลื่อนไหวของริมฝีปากได้อย่างมีประสิทธิภาพมากยิ่งขึ้น อย่างไรก็ตามปัญหาของการจดจำคำพูดด้วยภาพยังคงมีอยู่หลายประการ เช่น ข้อจำกัดของข้อมูลที่มีค่อนข้างน้อย การแยกแยะคำที่มีความคล้ายคลึงกัน และแบบจำลองที่มีขนาดใหญ่ซึ่งต้องการทรัพยากรในการทำงานสูงและง่ายต่อการเกิด Overfitting

ดังนั้น ผู้วิจัยจึงมีแนวคิดในการพัฒนาแบบจำลองการจดจำคำพูดด้วยภาพจากเทคนิคการค้นหาคุณลักษณะเชิงพื้นที่และเวลา ที่สามารถค้นหาความสัมพันธ์ระหว่างข้อมูลเชิงพื้นที่และเวลา

ได้อย่างมีประสิทธิภาพ โดยใช้ชุดข้อมูล LRW (Lip Reading in the Wild) (Chung & Zisserman, 2016) ซึ่งเป็นชุดข้อมูลมาตรฐานทั่วไป (Benchmark) สำหรับงานวิจัยการจดจำคำพูดด้วยภาพ โดยมีจุดมุ่งหมายหลักในการลดจำนวนพารามิเตอร์ของการประมวลผล และรักษาประสิทธิภาพของการจดจำคำพูดด้วยภาพ

1.2 วัตถุประสงค์ของการวิจัย

เพื่อพัฒนาแบบจำลองการเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพที่มีประสิทธิภาพ

1.3 ขอบเขตของการวิจัย

1.3.1 งานวิจัยนี้ใช้ข้อมูลจากภาพวิดีโอเพื่อการทำนายคำจากภาพเท่านั้น

1.3.2 งานวิจัยนี้มุ่งเน้นการพัฒนาแบบจำลอง Visual speech recognition โดยใช้เทคนิค Deep Learning

1.3.3 งานวิจัยนี้ใช้ตัวชี้วัดประสิทธิภาพ Precision / Recall / F1-score / Accuracy

1.3.4 งานวิจัยนี้ได้รับการฝึกฝนและทดสอบกับชุดข้อมูลมาตรฐาน LRW (Lip Reading in the Wild) (Chung & Zisserman, 2016) โดยแบ่งข้อมูลออกเป็น 3 ชุดข้อมูล ดังนี้

1.3.4.1 ชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง (78 คำ)

1.3.4.2 ชุดข้อมูลแบบสุ่ม (100 คำ)

1.3.4.3 ชุดข้อมูลทั้งหมด (500 คำ)

1.3.5 งานวิจัยนี้ทำการเปรียบเทียบประสิทธิภาพกับแบบจำลอง ดังนี้

1.3.5.1 แบบจำลอง CNN

1.3.5.2 แบบจำลอง CNN ร่วมกับ RNN

1.3.5.3 แบบจำลอง CNN ร่วมกับ RNN และ Attention

1.3.5.4 แบบจำลอง CNN ร่วมกับ Transformer Encoder (Vision Transformers)

1.4 นิยามศัพท์เฉพาะ

1.4.1 การจดจำคำพูดด้วยภาพ (Visual Speech Recognition) หมายถึง กระบวนการทางเทคโนโลยีที่ใช้การประมวลผลสัญญาณภาพเพื่อให้สามารถแยกแยะและตีความข้อมูลการพูดจากการเคลื่อนไหวของริมฝีปาก โดยมีเป้าหมายเพื่อสร้างระบบที่สามารถแปลงภาพการพูดให้เป็นคำพูดที่เข้าใจได้ซึ่งการใช้ภาพในการเรียนรู้คำพูดนี้สามารถเสริมความแม่นยำให้กับระบบการรู้จำเสียงในกรณีที่เสียงรบกวนหรือไม่ชัดเจน

1.4.2 การอ่านริมฝีปาก (Lipreading) หมายถึง กระบวนการที่ใช้การถอดรหัสข้อมูลการพูดจากการเคลื่อนไหวและตำแหน่งของริมฝีปาก เพื่อทำความเข้าใจกับบุคคลที่กำลังพูด โดยมักใช้ในสถานการณ์ที่เสียงไม่สามารถได้ยินอย่างชัดเจน

1.4.3 การเรียนรู้เชิงลึก (Deep Learning) หมายถึง วิธีการหนึ่งในสาขาการเรียนรู้ด้วยเครื่อง ที่อิงตามโครงข่ายประสาทเทียมประเภทหลายชั้น ซึ่งช่วยให้ระบบสามารถเรียนรู้และทำการวิเคราะห์ข้อมูลขนาดใหญ่ได้ในเชิงลึก โดยการฝึกฝนด้วยข้อมูลจำนวนมากและซับซ้อน ส่งผลให้ระบบมีความสามารถในการแยกแยะและจดจำรูปแบบต่าง ๆ ได้อย่างมีประสิทธิภาพ

1.4.4 กลไกความสนใจเชิงพื้นที่ (Spatial Attention Mechanism) หมายถึง กลไกของระบบประมวลผลข้อมูลที่ช่วยให้แบบจำลองสามารถมุ่งเน้นความสนใจไปยังพื้นที่เฉพาะภายในข้อมูลที่มีหลายมิติ

1.5 ประโยชน์ที่คาดว่าจะได้รับ

1.5.1 แบบจำลอง Deep Learning สำหรับ Visual speech recognition ที่มีขนาดเหมาะสม

1.5.2 สามารถนำงานวิจัยไปใช้พัฒนาแอปพลิเคชันเพื่อช่วยเหลือผู้ป่วยที่บกพร่องทางการได้ยินหรือออกเสียง

1.5.3 สามารถต่อยอดงานวิจัยไปสู่เชิงพาณิชย์

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพนั้น ผู้วิจัยได้ทำการศึกษาการจดจำคำพูดจากภาพ (Visual speech recognition) และงานวิจัยที่เกี่ยวข้อง ดังนี้

2.1 การจดจำคำพูดจากภาพ (Visual speech recognition)

เทคโนโลยีการจดจำคำพูดจากภาพ (Visual speech recognition) หรือเรียกอีกอย่างว่าการอ่านปาก (Lip Reading) เป็นเทคนิคที่ใช้วิเคราะห์การเคลื่อนไหวของริมฝีปากเพื่อทำความเข้าใจคำพูดของผู้พูด สามารถแบ่งออกเป็นสองประเภทหลักตามวิธีการสกัดคุณลักษณะ ได้แก่ การอ่านริมฝีปากด้วยวิธีการวิเคราะห์ภาพ (Image analysis) และการอ่านริมฝีปากด้วยวิธีการเรียนรู้เชิงลึก (Deep Learning) โดยมีรายละเอียด ดังนี้


2.1.1 การอ่านริมฝีปากด้วยวิธีการวิเคราะห์ภาพ (Image analysis)

วิธีนี้ในขั้นตอนแรกคือการสกัดบริเวณริมฝีปากออกจากภาพหรือวิดีโอจากนั้นใช้อัลกอริทึมเพื่อดึงคุณลักษณะการเคลื่อนไหวบริเวณริมฝีปาก วิธีนี้มักใช้เทคนิคทางคณิตศาสตร์ เช่น การวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis, PCA) และการแปลงโคไซน์แบบไม่ต่อเนื่อง (Discrete Cosine Transform, DCT) เพื่อประมวลผลและเข้ารหัสคุณลักษณะให้เป็นเวกเตอร์ที่มีความยาวเท่ากัน สุดท้ายจะนำเวกเตอร์เหล่านี้ไปใช้กับตัวจำแนก เช่น เครือข่ายประสาทเทียม (Artificial Neural Network, ANN) หรือแบบจำลองมาร์คอฟซ่อนเร้น (Hidden Markov Model, HMM) เพื่อจำแนกประเภทคำพูดหรือข้อมูลที่ได้จากริมฝีปาก สามารถแบ่งออกเป็น 3 ขั้นตอน ดังนี้

2.1.1.1 การตรวจจับและสกัดริมฝีปาก (Lip Detection and Extraction) การตรวจจับบริเวณริมฝีปากจากวิดีโอต้นฉบับเป็นขั้นตอนสำคัญในกระบวนการอ่านริมฝีปาก เนื่องจากต้องใช้ข้อมูลภาพของริมฝีปากในการจดจำเสียงพูด การมุ่งเน้นไปที่การสกัดบริเวณที่สนใจ (Region of Interest, ROI) ของริมฝีปากอย่างมีประสิทธิภาพจึงมีผลโดยตรงต่อความแม่นยำในการจดจำ วิธีการตรวจจับริมฝีปากสามารถแบ่งออกเป็น 3 วิธีการ ดังนี้


2.1.1.1.1 วิธีการที่ใช้ข้อมูลพิกเซล (Pixel information-based methods) เป็นวิธีการตรวจจับริมฝีปากโดยอาศัยความแตกต่างของสีระหว่างริมฝีปากและสีผิวโดยรอบ โดย (Wark et al., 1998) ได้นำเสนอการใช้อัตราส่วนสีแดงต่อสีเขียว (R/G Ratio) เพื่อกำหนดตำแหน่งของริมฝีปาก โดยพิกเซลที่มีค่าอัตราส่วนสีอยู่ในช่วงที่กำหนดจะถูกพิจารณาว่าเป็นบริเวณ

ริมฝีปาก ซึ่งวิธีนี้มีจุดเด่นที่ความเรียบง่ายแต่ผลลัพธ์อาจไม่แม่นยำในกรณีที่สภาพแสงเปลี่ยนแปลง หรือสีผิวใกล้เคียงกับสีริมฝีปาก แสดงดังภาพที่ 2-1




ภาพที่ 2-1 แสดงการสกัดบริเวณริมฝีปาก (ภาพที่ 1 (Wark et al., 1998))

2.1.1.1.2 วิธีการตามโครงสร้างใบหน้า (Face structure-based methods) เป็นวิธีที่ใช้ตำแหน่งเชิงโครงสร้างของอวัยวะบนใบหน้า เช่น ตา จมูก และปาก ในการระบุตำแหน่งของริมฝีปาก โดยเริ่มต้นจากการตรวจจับใบหน้าทั้งหมดโดยใช้คุณลักษณะ Haar และตัวจำแนกแบบเรียงซ้อน AdaBoost (Xianghua et al., 2012) จากนั้นคำนวณหาตำแหน่งของริมฝีปากตามสัดส่วนของใบหน้า ซึ่งวิธีนี้มีความแม่นยำสูงในกรณีที่ใบหน้ามีโครงสร้างปกติและภาพมีความชัดเจน แสดงดังภาพที่ 2-2



ภาพที่ 2-2 แสดงคุณลักษณะแบบต่าง ๆ ของ Haar (ภาพที่ 1 (Xianghua et al., 2012))


2.1.1.1.3 วิธีการตามแบบจำลอง (Model-based methods) เป็นวิธีที่ใช้แบบจำลองที่อาศัยรูปร่างและลักษณะเฉพาะของริมฝีปาก โดย (Kass et al., 1988) ได้นำเสนออัลกอริทึม Snake เรียกอีกอย่างว่า Active Contour Model (ACM) เป็นอัลกอริทึมค้นหาจุดสำคัญของริมฝีปากหลายจุด จากนั้นจึงกำหนดเส้นโค้งที่เปลี่ยนรูปได้ ซึ่งจะพอดีกับจุดสำคัญของริมฝีปากภายใต้การกระทำร่วมกันของค่าสัมประสิทธิ์พลังงานข้อจำกัดภายใน (ความเรียบของเส้นโค้ง) และค่าสัมประสิทธิ์พลังงานข้อจำกัดภายนอก (การกำหนดคุณลักษณะของเส้นขอบ) แสดงดังภาพที่ 2-3



ภาพที่ 2-3 แสดงอัลกอริทึม Snake ติดตามการเคลื่อนไหวของริมฝีปาก (ภาพที่ 8 (Kass et al., 1988))


2.1.1.2 การสกัดคุณลักษณะ (Feature Extraction) หลังจากการตรวจจับและสกัดบริเวณริมฝีปากแล้ว ขั้นตอนถัดไปคือการสกัดคุณลักษณะจากบริเวณที่สนใจ (ROI) เพื่อใช้ในการจำแนกประเภท สามารถแบ่งออกเป็น 3 วิธีการ ดังนี้

2.1.1.2.1 วิธีการแบบพิกเซล (Pixel-Based Method) เป็นวิธีที่ใช้ค่าพิกเซลทั้งหมดในบริเวณ ROI ของริมฝีปากเป็นข้อมูลดิบสำหรับการสร้างคุณลักษณะ โดยสมมติว่าทุกพิกเซลในบริเวณริมฝีปากมีความเกี่ยวข้องกับเสียงพูด (Potamianos et al., 2004) จากนั้นจึงใช้เทคนิคลดมิติ (Dimensionality Reduction) เช่น PCA หรือ DCT เพื่อแปลงข้อมูลพิกเซลดิบให้เป็นคุณลักษณะสำคัญที่กระชับและแสดงบริบทได้ดี แสดงดังภาพที่ 2-4



ภาพที่ 2-4 แสดงการสกัดคุณลักษณะจากบริเวณที่สนใจ (ROI) ของริมฝีปาก
(ภาพที่ 2 (Potamianos et al., 2004))


2.1.1.2.2 วิธีการตามรูปร่าง (Shape-Based Method) เป็นวิธีที่เน้นการสร้างแบบจำลองรูปร่างริมฝีปากขณะพูด โดยอาศัยข้อมูลเกี่ยวกับรูปทรงและโครงสร้างทางเรขาคณิตของริมฝีปาก เช่น ความสูง ความกว้าง เส้นรอบวง พื้นที่ และรูปร่างของริมฝีปากทั้งภายนอกและภายใน โดย (Ma et al., 2016) ใช้ลักษณะทางเรขาคณิต เช่น การคำนวณตำแหน่งของจุดสำคัญบนริมฝีปากจำนวน 6 จุด (แสดงดังภาพที่ 2-5) เพื่อนำมาวิเคราะห์และสร้างคุณลักษณะ ซึ่งวิธีนี้ช่วยแสดงถึงการเปลี่ยนแปลงของรูปทรงริมฝีปากขณะพูดได้อย่างชัดเจน



ภาพที่ 2-5 แสดงการสกัดคุณลักษณะในการอ่านริมฝีปาก (ภาพที่ 1 (Ma et al., 2016))

2.1.1.2.3 การสกัดคุณลักษณะแบบผสม (Mixed Feature Extraction) เป็นวิธีที่ผสมผสานระหว่างข้อมูลพิกเซล (คุณลักษณะระดับต่ำ) และข้อมูลรูปร่าง (คุณลักษณะระดับสูง) เข้าด้วยกัน โดยรวมจุดเด่นของทั้งสองวิธีเพื่อเพิ่มความแม่นยำและครอบคลุมข้อมูลที่หลากหลาย โดย (Cootes et al., 2001) ได้พัฒนาการสกัดคุณลักษณะแบบผสมคือ Active Appearance Model (AAM) ซึ่งเป็นการผสานข้อมูลระดับสีเทาของบริเวณริมฝีปาก (Texture

Features) กับลักษณะรูปร่างริมฝีปาก (Shape Features) เพื่อสร้างคุณลักษณะที่แสดงถึงข้อมูลทั้งเชิงรูปร่างและพื้นผิวของริมฝีปาก แสดงดังภาพที่ 2-6



ภาพที่ 2-6 แสดงข้อมูลทั้งแพทช์แบบรูปร่างอิสระ และชุดข้อมูลของจุด (ภาพที่ 1 (Cootes et al., 2001))

2.1.1.3 การจำแนกประเภท (Classification) หลังจากสกัดคุณลักษณะของริมฝีปากได้แล้ว ขั้นตอนถัดไปคือการจำแนกประเภทโดยใช้คุณลักษณะที่ได้ สามารถแบ่งออกเป็น 3 วิธีการ ดังนี้

2.1.1.3.1 วิธีการจับคู่เทมเพลต (Template Matching Method) เป็นวิธีที่จับคู่คุณลักษณะที่สกัดจากภาพกับเทมเพลตในฐานข้อมูลที่จัดเตรียมไว้ โดย (Petajan, 1984) ได้นำเวกเตอร์คุณลักษณะของการออกเสียงแต่ละคำเข้าสู่ฐานข้อมูลในขั้นตอนการฝึกฝน และในขั้นตอนการจำแนกจะจับคู่เวกเตอร์คุณลักษณะของคำที่ป้อนเข้ากับเทมเพลตในฐานข้อมูล ซึ่งให้ผลลัพธ์ในการจดจำจะขึ้นอยู่กับเวกเตอร์ที่มีค่าสัมประสิทธิ์สหสัมพันธ์สูงที่สุดกับเทมเพลตที่มีอยู่

2.1.1.3.2 เครือข่ายประสาทเทียม (Artificial Neural Network, ANN) เป็นเครือข่ายที่สามารถเรียนรู้และปรับตัวได้ โดยมีความสามารถในการจัดการข้อมูลที่ถูกรบกวน และมีประสิทธิภาพในการจำแนกประเภท เช่น เครือข่ายประสาทเทียมแบบหน่วงเวลา (Time-Delay Neural Network, TDNN) ซึ่งออกแบบมาให้มีหลายชั้นเพื่อเพิ่มความสามารถในการแสดงข้อมูลในเชิงลึก โดย TDNN ใช้ข้อมูลที่เป็นหน้าต่างเวลาซึ่งสามารถเปลี่ยนแปลงได้ จึงสามารถเรียนรู้ความสัมพันธ์ของข้อมูลในมิติเวลาได้ดี ซึ่งมีความสามารถในการแสดงคุณลักษณะเชิงเวลาได้ดี และสามารถแบ่งปันค่าน้ำหนักเพื่อปรับปรุงประสิทธิภาพการเรียนรู้ได้ง่าย (Bregler & Konig, 1994)

2.1.1.3.3 แบบจำลองมาร์คอฟที่ซ่อนอยู่ (Hidden Markov Model, HMM) เป็นวิธีที่ได้รับความนิยมมากที่สุดในช่วงแรกของการอ่านริมฝีปาก โดย Baum ได้เสนอแนวคิดนี้ในปี 1960 และนำมาใช้กับการจดจำเสียงพูด ต่อมาในปี 1990 HMM ได้รับการปรับใช้ในการอ่านริมฝีปาก ซึ่งมีแนวคิดพื้นฐานคือ การเคลื่อนไหวของริมฝีปากมีลักษณะเป็นเส้นตรงในช่วงเวลาสั้น ๆ ซึ่งสามารถแทนด้วยพารามิเตอร์ของแบบจำลองเชิงเส้น และแบบจำลองเชิงเส้นเหล่านี้จะถูกเชื่อมโยงกันในรูปแบบของห่วงโซ่มาร์คอฟ โดย (Sujatha & Krishnan, 2012) ได้ใช้การแปลงโคไซน์

แบบไม่ต่อเนื่อง (DCT) เพื่อสกัดคุณลักษณะการเคลื่อนไหวของภาพ และใช้คุณลักษณะเหล่านี้เป็นข้อมูลอินพุตสำหรับ HMM ซึ่งเหมาะสำหรับการจัดการข้อมูลเชิงลำดับ

2.1.2 การอ่านริมฝีปากด้วยวิธีการเรียนรู้เชิงลึก (Deep Learning)

การอ่านริมฝีปากมีปัญหาที่ท้าทายที่ส่งผลต่อความแม่นยำอยู่หลายประการ เช่น การออกเสียงบางคำอาจมีรูปแบบของการขยับริมฝีปากที่คล้ายคลึง (homophones) ซึ่งส่งผลให้เกิดความสับสน ยิ่งไปกว่านั้นความหลากหลายของรูปร่างและการเคลื่อนไหวของริมฝีปากของแต่ละบุคคล การพูดเร็วหรือช้า มุมกล้อง แสง เงา และคุณภาพของภาพที่นำมาวิเคราะห์ ซึ่งวิธีการแบบดั้งเดิมไม่สามารถการดำเนินการเรียนรู้คุณลักษณะได้อย่างมีประสิทธิภาพ จึงมีการนำเทคนิคเครือข่ายประสาทเทียมเชิงลึก (Deep Neural Network, DNN) มาใช้ เพื่อให้สามารถเรียนรู้คุณลักษณะเชิงลึกได้แบบอัตโนมัติและมีความทนทานต่อข้อมูลขนาดใหญ่ ซึ่งสามารถเรียนรู้ลักษณะเฉพาะจากการเคลื่อนไหวของริมฝีปากในภาพหรือวิดีโอในการจำแนกคำพูดได้อย่างแม่นยำ ประกอบเทคนิคที่สำคัญ ดังนี้


2.1.2.1 เครือข่ายประสาทเทียมคอนโวลูชัน (Convolution Neural Network) โดยสามารถแบ่งออกเป็น 3 ลักษณะ ดังนี้

2.1.2.1.1 เครือข่ายประสาทเทียมแบบคอนโวลูชัน 2 มิติ (2D Convolutional Neural Network) เป็นการนำ 2D CNN มาใช้ในการอ่านริมฝีปากโดยอาศัยการดำเนินการคอนโวลูชันแบบสองมิติในทุกเฟรมของวิดีโอ ซึ่งชั้นคอนโวลูชันจะทำการสกัดคุณลักษณะจากแผนที่คุณลักษณะ (Feature Map) ที่อยู่ติดกันในชั้นก่อนหน้า จากนั้นจึงเพิ่มค่าเบี่ยงเบน (Bias) และส่งผลลัพธ์เข้าสู่ฟังก์ชันกระตุ้น (Activation Function) แสดงดังภาพที่ 2-7(a) และสมการที่ 2-1 แสดงค่าคุณลักษณะในแผนที่คุณลักษณะ j ที่ตำแหน่ง (x, y) ในชั้นที่ i

$$v_{ij}^{xy} = ReLU(b_{ij} + \sum_m \sum_{p=0}^{P_{i-1}} \sum_{q=0}^{Q_{i-1}} w_{ijm}^{pq} v_{(i-1)m}^{(x-p)(y-q)}) \dots\dots\dots (2-1)$$

โดยที่:

v_{ij}^{xy}	คือ	ค่าคุณลักษณะในแผนที่คุณลักษณะ j ที่ตำแหน่ง (x, y) ในชั้นที่ i
$ReLU$	คือ	ฟังก์ชันกระตุ้น (Activation Function)
w_{ijm}^{pq}	คือ	ค่าน้ำหนักของตัวกรองที่เชื่อมต่อระหว่างแผนที่คุณลักษณะ m กับ j
$v_{(i-1)m}^{(x-p)(y-q)}$	คือ	ค่าในแผนที่คุณลักษณะ m ของเลเยอร์ก่อนหน้า $i-1$
b_{ij}	คือ	ค่าเบี่ยงเบนที่เพิ่มในแผนที่คุณลักษณะลำดับ j



ภาพที่ 2-7 แสดงวิธีการสกัดและจดจำคุณลักษณะโดยใช้เทคนิค (a) 2D CNN และ (b) 3D CNN

2.1.2.1.2 เครือข่ายประสาทเทียมแบบคอนโวลูชัน 3 มิติ (3D Convolutional Neural Network) โครงสร้าง 3D CNN มีคล้ายคลึงกับ 2D CNN โดยใน 2D CNN มีการดำเนินการคอนโวลูชันแบบสองมิติซึ่งสามารถสกัดคุณลักษณะจากภาพสองมิติได้เท่านั้น เนื่องจากการคอนโวลูชันในแต่ละขั้นตอนจะพิจารณาเพียงเฟรมเดียวในแต่ละครั้ง แต่ในทางกลับกัน 3D CNN จะทำการรวมเฟรมภาพที่ต่อเนื่องกันของวิดีโอให้เป็นบล็อกสามมิติ (Cubes) และใช้ตัวกรองคอนโวลูชันแบบสามมิติ (3D Convolution Kernel) บนบล็อกเหล่านั้น เพื่อสร้างบล็อกคุณลักษณะ (Feature Cubes) วิธีการนี้ช่วยให้แผนที่คุณลักษณะ (Feature Map) ในขั้นปัจจุบันสามารถเชื่อมโยงกับเฟรมภาพต่อเนื่องหลายเฟรมในขั้นก่อนหน้าได้ แสดงดังภาพที่ 2-7(b) และสมการที่ 2-2 แสดงค่าคุณลักษณะในแผนที่คุณลักษณะ j ที่ตำแหน่ง (x, y, z) ในชั้นที่ i


$$v_{ij}^{xyz} = ReLU(b_{ij} + \sum_m \sum_{p=0}^{P_{i-1}} \sum_{q=0}^{Q_{i-1}} \sum_{r=0}^{R_{i-1}} w_{ijm}^{pqr} v_{(i-1)m}^{(x-p)(y-q)(z-r)}) \dots \dots \dots (2-2)$$

โดยที่:

v_{ij}^{xyz}	คือ	ค่าคุณลักษณะในแผนที่คุณลักษณะ j ที่ตำแหน่ง (x, y, z) ในชั้นที่ i
$ReLU$	คือ	ฟังก์ชันกระตุ้น (Activation Function)
w_{ijm}^{pqr}	คือ	ค่าน้ำหนักของตัวกรองที่เชื่อมต่อระหว่างแผนที่คุณลักษณะ m กับ j
$v_{(i-1)m}^{(x-p)(y-q)(z-r)}$	คือ	ค่าในแผนที่คุณลักษณะ m ของเลเยอร์ก่อนหน้า $i-1$
b_{ij}	คือ	ค่าเบี่ยงเบนที่เพิ่มในแผนที่คุณลักษณะลำดับ j

2.1.2.1.3 การผสมผสานระหว่างเครือข่ายประสาทเทียมแบบคอนโวลูชัน 3 มิติ และ 2 มิติ (3D + 2D Convolutional Neural Network) การใช้เครือข่ายประสาทเทียมแบบคอนโวลูชัน 2 มิติ (2D CNN) ได้รับการพิสูจน์แล้วว่าสามารถสกัดคุณลักษณะเชิงพื้นที่ได้อย่างมีประสิทธิภาพ แต่มีข้อจำกัดในการสกัดคุณลักษณะเชิงเวลาในลำดับข้อมูล ในขณะที่เครือข่ายประสาท

เทียมแบบคอนโวลูชัน 3 มิติ (3D CNN) สามารถสกัดคุณลักษณะเชิงเวลาได้ แต่ต้องการประสิทธิภาพในการประมวลผลสูงเนื่องจากต้องใช้ในการคำนวณและหน่วยความจำมาก ดังนั้น จึงมีการพัฒนาโครงสร้างเครือข่ายประสาทเทียมแบบผสมระหว่าง 3D CNN และ 2D CNN (3D + 2D CNN) ซึ่งสามารถสกัดคุณลักษณะเชิงเวลาได้จาก 3D CNN และยังสามารถสกัดคุณลักษณะเชิงพื้นที่จาก 2D CNN ได้อย่างมีประสิทธิภาพอีกด้วย แสดงดังภาพที่ 2-8



ภาพที่ 2-8 แสดงวิธีการสกัดและจดจำคุณลักษณะโดยใช้เทคนิค 3D+2D CNN

2.1.2.2 เครือข่ายคอนโวลูชันเชิงเวลา (Temporal Convolutional Networks, TCN) เป็นสถาปัตยกรรมที่ใช้สำหรับการประมวลผลลำดับข้อมูลตามเวลา โดยใช้การคอนโวลูชัน 1 มิติ ซึ่งจะทำให้ลำดับของเวกเตอร์คุณลักษณะเปลี่ยนแปลงรูปแต่ไม่เปลี่ยนแปลงความยาวของลำดับข้อมูล ในการออกแบบ TCN จะใช้โครงสร้างพื้นฐานคล้ายคลึงกับโครงสร้างของ ResNet ประกอบด้วยสองชุดของเลเยอร์คอนโวลูชันเชิงเวลา ชั้นการทำให้มาตรฐานข้อมูล (Batch normalization) และฟังก์ชันกระตุ้น (Activation function) นอกจากนี้ยังมีการเชื่อมต่อสำรองที่เชื่อมโยงจากข้อมูลขาเข้าไปยังขาออก เพื่อเป็นการเข้ารหัสลำดับคุณลักษณะที่มีความลึก สุดท้ายจะมีการใช้ชั้นหนาแน่น (Dense layer) เพื่อประมวลผลลำดับของเวกเตอร์คุณลักษณะที่ได้ และทำการจำแนกประเภทของลำดับข้อมูลทั้งหมด โดยขอยกตัวอย่างเทคนิคที่สำคัญ ดังนี้

คอนโวลูชันแบบขยาย (Dilated Convolution) เป็นเทคนิคที่ถูกนำไปใช้ในเครือข่ายประสาทเทียมแบบ TCN เพื่อเพิ่มขอบเขตการรับข้อมูล (Receptive Field) อย่างมีประสิทธิภาพโดยไม่ต้องเพิ่มจำนวนพารามิเตอร์ ซึ่งใน TCN แต่ละบล็อกของเครือข่าย จะใช้คอนโวลูชันแบบขยายที่มีค่าการขยายตัว (Dilation Rate) เป็น $2^{(i-1)}$ สำหรับบล็อกที่ i ซึ่งช่วยให้แบบจำลองสามารถเรียนรู้

ข้อมูลจากช่วงเวลาที่ห่างออกไปได้โดยไม่ต้องเพิ่มขนาดของตัวกรอง (Filter Size) หรือเพิ่มจำนวนชั้นเครือข่าย ทั้งนี้ การดำเนินคอนโวลูชันแบบขยาย แสดงสมการที่ 2-3

$$y_t = \sum_{i=0}^{k-1} x_{t-d \cdot i} \cdot w_i \dots\dots\dots (2-3)$$

โดยที่:

y_t	คือ	ค่าผลลัพธ์ที่ตำแหน่ง t
x_t	คือ	ค่าของอินพุตที่ตำแหน่ง t
w_i	คือ	ค่าน้ำหนักของตัวกรองที่ตำแหน่ง i
d	คือ	อัตราการขยาย (Dilation Rate)
k	คือ	ขนาดของตัวกรอง

2.1.2.3 เครือข่ายประสาทเทียมแบบวนซ้ำ (Recurrent Neural Network, RNN) ถูกใช้เป็นหลักเพื่อจัดการกับข้อมูลในลำดับของเวลา ซึ่งข้อมูลส่วนใหญ่มักขึ้นอยู่กับสถานะก่อนหน้า อย่างไรก็ตาม RNN แบบดั้งเดิมประสบกับปัญหาในการเรียนรู้ความสัมพันธ์ในระยะยาว ซึ่งมักนำไปสู่ปัญหาการหายไปของเกรเดียนต์ (Gradient disappearance) ส่งผลให้ RNN มีหน่วยความจำระยะสั้นเพียงเท่านั้น และต่อมาได้รับการพัฒนาต่อยอดเป็น LSTM, GRU และ Bi-RNN ซึ่งมีรายละเอียดดังนี้

2.1.2.3.1 หน่วยความจำระยะยาวและระยะสั้น (Long Short-Term Memory, LSTM) (Hochreiter & Schmidhuber, 1997) ได้รับการพัฒนาขึ้นจาก RNN โดยมีการนำ "Gate" มาใช้เพื่อควบคุมสถานะและผลลัพธ์ในช่วงเวลาที่แตกต่างกัน ประกอบด้วย Input gate, Forget gate และ Output gate ซึ่งทำให้ LSTM สามารถรวมทั้งหน่วยความจำระยะยาวและระยะสั้นได้ เพื่อเป็นการช่วยป้องกันปัญหาการหายไปของเกรเดียนต์ได้ แสดงการคำนวณแต่ละสถานะดังสมการที่ 2-4

$$\begin{aligned} f_t &= \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \dots\dots\dots (2-4) \\ i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ \tilde{C}_t &= \sigma(W_C \cdot [h_{t-1}, x_t] + b_C) \\ C_t &= f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \\ h_t &= o_t \odot \tanh(C_t) \end{aligned}$$

โดยที่:

f_t	คือ	Forget gate
i_t	คือ	Input gate
o_t	คือ	Output gate
$\tilde{C}_t$	คือ	ข้อมูลใหม่ที่จะถูกเพิ่มลงใน Cell state
C_t	คือ	ค่า Cell state ณ เวลา t
h_t	คือ	ค่า Hidden state ณ เวลา t
x_t	คือ	ค่าของอินพุต ณ เวลา t

$W_{f,i,c,o}$	คือ	ค่าเมทริกซ์น้ำหนัก
$b_{f,i,c,o}$	คือ	ค่า Bias
σ	คือ	Sigmoid activation function
$\odot$	คือ	ตัวดำเนินการคูณเชิงองค์ประกอบ (Hadamard product)

2.1.2.3.2 หน่วยประมวลผลวนซ้ำแบบเกต (Gate Recurrent Units, GRU) (Cho et al., 2014) ได้ปรับปรุงโครงสร้างของ LSTM ซึ่งได้ลดจำนวนเกตลงเหลือเพียง 2 เกต ได้แก่ Update gate และ Reset gate ทำให้โครงสร้างง่ายขึ้นและความซับซ้อนน้อยลง แสดงการคำนวณแต่ละสถานะดังสมการที่ 2-5

$$\begin{aligned} z_t &= \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \dots\dots\dots (2-5) \\ r_t &= \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \\ \tilde{h}_t &= \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h) \\ h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \end{aligned}$$

โดยที่:

z_t	คือ	Update gate
r_t	คือ	Reset gate
$\tilde{h}_t$	คือ	ค่า Candidate hidden state
h_t	คือ	ค่า Hidden state ณ เวลา t
x_t	คือ	ค่าของอินพุต ณ เวลา t
$W_{z,r,h}$	คือ	ค่าเมทริกซ์น้ำหนัก
$b_{z,r,h}$	คือ	ค่า Bias
σ	คือ	Sigmoid activation function
$\odot$	คือ	ตัวดำเนินการคูณเชิงองค์ประกอบ (Hadamard product)

2.1.2.3.3 เครือข่ายประสาทวนกลับแบบทิศทางคู่ (Bidirectional Recurrent Neural Network, Bi-RNN) โครงสร้าง RNN แบบดั้งเดิม การส่งผ่านสถานะจะเกิดขึ้นจากหน้าไปหลัง ซึ่งในบางสถานการณ์ผลลัพธ์ปัจจุบันไม่ได้ขึ้นอยู่กับสถานะก่อนหน้าเพียงอย่างเดียว แต่ยังขึ้นอยู่กับสถานะในลำดับถัดไปด้วย ซึ่งจำเป็นต้องใช้ Bi-RNN เพื่อแก้ไขปัญหาดังกล่าว โครงสร้างของ Bi-RNN เป็นการรวมกันของ RNN ทิศทางเดียวจำนวนสองเครือข่าย โดยข้อมูลนำเข้าไปยัง RNN ทั้งสองเครือข่ายในเวลาเดียวกันแบบสลับทิศทางกัน

2.1.2.3.3 ทรานส์ฟอร์มเมอร์ (Transformer) ถูกเสนอครั้งแรกใน (Vaswani et al., 2017) และมีประสิทธิภาพที่เหนือกว่าสถาปัตยกรรมแบบ RNN และ CNN ในงานด้านการแปลภาษาด้วยเครื่อง โดยสามารถสร้างผลลัพธ์ที่ดีได้ด้วยกลไกตัวเข้ารหัส-ตัวถอดรหัส (Encoder-decoder) และกลไกความสนใจ (Attention mechanism) ทั้งนี้ ข้อได้เปรียบที่สำคัญที่สุดของทรานส์ฟอร์มเมอร์คือความสามารถในการประมวลผลแบบขนานได้อย่างมีประสิทธิภาพ ซึ่งในระยะแรกถูกนำมาใช้ในงานประมวลผลภาษาธรรมชาติ (Natural Language Processing) ซึ่งให้ผลลัพธ์ที่โดดเด่น

และในช่วงไม่กี่ปีที่ผ่านมาทรานส์ฟอร์เมอร์ได้ถูกนำไปประยุกต์ใช้กับงานด้านการรู้จำภาพ (Visual recognition) ซึ่งพิสูจน์ให้เห็นว่าทรานส์ฟอร์เมอร์สามารถให้ผลลัพธ์ที่ดีกว่าวิธีการอื่นในงานประมวลผลภาพ ดังนั้น ทรานส์ฟอร์เมอร์สามารถนำมาใช้ในการอ่านปาก (Lipreading) ได้อย่างมีประสิทธิภาพ โดยขออธิบายกลไกความสนใจเพิ่มเติมดังนี้

2.1.2.3.1 กลไกความสนใจ (Attention Mechanism) เป็นกระบวนการที่ช่วยให้แบบจำลองสามารถเลือกข้อมูลที่มีความสำคัญที่สุดต่อผลลัพธ์ โดยมักถูกนำไปใช้ในแบบจำลองของ Transformer เพื่อประมวลผลข้อมูลลำดับ (Sequence) ทำให้สามารถจัดการกับข้อมูลได้อย่างมีประสิทธิภาพ โดยไม่ต้องพึ่งพาโครงสร้างลำดับดั้งเดิม เช่น LSTM หรือ GRU สมการพื้นฐานสำหรับการคำนวณ Attention ดังแสดงสมการที่ 2-6

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V \quad \dots\dots\dots (2 - 6)$$

โดยที่:

<i>Query (Q)</i>	คือ	เวกเตอร์ที่แทนคำถามที่ใช้เพื่อค้นหาข้อมูลที่มีความเกี่ยวข้องกับบริบทที่สนใจ
<i>Key (K)</i>	คือ	เวกเตอร์ที่แสดงถึงข้อมูลที่สามารถเชื่อมโยงกับ Q
<i>Value (V)</i>	คือ	เวกเตอร์ที่เก็บข้อมูลที่เกี่ยวข้อง
d_k	คือ	ขนาดของแต่ละ Vector ใน K เพื่อป้องกันการเกิดค่าอนันต์ (Infinity)


2.1.2.3.2 กลไกความสนใจเชิงพื้นที่ (Spatial attention mechanism) เป็นเทคนิคที่ช่วยให้แบบจำลองการเรียนรู้เชิงลึก สามารถมุ่งเน้นไปที่ส่วนที่สำคัญของข้อมูล เช่น ภาพหรือแผนที่คุณลักษณะ โดยการสร้างแผนที่ความสนใจ (Attention Map) ที่แสดงถึงค่าน้ำหนักความสำคัญของแต่ละตำแหน่งของข้อมูล เทคนิคนี้ทำให้แบบจำลองสามารถให้ความสำคัญกับพิกเซลหรือบริเวณที่เกี่ยวข้องมากขึ้น ขณะเดียวกันก็ลดความสำคัญของพื้นที่ที่ไม่เกี่ยวข้อง ด้วยการคูณแผนที่คุณลักษณะด้วยแผนที่ความสนใจ ซึ่งจะช่วยเพิ่มประสิทธิภาพในการจำแนกประเภทและการประมวลผลข้อมูลในงานต่าง ๆ เช่น การจำแนกภาพ การตรวจจับวัตถุ และการวิเคราะห์ภาพในแอปพลิเคชันต่าง ๆ ได้อย่างมีประสิทธิภาพมากขึ้น ซึ่งสามารถคำนวณได้ดังสมการที่ 2-7

$$M = Softmax(W_a \cdot F + b_a) \odot F \quad \dots\dots\dots (2 - 7)$$

โดยที่:

M	คือ	แผนที่ความสนใจ (Attention map)
F	คือ	แผนที่คุณลักษณะ (Feature map)
W_a	คือ	ค่าเมทริกซ์น้ำหนัก
b_a	คือ	ค่า Bias
$\odot$	คือ	ตัวดำเนินการคูณเชิงองค์ประกอบ (Hadamard product)

2.1.2.4 วิชันทรานส์ฟอร์เมอร์ (Vision Transformer, ViT) (Dosovitskiy et al., 2020) เป็นสถาปัตยกรรมที่นำทรานส์ฟอร์เมอร์มาใช้ในการรับรู้จำภาพ (Visual recognition) โดยอาศัยชุดข้อมูลขนาดใหญ่ ในกระบวนการทำงานวิชันทรานส์ฟอร์เมอร์จะทำการแบ่งภาพเป็นส่วนย่อยที่ไม่ทับซ้อนกัน (Patch) เพื่อสร้างภาพเป็นโทเคน (token) ที่มีความยาวคงที่ จากนั้นใช้วิชันทรานส์ฟอร์เมอร์มาตรฐานหลายชั้นในการสร้างแบบจำลองของโทเคนเหล่านี้ และให้ผลลัพธ์ที่ดีในงานด้านการแยกประเภทของภาพ (Image classification) แต่อย่างไรก็ตาม การฝึกแบบจำลองให้มีประสิทธิภาพจำเป็นต้องอาศัยชุดข้อมูลขนาดใหญ่ แสดงสถาปัตยกรรมของ ViT ดังภาพที่ 2-9



ภาพที่ 2-9 แสดงวิธีการสกัดและจดจำคุณลักษณะโดยใช้เทคนิค ViT (ภาพที่ 1 (Dosovitskiy et al., 2020))

2.2 งานวิจัยที่เกี่ยวข้อง

หลังจากที่ผู้วิจัยได้ทำการศึกษางานวิจัยที่เกี่ยวข้องเพื่อเป็นแนวทางในการดำเนินการวิจัยให้สำเร็จตรงตามวัตถุประสงค์สามารถแบ่งงานวิจัยที่เกี่ยวข้องออกเป็น 3 กลุ่มหลัก ได้แก่ การสกัดคุณลักษณะเชิงพื้นที่ (Spatial Feature Extraction) การสกัดคุณลักษณะเชิงพื้นที่และเวลา (Spatial-Temporal Feature Extraction) และการผสานข้อมูลหลายรูปแบบ (Multimodal Fusion) ที่ผสานข้อมูลจากหลายแหล่ง ซึ่งสามารถศึกษารายละเอียดเพิ่มเติมได้ในตารางที่ 3-1

2.2.1 เทคนิคการค้นหาคคุณลักษณะเชิงพื้นที่ (Spatial Feature Extraction) เป็นเทคนิคที่มุ่งเน้นการสกัดคุณลักษณะของข้อมูลจากภาพหรือวิดีโอ โดยพิจารณาจากการจัดเรียงของพิกเซลบนพื้นที่ โดยใช้ 3D CNN ซึ่ง (Chung & Zisserman, 2016) ได้นำเสนอผลงานการระบุคำพูดโดยใช้เพียงข้อมูลวิดีโอใบหน้าที่กำลังพูดเท่านั้นโดยไม่ใช้ข้อมูลเสียง ซึ่งมุ่งความสนใจใน 2 ประเด็น ดังนี้

2.2.1.1 การพัฒนากระบวนการจัดเก็บข้อมูลที่เป็นอัตโนมัติจากรายการโทรทัศน์ ซึ่งสามารถสร้างชุดข้อมูลที่มีจำนวนคำพูดมากกว่าล้านคำ จากจำนวนผู้พูดมากกว่า 1,000 คน

2.2.1.2 การพัฒนาโครงข่าย CNN ใน 4 รูปแบบ ได้แก่ EF-3, MT-3, EF, และ MT โดยสถาปัตยกรรมเหล่านี้มีพื้นฐานมาจากแบบจำลอง VGG-M ที่สามารถเรียนรู้และรู้จำคำศัพท์หลาย

ร้อยคำได้อย่างมีประสิทธิภาพบนชุดข้อมูลนี้ และยังแสดงให้เห็นถึงประสิทธิภาพการจดจำที่ดีกว่าผลลัพธ์ที่ดีที่สุดบนชุดข้อมูลมาตรฐานสาธารณะ OuluVS1 และ OuluVS2 อีกด้วย ทั้งนี้ ได้ประเมินผลแบบจำลองนี้จากชุดข้อมูลที่สร้างขึ้น ผลลัพธ์ที่ได้จากแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 61.10%

2.2.2 เทคนิคการค้นหาคูณลักษณะเชิงพื้นที่และเวลา (Spatial-temporal Feature Extraction) เทคนิคนี้พัฒนาขึ้นเพื่อเรียนรู้ข้อมูลทั้งในมิติพื้นที่และเวลา โดยพิจารณาไม่เพียงแต่การจัดเรียงของพิกเซลในแต่ละเฟรมของวิดีโอเท่านั้น แต่ยังรวมถึงการเปลี่ยนแปลงที่เกิดขึ้นในช่วงเวลาต่าง ๆ ระหว่างเฟรมด้วย ซึ่งมีรายละเอียด ดังนี้

2.2.2.1 การผสมผสานระหว่างเครือข่าย 3D CNN และ Bi-GRU โดย (Yang et al., 2018) นำเสนอชุดข้อมูลมาตรฐาน (Benchmark) ขนาดใหญ่สำหรับการอ่านริมฝีปากในสภาพแวดล้อมในธรรมชาติ ซึ่งชื่อว่า LRW-1000 ซึ่งประกอบด้วย 1,000 หมวดหมู่และ 718,018 ตัวอย่างจากผู้พูดมากกว่า 2,000 คน ซึ่งแต่ละหมวดหมู่จะแทนเสียงพยัญชนะของคำในภาษาจีนกลางที่ประกอบด้วยอักขระจีนหนึ่งตัวหรือมากกว่า ชุดข้อมูลนี้ถือเป็นชุดข้อมูลที่ใหญ่ที่สุดในระดับคำและยังเป็นชุดข้อมูลการอ่านริมฝีปากภาษาจีนกลาง (Mandarin lip-reading) ที่เปิดให้สาธารณะใช้เพียงชุดเดียวที่มีขนาดใหญ่ ชุดข้อมูลนี้มีวัตถุประสงค์ในการครอบคลุมความแปรผันตามธรรมชาติในโหมดการพูดและเงื่อนไขการถ่ายภาพที่แตกต่างกัน เพื่อนำเสนอความท้าทายที่พบจากการใช้งานจริง ทั้งนี้ ผู้เขียนได้นำเสนอการแปลง 2D DenseNet ให้เป็น 3D โดยการนำคอนโวลูชัน 3D ไปใช้ในส่วนหน้า และตั้งชื่อแบบจำลองนี้ว่า D3D (DenseNet in 3D version) ร่วมกับเครือข่ายส่วนท้ายที่มีโครงสร้าง GRU สองชั้นแบบสองทิศทางสำหรับการจำแนกประเภทขั้นสุดท้าย ซึ่งได้ฝึกฝนและประเมินผลแบบจำลองบนข้อมูลทดสอบ LRW โดยผลลัพธ์ที่ได้จากแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 78.00%

2.2.2.2 การผสมผสานระหว่างเครือข่าย 3D + 2D CNN และ Bi-RNN ดังนี้

2.2.2.2.1 ในงานวิจัย (Stafylakis & Tzimiropoulos, 2017) นำเสนอสถาปัตยกรรมการเรียนรู้เชิงลึกแบบ end-to-end สำหรับการรับรู้การพูดด้วยภาพในระดับคำ ซึ่งแบบจำลองนี้เป็นการรวมกันของเครือข่าย Convolutional เชิงพื้นที่และเวลา (Spatiotemporal convolutional), เครือข่าย ResNet และเครือข่าย LSTM แบบสองทิศทาง (Bi-LSTM) ซึ่งได้ฝึกฝนและประเมินผลแบบจำลองบนข้อมูลทดสอบ LRW ซึ่งประกอบไปด้วยคำเป้าหมาย 500 คำ โดยมีคลิปวิดีโอความยาว 1.16 วินาทีจากการเผยแพร่ของ BBC ผลลัพธ์ที่ได้จากแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 83.00%

2.2.2.2.2 ในงานวิจัย (Zhao et al., 2020) นำเสนอข้อจำกัดด้านข้อมูลร่วม (Mutual Information constraints) ทั้งในระดับคุณลักษณะข้อมูลท้องถิ่นและระดับคุณลักษณะ

ข้อมูลรวม เพื่อเพิ่มความสัมพันธ์ระหว่างคุณลักษณะกับเนื้อหาคำพูด ประการแรกจะกำหนดข้อจำกัดในการเพิ่มข้อมูลร่วมในระดับท้องถิ่น (Local Mutual Information Maximization, LMIM) สำหรับคุณลักษณะที่สร้างขึ้นในแต่ละช่วงเวลา ทำให้คุณลักษณะเหล่านี้มีความสัมพันธ์ที่แข็งแกร่งกับเนื้อหาคำพูด ซึ่งนำไปสู่การปรับปรุงความสามารถของแบบจำลองในการเรียนรู้การเคลื่อนไหวของริมฝีปากอย่างละเอียด และความแตกต่างระหว่างคำที่ออกเสียงคล้ายกัน เช่น “spend” และ “spending” ประการที่สองจะกำหนดข้อจำกัดในการเพิ่มข้อมูลร่วมในระดับข้อมูลรวม (Global Mutual Information Maximization, GMIM) เพื่อให้แบบจำลองให้ความสนใจไปที่การแยกแยะกรอบสำคัญที่เกี่ยวข้องกับเนื้อหาคำพูดได้มากขึ้น และลดความสนใจต่อเสียงรบกวนที่เกิดขึ้นในระหว่างการพูด ด้วยการรวมสองข้อนี้เข้าด้วยกัน วิธีการที่เสนอจึงคาดว่าจะมีทั้งความสามารถในการแยกแยะและความทนทานสำหรับการอ่านปากอย่างมีประสิทธิภาพ ทั้งนี้ ผู้เขียนได้นำเสนอแบบจำลองการรวมกันของเครือข่าย 3D CNN, ResNet-18 และ GRU แบบสองทิศทาง (Bi-GRU) จำนวน 3 ชั้น ซึ่งได้ฝึกฝนและประเมินผลแบบจำลองนี้บนข้อมูลทดสอบ LRW โดยผลลัพธ์ที่ได้จากแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 84.41%

2.2.2.2.3 ในงานวิจัย (Luo et al., 2020) นำเสนอวิธีการที่ใช้พื้นฐานจากการไล่ระดับเชิงนโยบายคอนโวลูชันแบบเทียม (Pseudo-convolutional Policy Gradient) เพื่อแก้ปัญหา 2 ประการ คือ 1) การบังคับของผู้สอน (Teacher-forcing) ซึ่งได้นำเสนอแนวทางแก้ไขโดยนำเมตริกซ์การประเมินผล (Word Error Rate, WER) มาใช้ในรูปแบบของการให้รางวัลเพื่อเพิ่มประสิทธิภาพของแบบจำลองร่วมกับเป้าหมายการแยกแยะดั้งเดิม และ 2) ความไม่สอดคล้องกันระหว่างเป้าหมายและการเพิ่มประสิทธิภาพของการแยกแยะ ซึ่งมักใช้การประเมินค่าความสูญเสียจาก Cross-entropy loss จากคุณสมบัติการรับรู้ข้อมูลเชิงพื้นที่ของการดำเนินการ Convolutional ผู้เขียนจึงเสนอการดำเนินการ Pseudo-Convolutional ในมิติของการให้รางวัลและคำนวณค่าการสูญเสีย เพื่อให้แบบจำลองสามารถพิจารณาบริบทโดยรอบของแต่ละช่วงเวลาได้อย่างมีประสิทธิภาพ ทั้งนี้ ผู้เขียนได้นำเสนอแบบจำลองการรวมกันของเครือข่าย 3D CNN, ResNet-18 และ GRU แบบสองทิศทาง (Bi-GRU) จำนวน 2 ชั้น ซึ่งได้ฝึกฝนและประเมินผลแบบจำลองนี้บนข้อมูลทดสอบ LRW โดยผลลัพธ์ที่ได้จากแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 83.50% และอัตราความผิดพลาดของคำ (WER) เท่ากับ 22.70%

2.2.2.2.4 ในงานวิจัย (Cheng et al., 2019) นำเสนอกรอบการดำเนินงานสำหรับการฝึกฝนแบบจำลองการอ่านริมฝีปากที่ไม่อ่อนไหวต่อท่าทาง (Pose-invariant) โดยสร้างข้อมูลสังเคราะห์แทนที่จะเก็บรวบรวมและทำการเครื่องหมายบนข้อมูลที่ไม่ใช่มุมหน้าตรง ซึ่งเป็นขั้นตอนที่มีค่าใช้จ่ายและใช้เวลาดำเนินการนาน ผู้เขียนเสนอแบบจำลองการรวมกันของเครือข่าย 3D CNN,

ResNet-18 และ GRU แบบสองทิศทาง (Bi-GRU) จำนวน 2 ชั้น ซึ่งสามารถทำงานได้ดีกว่าแนวทางในอดีตในการอ่านริมฝีปากจากมุมมองที่ไม่ตรงหน้า ในขณะที่ยังคงรักษาประสิทธิภาพที่เหนือกว่าบนมุมมองที่หันหน้าตรงและมุมมองที่ใกล้เคียงกัน และเสนอให้ใช้แบบจำลอง 3D Morphable Model (3DMM) เพื่อเพิ่มข้อมูลชุด LRW ซึ่งเป็นชุดข้อมูลขนาดใหญ่ที่มุมมองส่วนใหญ่เป็นหน้าตรง และนำชุดข้อมูลดังกล่าว ไปสร้างข้อมูลใบหน้าสังเคราะห์ในท่าทางที่หลากหลาย ซึ่งข้อมูลชุดใหม่ถูกใช้ในการฝึกฝนแบบจำลองที่เสนอสำหรับการอ่านริมฝีปาก โดยให้ผลลัพธ์ที่ได้จากแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 79.53%

2.2.2.2.5 ในงานวิจัย (Feng et al., 2020) นำเสนอสถาปัตยกรรมการเรียนรู้เชิงลึกที่รวมกันของเครือข่าย 3D CNN, ResNet-18 และ GRU แบบสองทิศทาง (Bi-GRU) ซึ่งวิธีการส่วนใหญ่ในปัจจุบันสามารถทำงานได้ดีโดยการสร้างเครือข่ายประสาทเทียมที่ซับซ้อนร่วมกับเทคนิคในการฝึกฝนที่ปรับแต่งเฉพาะซึ่งมักจะอธิบายรายละเอียดอย่างสั้น ๆ ผู้เขียนพบว่าการใช้เทคนิค Squeeze-and-Excitation Networks, MixUp, Cosine Learning Rate Scheduling, Label Smoothing และ Word Boundary อย่างเหมาะสมสามารถนำไปสู่การปรับปรุงที่มีประสิทธิภาพมากขึ้น โดยไม่จำเป็นต้องเปลี่ยนแปลงโครงสร้างแบบจำลองมากนัก จึงได้ทำการศึกษา วิเคราะห์ เปรียบเทียบในมิติรอบด้านเพื่อแสดงผลกระทบของเทคนิคที่แตกต่างกันในการอ่านริมฝีปาก และเสนอแนวทางการปรับปรุงที่ง่ายต่อเส้นทางพื้นฐาน (Baseline pipeline) ซึ่งสามารถปรับปรุงประสิทธิภาพจาก 83.7% เป็น 88.4% ในชุดข้อมูลการอ่านริมฝีปากที่เปิดเผยต่อสาธารณะขนาดใหญ่ที่สุดคือ LRW ซึ่งมีค่าเทียบเคียงกับหรือแม้กระทั่งเหนือกว่าผลลัพธ์ที่ดีที่สุดขณะนั้น

2.2.2.3 การผสมผสานระหว่างเครือข่าย 3D + 2D CNN และ TCN ดังนี้

2.2.2.3.1 ในงานวิจัย (Martínez et al., 2020) นำเสนอข้อจำกัดของสถาปัตยกรรมการเรียนรู้เชิงลึกที่รวมกันของเครือข่าย 3D CNN, ResNet-18 และ GRU แบบสองทิศทาง (Bi-GRU) และเสนอแนวทางการเปลี่ยนแปลงเพื่อปรับปรุงประสิทธิภาพของแบบจำลองเพิ่มเติม ประกอบด้วย 1) แทนที่ชั้น Bi-GRU ด้วย Temporal Convolutional Networks (TCN) ซึ่งช่วยเพิ่มประสิทธิภาพในการประมวลผลข้อมูล 2) ทำให้ขั้นตอนการฝึกฝนเรียบง่ายขึ้น ซึ่งสามารถฝึกฝนแบบจำลองได้ในขั้นตอนเดียว และ 3) แสดงให้เห็นว่าแบบจำลองในปัจจุบันไม่สามารถทนทานต่อความหลากหลายของความยาวลำดับได้ จึงนำเสนอวิธีการขยายความยาวลำดับแบบปรับเปลี่ยนได้ ซึ่งผลลัพธ์จากชุดข้อมูลขนาดใหญ่ที่เปิดให้ใช้งานแก่สาธารณะสำหรับการรู้จำคำพูดในภาษาอังกฤษ คือ ชุดข้อมูล LRW ซึ่งแบบจำลองที่เสนอแสดงให้เห็นถึงความถูกต้องของการทำนายคำ (Word accuracy) เท่ากับ 85.30% และถือว่าแบบจำลองมีประสิทธิภาพที่ดีที่สุดในขณะนั้น

2.2.2.3.2 ในงานวิจัย (Ma, Martínez, et al., 2020) นำเสนอเทคนิคที่สามารถลดช่องว่างที่สำคัญระหว่างวิธีการในปัจจุบันและข้อกำหนดสำหรับการใช้งานการอ่านริมฝีปากอย่างมีประสิทธิภาพในสถานการณ์จริง ประกอบด้วย 1) ยกระดับประสิทธิภาพที่ดีที่สุดในปัจจุบันให้สูงขึ้น 88.5% ในชุดข้อมูล LRW โดยการใช้เทคนิคการเรียนรู้จากตนเอง (Self-distillation) 2) นำเสนอการเปลี่ยนแปลงทางสถาปัตยกรรมที่หลากหลาย รวมถึงการสร้างส่วนหน้าของแบบจำลองด้วย Depthwise Separable Temporal Convolutional Network (DS-TCN) ซึ่งช่วยลดต้นทุนการคำนวณให้เหลือน้อยลงอย่างมากเมื่อเปรียบเทียบกับแบบจำลองต้นแบบที่มีประสิทธิภาพดีอยู่แล้ว และ 3) แสดงให้เห็นว่าการถ่ายทอดความรู้ (Knowledge distillation) เป็นเครื่องมือที่มีประสิทธิภาพสูงในการฟื้นฟูประสิทธิภาพของแบบจำลองที่มีขนาดเล็ก ทั้งนี้ แบบจำลองขนาดเล็กที่มีแนวโน้มดีที่สุดสามารถทำงานได้ในระดับเดียวกับแบบจำลองที่ดีที่สุด ในขณะที่ขณะเดียวกันก็ลดต้นทุนการคำนวณได้ถึง 8.2 เท่า และลดจำนวนพารามิเตอร์ได้ถึง 3.9 เท่า ซึ่งเราหวังว่าจะช่วยให้สามารถนำแบบจำลองการอ่านริมฝีปากมาใช้ในแอปพลิเคชันจริงได้อย่างมีประสิทธิภาพ

2.2.2.3.3 ในงานวิจัย (Ma, Wang, et al., 2020) นำเสนอ Densely Connected Temporal Convolutional Network (DC-TCN) สำหรับการอ่านริมฝีปากของคำพูด ในขณะที่ Temporal Convolutional Networks (TCN) แสดงศักยภาพที่ดีในหลายงานด้านการมองเห็นด้วยภาพ แต่ยังไม่สามารถสร้างพื้นที่รับข้อมูลได้อย่างหนาแน่นพอสำหรับแบบจำลองเชิงซ้อนในสถานการณ์การอ่านริมฝีปากได้อย่างมีประสิทธิภาพ เพื่อเป็นการแก้ไขปัญหาดังกล่าว ผู้เขียนได้เสนอการเชื่อมต่อแบบหนาแน่น (Dense connections) ในโครงสร้างของเครือข่ายเพื่อช่วยในการจับคุณลักษณะทางเวลาที่มีประสิทธิภาพมากขึ้น นอกจากนี้ ยังใช้ Squeeze-and-Excitation block ซึ่งเป็นกลไกความสนใจที่มีน้ำหนักเบา มาช่วยเพิ่มขีดความสามารถในการจำแนกประเภทของแบบจำลองให้ดียิ่งขึ้น โดยไม่ต้องใช้เทคนิคพิเศษอื่นใดเพิ่มเติม ซึ่ง DC-TCN ที่นำเสนอได้รับความแม่นยำถึง 88.36% ในการทดสอบบนชุดข้อมูล Lip Reading in the Wild (LRW) ซึ่งทำให้แบบจำลองสามารถเอาชนะวิธีการพื้นฐานทั้งหมดและกลายเป็นมาตรฐานใหม่ที่ดีที่สุดในขณะนั้น

2.2.2.4 การผสมผสานระหว่างเครือข่าย 3D CNN, Transformer และ (TCN หรือ Bi-GRU) ดังนี้

2.2.2.4.1 ในงานวิจัย (Wiriathamabhum, 2020) นำเสนอสถาปัตยกรรม SpotFast Networks ที่มีประสิทธิภาพสูงในการจดจำการกระทำ โดยการใช้หน้าต่างเวลาเป็นเส้นทางของจุด (Spot pathway) และใช้กรอบของภาพทั้งหมดเป็นเส้นทางที่รวดเร็ว (Fast pathway) นอกจากนี้ ยังได้รวมเอา Memory Augmented Lateral Transformers เข้าด้วยกันเพื่อเรียนรู้ลักษณะเฉพาะตามลำดับสำหรับการแยกประเภท และได้รับการประเมินแบบจำลองที่เสนอในชุดข้อมูล LRW ซึ่งผลการทดสอบแสดงให้เห็นว่าแบบจำลองมีประสิทธิภาพเหนือกว่าแบบจำลอง

มาตรฐานที่ดีที่สุด และการรวม Memory Augmented Lateral Transformers ช่วยเพิ่มประสิทธิภาพให้กับ SpotFast Networks ได้รับความแม่นยำถึง 84.40% ซึ่งแสดงให้เห็นถึงความก้าวหน้าในการอ่านริมฝีปากในระดับคำ

2.2.2.4.2 ในงานวิจัย (Wang et al., 2022) นำเสนอวิธีการอ่านริมฝีปากที่ใช้ 3D Convolutional Vision Transformer (3DCvT) ซึ่งรวมการทำงานของ Vision Transformer และการทำงานของ 3D Convolution เพื่อดึงลักษณะเฉพาะในเชิงพื้นที่และเวลา (Spatio-temporal feature) จากภาพต่อเนื่อง โดยใช้คุณสมบัติของการทำ Convolutions และ Transformers เพื่อสกัดคุณลักษณะเฉพาะทั้งในระดับพื้นที่และระดับภาพรวมอย่างมีประสิทธิภาพ จากนั้นคุณลักษณะเฉพาะที่สกัดมาได้จะถูกส่งไปยัง Bidirectional Gated Recurrent Unit (Bi-GRU) เพื่อทำการสร้างแบบจำลองลำดับ ซึ่งพิสูจน์ได้ถึงประสิทธิภาพของวิธีการนี้ในชุดข้อมูลการอ่านริมฝีปากขนาดใหญ่ LRW ได้รับความแม่นยำถึง 88.50% และสามารถบรรลุประสิทธิภาพที่ดีที่สุด在这一สาขา

2.2.2.5 การผสมผสานระหว่างเครือข่าย 3D + 2D CNN, และ (TCN + Attention หรือ Transformer + TCN) ดังนี้

2.2.2.5.1 ในงานวิจัย (Chen et al., 2020) นำเสนอแนวทางสถาปัตยกรรมการเรียนรู้เชิงลึกแบบใหม่เพื่อปรับปรุงการอ่านริมฝีปากในระดับคำ ประกอบด้วย 1) เสนอการประมวลผลหลายขนาดเพื่อการสกัดคุณลักษณะเฉพาะในเชิงพื้นที่สำหรับการอ่านริมฝีปาก และได้พัฒนาวิธีการที่เรียกว่า Hierarchical Pyramidal Convolution (HPConv) เพื่อแทนที่การดำเนินการ Convolution แบบดั้งเดิม ซึ่งช่วยเสริมประสิทธิภาพของแบบจำลองในการเรียนรู้การเคลื่อนไหวของริมฝีปากที่ละเอียดขึ้น 2) เสนอการรวมข้อมูลจากทุกช่วงเวลาของลำดับโดยใช้ Self-attention ซึ่งช่วยให้แบบจำลองให้ความสนใจกับภาพที่สำคัญมากขึ้น ทั้งนี้ ข้อได้เปรียบทั้งสองนี้ได้ถูกนำมารวมกันเพื่อเสริมกำลังในการจำแนกประเภทของแบบจำลองอีกชั้นหนึ่ง ผลการทดลองในชุดข้อมูล Lip Reading in the Wild (LRW) แสดงให้เห็นว่าแบบจำลองที่นำเสนอสามารถบรรลุความแม่นยำ 86.83% ซึ่งเพิ่มขึ้น 1.53% เมื่อเปรียบเทียบกับแบบจำลองที่มีประสิทธิภาพดีที่สุดในขณะนั้น นอกจากนี้ ยังได้ทำการทดลองอย่างกว้างขวางเพื่อให้เข้าใจพฤติกรรมของแบบจำลองที่เสนออย่างละเอียดมากขึ้น

2.2.2.5.2 ในงานวิจัย (Koumparoulis & Potamianos, 2022) นำเสนอสถาปัตยกรรมการอ่านริมฝีปากแบบใหม่ที่มีประสิทธิภาพในด้านการใช้ทรัพยากร ซึ่งสามารถให้ผลลัพธ์ที่ดีที่สุดในชุดข้อมูลมาตรฐานที่ได้รับความนิยมและท้าทาย ประกอบด้วย 1) เสนอการนำ EfficientNet มาใช้ในงานการอ่านริมฝีปาก ซึ่งได้ความสำเร็จในการจำแนกประเภทภาพ 2) เสนอให้ลดชั้น Max-pooling ออกจากเครือข่าย 3 มิติ ในส่วนหน้า (Front-end) ที่ได้รับความนิยมมากที่สุด

ในปัจจุบัน ซึ่งทำให้เครือข่ายมีประสิทธิภาพที่ดีขึ้น และ 3) เสนอการปรับปรุงเครือข่ายในส่วนท้าย (Back-end) โดยรวม Transformer encoder เข้าไป และได้ทำการประเมินแบบจำลองที่เสนอ ในชุดข้อมูล Lip Reading in the Wild (LRW) ซึ่งเป็นฐานข้อมูลที่ประกอบด้วยคลิปวิดีโอสั้นจากการออกอากาศของช่อง BBC ซึ่งผลการทดลองแสดงให้เห็นว่าแบบจำลองที่เสนอ (T-variant) มีความแม่นยำในการจำแนกคำ 88.53% ซึ่งเพิ่มขึ้น 0.17% เมื่อเปรียบเทียบกับผลลัพธ์ที่ดีที่สุด ในขณะที่นั้น โดยใช้ทรัพยากรในการคำนวณน้อยกว่าถึงห้าเท่า นอกจากนี้ รุ่นที่ขยายขนาดของแบบจำลอง (L-variant) ยังสามารถทำความแม่นยำได้ถึง 89.52% ซึ่งเป็นผลลัพธ์ที่ดีที่สุดบนชุดข้อมูล LRW

2.2.3 เทคนิคการผสมผสานข้อมูลหลายรูปแบบ (Multimodal Fusion) เทคนิคนี้รวมข้อมูลจากหลายแหล่งหรือหลายรูปแบบ เช่น การใช้ข้อมูลจากภาพ เสียง หรือ Deformation flow รายละเอียดดังนี้

2.2.3.1 ข้อมูลทั้งภาพและเสียง (Audio and visual)

2.2.3.1.1 การผสมผสานเครือข่ายหลายรูปแบบ (Visual) 3D CNN, (Audio) 2D CNN และ (LSTM + Attention หรือ Transformer) ดังนี้

ก) ในงานวิจัย (Chung et al., 2016) นำเสนองานวิจัยการรับรู้คำและประโยคจากวิดีโอใบหน้าที่กำลังพูด ซึ่งสามารถแยกแยะประเภทได้ทั้งข้อมูลที่มีเสียงและไม่มีเสียง จึงเสนอการอ่านริมฝีปากโดยใช้ประโยคในภาษาธรรมชาติอย่างไม่จำกัดและวิดีโอจากสถานการณ์จริง โดยมีข้อเสนอหลัก 3 ประการ ประกอบด้วย 1) เครือข่าย ‘Watch, Listen, Attend and Spell’ (WLAS) ซึ่งเรียนรู้การถอดเสียงจากวิดีโอการเคลื่อนไหวของริมฝีปากเป็นตัวอักษร 2) กลยุทธ์การเรียนรู้แบบหลักสูตร เพื่อเร่งกระบวนการฝึกฝนและลดการเกิด Overfitting 3) ชุดข้อมูล ‘Lip Reading Sentences’ (LRS) สำหรับการรับรู้การพูดด้วยภาพ ประกอบด้วยประโยคกว่า 100,000 ประโยค จากรายการโทรทัศน์ของอังกฤษในชุดข้อมูล LRW ซึ่งแบบจำลอง WLAS ที่นำเสนอได้รับการฝึกฝนจากชุดข้อมูล LRS และทำการทดสอบแบบจำลองกับชุดข้อมูล LRW ซึ่งมีอัตราความผิดพลาดของคำ (WER) เท่ากับ 23.8% และยังแสดงให้เห็นว่าข้อมูลภาพช่วยปรับปรุงประสิทธิภาพการรู้จำเสียง

ข) ในงานวิจัย (Ren et al., 2021) นำเสนอกรอบการทำงานใหม่สำหรับการอ่านริมฝีปาก โดยพิจารณาปัญหาสองด้านหลัก ประกอบด้วย 1) ผู้สอนควรมีความเข้าใจในความรู้ทั้งจากเสียงและภาพ เพื่อช่วยลดช่องว่างของความเข้าใจระหว่างทั้งสองรูปแบบ 2) ผู้สอนควรปรับเนื้อหาการสอนตามพัฒนาการของผู้เรียน เพื่อให้บรรลุเป้าหมายนี้ ผู้เขียนได้พัฒนาเครือข่าย “Master” ที่สามารถฝึกฝนได้ ซึ่งใช้ข้อมูลเสียงและวิดีโอริมฝีปากเข้าด้วยกัน โดย Master จะสร้างเนื้อหาการสอนจากข้อมูลทั้งสามประเภท ได้แก่ เสียง วิดีโอ และการรวมกันของทั้งเสียงและวิดีโอ นอกจากนี้ ผู้เขียนยังออกแบบวิธีการที่ช่วยให้สามารถรวมความรู้จากสาขาต่างๆ ได้ดีขึ้น โดยด้วยการตอบกลับ (Feedback) จากนักเรียนที่ช่วยปรับปรุงการสอนของ Master อีกทั้ง ได้นำเสนอ

เครือข่าย “Tutor” เพื่อช่วยเน้นย้ำความรู้ในกระบวนการเรียนรู้ สุดท้ายได้เพิ่มแนวทางการเรียนรู้แบบหลักสูตร (Curriculum learning) เพื่อช่วยให้มีการพัฒนาอย่างมีประสิทธิภาพและทำการทดสอบแบบจำลองกับชุดข้อมูล LRW ซึ่งมีอัตราความผิดพลาดของคำ (WER) เท่ากับ 14.30% รวมถึงการทดลองที่หลากหลายแสดงให้เห็นว่าเครือข่ายที่เรานำเสนอมีประสิทธิภาพดีกว่าวิธีการที่ดีที่สุด ในขณะที่นั้น ทั้งในระดับคำและระดับประโยค

2.2.3.1.2 การผสมผสานเครือข่ายหลายรูปแบบ ((Visual) 3D + 2D CNN, (Audio) 2D CNN) และ Bi-GRU ในงานวิจัย (Petridis et al., 2018) นำเสนอแนวทางการเรียนรู้เชิงลึกแบบ end-to-end หลายวิธีที่สามารถสกัดคุณลักษณะจากสัญญาณภาพและเสียงเพื่อทำการรู้จำเสียงพูด ซึ่งอ้างอิงจากเครือข่าย ResNet และ Bi-GRU โดยแบบจำลองนี้สามารถสกัดคุณลักษณะจากพิกเซลในภาพและรูปร่างคลื่นเสียงได้ในเวลาเดียวกัน และสามารถรู้จำคำในบริบทจากชุดข้อมูลขนาดใหญ่ที่เปิดให้เข้าถึงได้ LRW แบบจำลองนี้ประกอบด้วย 2 สาขา ซึ่งจะสกัดคุณลักษณะโดยตรงจากบริเวณริมฝีปากปากและจากรูปร่างคลื่นเสียงแยกกัน โดยจะนำเข้าสู่ข้อมูลแต่ละสาขาไปยัง Bi-GRU จำนวน 2 ชั้น ในจัดการกับลำดับของเวลา และรวมข้อมูลจากสองสาขาเข้าด้วยกันผ่าน Bi-GRU จำนวน 2 ชั้นอีกชุดหนึ่ง เมื่อเปรียบเทียบกับแบบจำลองที่ใช้เสียงเพียงอย่างเดียวและแบบจำลองที่ใช้ MFCC (Mel Frequency Cepstral Coefficients) พบว่ามีการปรับปรุงอัตราการจำแนกประเภทขึ้นเล็กน้อยในสถานะที่เสียงที่ชัดเจนหรือมีเสียงรบกวนต่ำ แต่ในสถานะที่มีเสียงรบกวนสูงแบบจำลองที่นำเสนอแสดงผลลัพธ์ที่ดีกว่าแบบจำลองที่ใช้เพียงข้อมูลเสียงเท่านั้นอย่างมีนัยสำคัญ ซึ่งผลการทดลองในชุดข้อมูล LRW แสดงให้เห็นว่าแบบจำลองที่นำเสนอสามารถบรรลุความแม่นยำ 82.00%

2.2.3.2 ข้อมูลทั้งภาพและการไหลของการเปลี่ยนรูป (Visual and Deformation flow)

การผสมผสานเครือข่ายหลายรูปแบบ ((DF) 2D CNN, (Visual) 3D + 2D CNN) และ Bi-GRU ในงานวิจัย (Xiao et al., 2020) นำเสนอเครือข่าย Deformation Flow Network (DFN) เพื่อเรียนรู้การไหลของการเปลี่ยนรูประหว่างเฟรมที่ติดกัน ซึ่งจะเรียนรู้การเคลื่อนไหวในบริเวณริมฝีปากได้โดยตรง จากนั้น DFN ที่ได้เรียนรู้จะถูกรวมเข้ากับเฟรมภาพสีเทาต้นฉบับด้วยเครือข่ายแบบสองสาขาที่สามารถเรียนรู้จากกันและกันในกระบวนการเรียนรู้ผ่านการสูญเสียความรู้แบบสองทิศทาง (Bidirectional knowledge distillation loss) เพื่อทำการฝึกฝนทั้งสองสาขาพร้อมกัน เนื่องจากมีข้อมูลเสริมที่มาจากแต่ละสาขาที่ต่างกัน แบบจำลองเครือข่ายแบบสองสาขาที่เสนอแสดงให้เห็นถึงการปรับปรุงที่ชัดเจนเมื่อเปรียบเทียบการใช้เครือข่ายเพียงแค่สาขาเดียว อีกทั้งนำเสนอการประเมินผลการทดลองในชุดข้อมูลการอ่านริมฝีปากขนาดใหญ่ LRW ซึ่งแสดงให้เห็นว่าแบบจำลองที่นำเสนอสามารถบรรลุความแม่นยำ 84.13% และจากการวิเคราะห์อย่างละเอียด

ผลลัพธ์ที่ได้สอดคล้องกับแนวคิดและยังแสดงให้เห็นว่าเป็นวิธีการที่สามารถทำได้ผลลัพธ์ที่ดีที่สุด
ในขณะนั้น



บทที่ 3

การออกแบบ

การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพนั้น ผู้วิจัยได้แบ่งกระบวนการออกแบบเป็น 3 ขั้นตอน ประกอบด้วย ศึกษางานวิจัยที่เกี่ยวข้อง, การออกแบบแบบจำลอง และการฝึกฝนแบบจำลอง

3.1 ศึกษางานวิจัยที่เกี่ยวข้อง

ตารางที่ 3-1 แสดงงานวิจัยที่เกี่ยวข้อง

No.	Title	Spatial encode	Temporal encode	Recognition	Modality	WER	Accuracy
เทคนิคการค้นหาลักษณะเชิงพื้นที่ (Spatial Feature Extraction)							
1	Lip Reading in the Wild (Chung & Zisserman, 2016)	C3D	C3D	Word	V	-	61.10
เทคนิคการค้นหาลักษณะเชิงพื้นที่และเวลา (Spatial-temporal Feature Extraction)							
2	LRW-1000: A Naturally-Distributed Large-Scale Benchmark for Lip Reading in the Wild (Yang et al., 2018)	C3D	Bi-GRU	Word	V	-	78.00
3	Combining Residual Networks with LSTMs for Lipreading (Stafylakis & Tzimiropoulos, 2017)	C3D + C2D (ResNet-34)	Bi-LSTM	Word	V	-	83.00
4	Mutual Information Maximization for Effective Lip Reading (Zhao et al., 2020)	C3D + C2D (ResNet-18)	Bi-GRU	Word	V	-	84.41
5	Pseudo-Convolutional Policy Gradient for Sequence-to-Sequence Lip-Reading (Luo et al., 2020)	C3D + C2D (ResNet-18)	Bi-GRU	Sentence, Word	V	22.70	83.50
6	Towards Pose-Invariant Lip-Reading (Cheng et al., 2019)	C3D + C2D (ResNet-18)	Bi-GRU	Sentence, Word	V	-	79.53
7	Learn an Effective Lip Reading Model without Pains (Feng et al., 2020)	C3D + C2D (ResNet-18)	Bi-GRU	Word	V	-	88.40
8	Lipreading Using Temporal Convolutional Networks (Martínez et al., 2020)	C3D + C2D (ResNet-18)	MS-TCN	Word	V	-	85.30


ตารางที่ 3-1 แสดงงานวิจัยที่เกี่ยวข้อง (ต่อ)

No.	Title	Spatial encode	Temporal encode	Recognition	Modality	WER	Accuracy
9	Towards Practical Lipreading with Distilled and Efficient Models (Ma, Martinez, et al., 2020)	C3D + C2D (ShuffleNet-V2)	DS-TCN	Word	V	-	88.50
10	Lip-reading with Densely Connected Temporal Convolutional Networks (Ma, Wang, et al., 2020)	C3D + C2D (ResNet-18)	DC-TCN	Word	V	-	88.36
11	SpotFast Networks with Memory Augmented Lateral Transformers for Lipreading (Wiryathammabhum, 2020)	C3D + Transformer	TCN	Word	V	-	84.40
12	A Lip Reading Method Based on 3D Convolutional Vision Transformer (Wang et al., 2022)	C3D + Transformer	Bi-GRU	Word	V	-	88.50
13	Lip-reading with Hierarchical Pyramidal Convolution and Self-Attention (Chen et al., 2020)	C3D + C2D (ResNet-18)	MS-TCN/ Self-attention	Word	V	-	86.83
14	Accurate and Resource-Efficient Lipreading with Efficientnetv2 and Transformers (Koumparoulis & Potamianos, 2022)	C3D + C2D (EfficientNet-V2)	Transformer + TCN	Word	V	-	89.52
เทคนิคการผสานข้อมูลหลายรูปแบบ (Multimodal Fusion)							
15	Lip Reading Sentences in the Wild (Chung et al., 2016)	(V) C3D (A) C2D	LSTM/ Self-attention	Sentence, Word	AV	23.80	-
16	Learning from the Master: Distilling Cross-modal Advanced Knowledge for Lip Reading (Ren et al., 2021)	(V) C3D (A) C2D (ResNet-18)	Transformer (TM-Seq2Seq)	Sentence, Word	AV	14.30	-
17	End-to-End Audiovisual Speech Recognition (Petridis et al., 2018)	(V) C3D + C2D (ResNet-34) (A) C2D (ResNet-18)	Bi-GRU	Word	AV	-	97.70(A), 82.00(V), 98.00(AV)
18	Deformation Flow Based Two-Stream Network for Lip Reading (Xiao et al., 2020)	C2D, 3D + C2D (ResNet-18)	Bi-GRU	Word	V	-	84.13

หมายเหตุ: A = Audio, V = Visual, AV = Audio-Visual, DF = Deformation flow,
C2D = 2D CNN, C3D = 3D CNN

จากการศึกษางานวิจัยที่เกี่ยวข้องพบว่าแบบจำลอง Spatial-temporal แบบผสมผสาน จะให้ประสิทธิภาพสูงกว่าแบบจำลองทั่วไป แต่อย่างไรก็ตามแบบจำลองผสมผสานมักมีความซับซ้อน ของแบบจำลองทำให้ต้องใช้ทรัพยากรในการประมวลผลสูง และอาจเกิด Overfitting ได้ง่าย

3.2 การออกแบบแบบจำลอง สามารถแบ่งกระบวนการออกเป็น 4 ขั้นตอน แสดงดังภาพที่ 3-1




ภาพที่ 3-1 แสดงกระบวนการออกแบบแบบจำลองที่นำเสนอ

3.2.1 การประมวลผลข้อมูลล่วงหน้า (Data preprocessing)

ชุดข้อมูล Lipreading in the Wild (LRW) เป็นไฟล์วิดีโอสั้น ๆ ที่แสดงภาพใบหน้าของบุคคลที่กำลังพูดคำศัพท์ภาษาอังกฤษหนึ่งคำโดยมีความยาวประมาณ 1.16 วินาที (29 เฟรม ที่ 25 เฟรมต่อวินาที) ซึ่งตัดไฟล์วิดีโอมาจากรายการโทรทัศน์ในสภาพแวดล้อมที่หลากหลายของช่อง BBC ซึ่งไฟล์วิดีโอเหล่านี้มีการจัดกึ่งกลางที่ปากของผู้พูดและอยู่ในรูปแบบสี ขนาด 256×256 พิกเซล โดยแบ่งออกเป็นขั้นตอนการประมวลผลข้อมูลล่วงหน้าของชุดข้อมูล ประกอบด้วย การตรวจจับและสกัดริมฝีปาก และการสกัดคุณลักษณะของริมฝีปาก

3.2.1.1 การตรวจจับและสกัดริมฝีปาก (Lip Detection and Extraction) ในขั้นตอนนี้เป็นการนำ OpenCV มาใช้สำหรับการอ่านไฟล์วิดีโอเป็นภาพสีทีละเฟรม และส่งเฟรมต่อไปให้กับ MediaPipe เพื่อใช้อัลกอริทึมค้นหาจุดสังเกต (Landmark) บนใบหน้าและสร้างเป็นโครงข่ายใบหน้า (Face Mesh) จำนวน 478 จุด แสดงดังภาพที่ 3-2




ภาพที่ 3-2 แสดงการตรวจจับและสกัดริมฝีปาก

3.2.1.2 การสกัดคุณลักษณะของริมฝีปาก (Lip Feature Extraction) ในขั้นตอนนี้เมื่อได้โครงข่ายใบหน้า จำนวน 478 จุด เรียบร้อยแล้ว จึงเลือกเฉพาะจุดบนริมฝีปาก จำนวน 40 จุด (แสดงดังภาพที่ 3-3) โดยสามารถทำการคำนวณหาพิกัด (x, y) ของแต่ละจุดบนริมฝีปาก ดังสมการที่ 3-1

$$lip_coords_p = ((landmarks_p^x \cdot width), (landmarks_p^y \cdot height)) \dots\dots\dots (3 - 1)$$

โดยที่:

p	คือ	จุดบนริมฝีปาก
lip_coords_p	คือ	เป็นพิกัด (x, y) ของจุดบนริมฝีปาก จำนวน 40 จุด
$landmarks_p^{x,y}$	คือ	เป็นพิกัด (x, y) ของจุด p แต่ละจุด



ภาพที่ 3-3 แสดงคุณลักษณะของริมฝีปาก จำนวน 40 จุด

3.2.1.3 การคำนวณหาขอบเขตพื้นที่ของริมฝีปาก ซึ่งเป็นพื้นที่รอบริมฝีปากถูกกำหนดจากพิกัด x และ y ที่น้อยที่สุดและมากที่สุด ณ จุดพิกัดของริมฝีปาก และได้เพิ่มเติมค่าเผื่อ (Padding) ในการขยายขอบเขตพื้นที่รอบริมฝีปากออกไป 10 พิกเซล แสดงดังสมการที่ 3-2 หลังจากนั้นจึงดำเนินการจัดตำแหน่งของริมฝีปากให้อยู่กึ่งกลางเฟรม ทำการเติมค่าเผื่อศูนย์ (Zero Padding) ให้มีขนาดเท่ากับวิดีโอต้นฉบับ (256x256 พิกเซล) แสดงการสกัดคุณลักษณะของริมฝีปากดังภาพที่ 3-4

$$x_{min} = \min(\text{landmarks}_p^x) - \text{padding} \quad \dots\dots\dots (3-2)$$

$$x_{max} = \max(\text{landmarks}_p^x) + \text{padding}$$


$$y_{min} = \min(\text{landmarks}_p^y) - \text{padding}$$

$$y_{max} = \max(\text{landmarks}_p^y) + \text{padding}$$

โดยที่:

x_{min}, y_{min} คือ ค่าต่ำสุดของ x, y ของจุดที่ p


x_{max}, y_{max} คือ ค่าสูงสุดของ x, y ของจุดที่ p



ภาพที่ 3-4 การสกัดคุณลักษณะของริมฝีปาก


3.2.2 โครงสร้างแบบจำลอง

งานวิจัยนี้จึงได้มีการพัฒนาแบบจำลองผสมผสาน Spatial-temporal ที่มีขนาดเหมาะสม โดยใช้แนวคิดของ (Ren et al., 2021) ซึ่งได้นำโครงสร้างของ 3D CNN กับ 2D CNN (ResNet-18) มาใช้ในการค้นหาคุณลักษณะเชิงการมองเห็นด้วยภาพ และได้นำ TCN ร่วมกับ Self-Attention เพื่อค้นหาคุณลักษณะของเวลาได้อย่างมีประสิทธิภาพ แต่เนื่องด้วยแบบจำลองดังกล่าวมีความซับซ้อนของแบบจำลอง และต้องการใช้ทรัพยากรในการประมวลผลสูง นักวิจัยจึงมีแนวคิดในการลดความซับซ้อนของแบบจำลอง ลดทรัพยากรที่ใช้ในการประมวลผลแต่ประสิทธิภาพที่ยังใกล้เคียงกับแบบจำลองในปัจจุบัน ซึ่งมีกระบวนการในการจดจำคำพูดด้วยภาพที่ผู้วิจัยนำเสนอแสดงดังภาพที่ 3-5



ภาพที่ 3-5 แสดงแบบจำลองการจดจำคำพูดด้วยภาพที่ผู้วิจัยนำเสนอ โดยมีรายละเอียดของโครงสร้างเครือข่าย ดังนี้

3.2.2.1 การเข้ารหัสข้อมูลเชิงพื้นที่ (Spatial encode) ประกอบด้วย 3D CNN จำนวน 1 ชั้น 2D CNN จำนวน 4 ชั้น Global Average Pooling จำนวน 1 ชั้น และ Batch Normalization, ReLU จำนวน 5 ชั้น แสดงดังภาพที่ 3-6



ภาพที่ 3-6 แสดงโครงสร้างการเข้ารหัสข้อมูลเชิงพื้นที่

3.2.2.1.1 ชั้น Inputs layer ที่มีขนาด (29,112,112,3) โดยที่ 29 คือ จำนวนเฟรมวิดีโอ, 112 คือ ขนาดความสูงและความกว้างของเฟรมวิดีโอ และ 3 คือ ประเภทช่องสีของวิดีโอ ซึ่งในที่นี้คือ RGB

3.2.2.1.2 ชั้น 3D Conv (3D CNN) เป็นชั้นที่รับข้อมูลมาจากชั้น Inputs มาดำเนินการคอนโวลูชันด้วย Kernel ที่มีขนาด (3,5,5) (หมายความว่า ดำเนินการบนพื้นที่ขนาด 5x5 พิกเซล ระหว่างเฟรมที่อยู่ติดกันจำนวน 3 เฟรม) และ Stride ที่มีขนาด (1,2,2) (หมายความว่า ดำเนินการขยับ Kernel แนวความลึก 1 พิกเซล และแนวความสูงหรือแนวความกว้าง 2 พิกเซล) ทำให้ในชั้นนี้ดำเนินการทำคอนโวลูชันแบบ 3 มิติ ระหว่าง 3 เฟรมที่อยู่ติดกันทำให้สามารถเรียนรู้ความสัมพันธ์ในเชิงเวลาในระยะสั้นได้


3.2.2.1.3 ชั้น 2D Conv (2D CNN) จำนวน 4 ชั้น ซึ่งเป็นชั้นที่รับข้อมูลมาจากชั้น 3D Conv หรือ 2D Conv ด้วยกันมาดำเนินการคอนโวลูชันด้วย Kernel ที่มีขนาด (3,3) (หมายความว่า ดำเนินการบนพื้นที่ขนาด 3x3 พิกเซล) และ Stride ที่มีขนาด (2,2) (หมายความว่า ดำเนินการขยับ Kernel ในแนวความสูงหรือแนวความกว้าง 2 พิกเซล) ซึ่งแต่ละชั้นมีการกำหนดค่า Filter หรือจำนวนของ Kernel ที่ 64, 128, 256 และ 512 ที่แตกต่างกันตามลำดับ ทำให้ในแต่ละชั้นของ 2D Conv สามารถเรียนรู้คุณลักษณะของข้อมูลที่มีความละเอียดของความสัมพันธ์ในเชิงพื้นที่ที่เพิ่มขึ้นในแต่ละชั้น

3.2.2.1.4 ชั้น Global Average Pooling (GAP) เป็นชั้นที่รับข้อมูลมาจากชั้น 2D Conv ชั้นสุดท้าย ซึ่ง GAP จะคำนวณค่าเฉลี่ยของแต่ละแผนที่คุณลักษณะ (Feature map) ซึ่งช่วยให้สามารถรักษาคุณลักษณะเฉพาะที่สำคัญของข้อมูลได้ดียิ่งขึ้น

3.2.2.1.5 ชั้น Norm (Batch Normalization) เป็นชั้นที่ใช้ในการช่วยลดความไม่แน่นอนในการกระจายข้อมูลของชั้นต่าง ๆ และทำให้การเรียนรู้เป็นไปอย่างรวดเร็วและมีประสิทธิภาพ

3.2.2.1.6 ชั้น ReLU (Rectified Linear Unit) เป็นชั้นที่ใช้ในการช่วยให้แบบจำลองมีความสามารถในการเรียนรู้แบบไม่เป็นเชิงเส้น ทำให้สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนและไม่เป็นเชิงเส้นของข้อมูลได้ โดยที่หากข้อมูลมีค่าต่ำกว่าศูนย์เมื่อผ่านฟังก์ชันกระตุ้น ReLU จะแทนที่ข้อมูลด้วยค่าศูนย์ แต่ถ้าหากข้อมูลมีมากกว่าศูนย์ ReLU จะไม่มีการเปลี่ยนแปลงค่าของข้อมูล

3.2.2.2 การเข้ารหัสข้อมูลเชิงเวลา (Temporal encode) ประกอบด้วย Bi-GRU จำนวน 2 ชั้น Attention และ Flatten จำนวน 1 ชั้น แสดงดังภาพที่ 3-7




ภาพที่ 3-7 แสดงโครงสร้างการเข้ารหัสข้อมูลเชิงเวลา

3.2.2.2.1 ชั้น Bi-GRU เป็นชั้นที่รับข้อมูลมาจากชั้น Global Average Pooling (GAP) ซึ่งในชั้นนี้ประกอบด้วย Bi-GRU จำนวน 2 ชั้น ในแต่ละชั้นกำหนดค่า Units เป็น 512 กำหนดค่า Return Sequences เป็น True เพื่อให้ GRU คำนวณค่าข้อมูลเอาต์พุตทั้งหมดจากทุกช่วงเวลา (Time step) ซึ่งทำให้สามารถนำข้อมูลเอาต์พุตจากทุกช่วงเวลาไปใช้ในการทำนายให้มีประสิทธิภาพ

มากยิ่งขึ้น รวมถึงมีการกำหนดค่า Dropout เป็น 0.2 เพื่อสุมปิด Node ของ GRU ร้อยละ 20 ในการป้องกันการ Overfitting อีกทั้ง Bi-GRU ที่สามารถเรียนรู้ข้อมูลได้ทั้งจากซ้ายไปขวา และจากขวาไปซ้ายได้พร้อมกัน ทำให้สามารถเรียนรู้ความสัมพันธ์ข้อมูลลำดับเวลาในระยะยาวได้ดี

3.2.2.2.2 ชั้น Spatial Attention เป็นชั้นที่รับข้อมูลมาจากชั้น Bi-GRU ซึ่งในชั้นนี้เป็นชั้นที่ช่วยให้แบบจำลองสามารถเลือกหรือมุ่งความสนใจไปที่คุณลักษณะหรือข้อมูลที่มีความสำคัญมากที่สุดจากข้อมูลทั้งหมด โดยการกำหนดค่าน้ำหนักให้กับข้อมูลต่าง ๆ ตามความสำคัญเพื่อใช้ในการทำนายผลลัพธ์ของแบบจำลอง (แสดงดังภาพที่ 3-8) ประกอบด้วย 2 ขั้นตอน ดังนี้



ภาพที่ 3-8 แสดงการดำเนินการของ Spatial Attention

ก) การคำนวณค่าน้ำหนักความสนใจ (Attention Weights) โดยนำข้อมูลจากชั้น Bi-GRU เป็นข้อมูลอินพุต โดยใช้ชั้น Dense ที่ใช้ฟังก์ชัน tanh เพื่อสร้างคะแนนความสำคัญของอินพุตลำดับของเวลา ซึ่งเรียกว่า Attention Score จากนั้นนำ Attention Score ที่ได้เข้าฟังก์ชัน Softmax เพื่อให้ Attention Scores เป็นการแจกแจงความน่าจะเป็นปกติที่เกี่ยวข้องกับแต่ละเวลา แสดงสมการคำนวณ Attention Weights ดังสมการที่ 3-3

$$A = \text{softmax}(W_a \cdot \tanh(W_i \cdot X + b)) \dots\dots\dots (3-3)$$

โดยที่

A	คือ	Attention Scores
X	คือ	ข้อมูลอินพุต
W_a, W_i	คือ	ค่าเมทริกซ์น้ำหนัก
$\tanh$	คือ	ฟังก์ชันกระตุ้น
b	คือ	ค่า Bias

ข) การคำนวณเวกเตอร์บริบท (Context Vector) ในขั้นตอนนี้เป็นการนำ Attention Weights ไปดำเนินการคูณเชิงองค์ประกอบ (Hadamard product) กับข้อมูลอินพุต เพื่อคำนวณหาความสำคัญของข้อมูล และทำการรวมผลลัพธ์เพื่อสร้าง Context Vector ที่นำเสนอ

ข้อมูลโดยสรุปจากช่วงเวลาต่าง ๆ โดยให้ความสำคัญกับข้อมูลที่มีความเกี่ยวข้องมากที่สุด ซึ่งแสดงการคำนวณดังสมการที่ 3-4


$$C = \sum_{t=1}^T (A_t \odot X_t) \dots\dots\dots (3-4)$$

โดยที่

C	คือ	เวกเตอร์บริบท (Context Vector)
A_t	คือ	ค่าน้ำหนักความสนใจ (Attention Weights) ของตำแหน่งที่ t
X_t	คือ	ข้อมูลอินพุต ของตำแหน่งที่ t
Σ	คือ	ผลรวมของบริบทในแต่ละช่วงเวลา

3.2.2.2.3 ชั้น Flatten เป็นชั้นที่รับข้อมูลมาจากชั้น Attention เป็นชั้นที่ลดจำนวนมิติข้อมูลให้เหลือเป็นข้อมูลเวกเตอร์หนึ่งมิติ

3.2.2.3 ชั้นแยกประเภท (Classification layer) ประกอบด้วยชั้น Dropout และ Fully Connected จำนวน 1 ชั้น แสดงดังภาพที่ 3-9



ภาพที่ 3-9 แสดงโครงสร้างชั้นแยกประเภท

3.2.2.3.1 ชั้น Dropout เป็นชั้นที่รับข้อมูลมาจากชั้น Flatten ซึ่งในชั้นนี้ประกอบด้วย Hidden layer จำนวน 1 ชั้น และ 1,024 Node โดยมีการกำหนดค่า Dropout เป็น 0.5 หรือเป็นการดำเนินการสุ่มปิด Node คิดเป็นร้อยละ 50 (หรือ 512 Node) เพื่อใช้ในการป้องกันการเกิด Overfitting ของแบบจำลอง

3.2.2.3.2 ชั้น Fully Connected (Dense layer) เป็นชั้นที่รับข้อมูลมาจากชั้น Dropout ซึ่งในชั้นนี้ประกอบด้วย Hidden layer จำนวน 1 ชั้น และ 500 Node และทำให้ผลลัพธ์เป็นการแจกแจงความน่าจะเป็นโดยใช้ฟังก์ชัน Softmax

3.3 การฝึกฝนแบบจำลอง (Training model)

3.3.1 ฟังก์ชันการสูญเสีย (Loss function) เนื่องจากงานวิจัยนี้เป็นปัญหาการจำแนกประเภทแบบหลายคลาส (Multi classification) จึงได้เลือกใช้ฟังก์ชันการสูญเสียแบบเอนโทรปี (Cross-entropy loss function) เนื่องจากมีความสามารถในการวัดความแตกต่างระหว่างความน่าจะเป็นที่

แบบจำลองทำนายและค่าข้อมูลจริง ซึ่งสามารถปรับปรุงแบบจำลองให้มีประสิทธิภาพสูงขึ้นได้ แสดงการคำนวณ Cross-entropy loss function ดังสมการที่ 3-5

$$CE\ Loss = - \sum_{i=1}^C y_i \cdot \log(p_i) \dots\dots\dots (3-5)$$

โดยที่

C คือ จำนวนคลาส


y_i คือ ค่าจริง ของคลาสที่ i โดยการใช้การเข้ารหัสแบบ one-hot (จะมีค่าเป็น 1 สำหรับคลาสที่เป็นจริง และ 0 สำหรับคลาสอื่น ๆ)

p_i คือ ความน่าจะเป็นที่แบบจำลองทำนายสำหรับคลาสที่ i

3.3.2 การแพร่กระจายย้อนกลับ (Backpropagation) เป็นกระบวนการที่ใช้ในการฝึกฝนเครือข่ายประสาทเทียม ซึ่งทำหน้าที่ในการคำนวณการปรับค่าน้ำหนัก (Weights) ของแบบจำลอง โดยการใช้ข้อมูลที่ได้จากการคำนวณค่าการสูญเสียระหว่างข้อมูลที่แบบจำลองทำนายกับค่าจริง


ในการวิจัยนี้ได้ใช้ Adam (Adaptive Moment Estimation) ซึ่งเป็นอัลกอริทึมที่รวมคุณสมบัติของ AdaGrad และ RMSProp โดยใช้กระบวนการปรับปรุงที่ปรับตัวเองได้ (Adaptive) และการคำนวณโมเมนตัม (Momentum) ของ Gradients ทำให้ Adam สามารถปรับค่าเรียนรู้ (Learning rate) สำหรับแต่ละพารามิเตอร์ในแต่ละขั้นตอนโดยอัตโนมัติ ซึ่งในงานวิจัยนี้ได้กำหนดค่าเริ่มต้นของ Learning rate เป็น 0.0001

4.1.2 ชุดข้อมูลแบบสุ่ม (Random Dataset) จำนวน 100 คำ จำนวนวิดีโอทั้งสิ้น 107,523 ไฟล์ (Train: 97,523 ไฟล์ Validation & Test: 5,000 ไฟล์) โดยมีจุดประสงค์เพื่อทดสอบแนวคิดในขั้นตอนการพัฒนาแบบจำลอง ซึ่งสามารถศึกษารายละเอียดเพิ่มเติมในภาคผนวก ก และจำนวนไฟล์แต่ละคำดังภาพที่ 4-2



ภาพที่ 4-2 แสดงจำนวนไฟล์แต่ละคำของชุดข้อมูลแบบสุ่ม

4.1.3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ จำนวน วิดีโอทั้งสิ้น 538,766 ไฟล์ (Train: 488,766 ไฟล์ Validation & Test: 25,000 ไฟล์) โดยมีจุดประสงค์เพื่อทดสอบแบบจำลองในขั้นสุดท้าย ซึ่งสามารถศึกษารายละเอียดเพิ่มเติมในภาคผนวก ก และแสดงจำนวนไฟล์แต่ละคำดังภาพที่ 4-3



ภาพที่ 4-3 แสดงจำนวนไฟล์แต่ละคำของชุดข้อมูลทั้งหมด

4.2 แบบจำลองเปรียบเทียบ (Baseline model) ซึ่งสามารถแบ่งออกเป็น 4 แบบจำลอง ดังนี้

4.2.1 แบบจำลอง CNN

แบบจำลอง CNN (Convolutional Neural Network) เป็นเครือข่ายประสาทเทียมที่ออกแบบมาเฉพาะสำหรับการประมวลผลข้อมูลที่มีลักษณะเป็นตาราง เช่น ภาพหรือวิดีโอ โดยมีหลักการทำงานหลักคือการใช้ฟิลเตอร์ (Filter) หรือเคอร์เนล (Kernel) ในการดำเนินการ Convolution เพื่อสกัดคุณลักษณะเฉพาะ (Features) เช่น ขอบ, รูปทรง, หรือพื้นผิวในข้อมูลภาพ ซึ่งจะช่วยลดมิติของข้อมูลและเพิ่มประสิทธิภาพในการจำแนกประเภท ซึ่งใช้โครงสร้าง 3D CNN (Chung & Zisserman, 2016) รายละเอียดดังภาคผนวก ก

4.2.2 แบบจำลอง CNN ร่วมกับ RNN

แบบจำลอง CNN ร่วมกับ RNN เป็นการรวมกันของ Convolutional Neural Networks (CNN) และ Recurrent Neural Networks (RNN) เพื่อจัดการกับข้อมูลที่มีลักษณะทั้งในรูปแบบภาพและลำดับเวลา โดย CNN จะใช้ในการประมวลผลและเรียนรู้ลักษณะเฉพาะจากภาพหรือข้อมูลสองมิติ เช่น เฟรมวิดีโอ ในขณะที่ RNN จะทำหน้าที่เรียนรู้ลักษณะเฉพาะของข้อมูลที่มีลำดับเวลา ซึ่งใช้โครงสร้าง 2D CNN ร่วมกับ GRU หรือ LSTM หรือ Bi-GRU (Petridis et al., 2018; Xiao et al., 2020) รายละเอียดดังภาคผนวก ก

4.2.3 แบบจำลอง CNN ร่วมกับ RNN และ Attention

แบบจำลอง CNN ร่วมกับ RNN และ Attention เป็นแนวทางในการประมวลผลข้อมูลที่ต้องการทั้งการวิเคราะห์ภาพและการจัดการลำดับเวลาอย่างมีประสิทธิภาพ โดย CNN ทำหน้าที่ในการเรียนรู้คุณลักษณะเฉพาะจากข้อมูลภาพ เช่น ภาพหรือเฟรมวิดีโอ ในขณะที่ RNN ใช้สำหรับเรียนรู้ลักษณะเฉพาะของข้อมูลลำดับ เช่น การขยับของริมฝีปากที่เปลี่ยนแปลงตามเวลา และนำ Attention มาช่วยให้แบบจำลองสามารถมุ่งความสนใจไปยังส่วนที่สำคัญของข้อมูลในแต่ละช่วงเวลาได้อย่างมีประสิทธิภาพ ซึ่งสามารถรวมข้อมูลที่เกี่ยวข้องจากลำดับก่อนหน้าได้อย่างเหมาะสม ทำให้แบบจำลองสามารถสร้างการตัดสินใจได้อย่างมีประสิทธิภาพมากขึ้นในการจัดการกับข้อมูลที่ซับซ้อน ซึ่งใช้โครงสร้าง 2D CNN ร่วมกับ GRU หรือ Bi-GRU และ Attention (Chung et al., 2016) และ 3D + 2D CNN (ResNet) ร่วมกับ GRU หรือ Bi-GRU และ Attention (Cheng et al., 2019; Feng et al., 2020; Luo et al., 2020; Stafylakis & Tzimiropoulos, 2017; Zhao et al., 2020) รายละเอียดดังภาคผนวก ก

4.2.4 แบบจำลอง CNN ร่วมกับ Transformer Encoder (Vision Transformers)

แบบจำลอง CNN ร่วมกับ Transformer Encoder หรือที่เรียกว่า Vision Transformers (ViT) เป็นแนวทางที่ผสมผสานแนวคิดของการประมวลผลภาพแบบ Convolutional กับความสามารถในการจัดการลำดับเชิงซ้อนของ Transformer ในการวิเคราะห์ภาพ โดยใน Vision Transformers ข้อมูลภาพจะถูกแปลงเป็นชุดของพิกเซลหรือ Patch ซึ่งแต่ละ Patch จะถูกแทนที่ด้วยเวกเตอร์คุณลักษณะเฉพาะ (Feature vectors) ก่อนที่จะถูกป้อนข้อมูลเข้าสู่ Transformer encoder ที่ใช้กลไก Attention ในการตรวจจับความสัมพันธ์ระหว่าง Patch ช่วยให้แบบจำลองสามารถเรียนรู้ลักษณะความสัมพันธ์ที่ซับซ้อนได้ทั้งภายในภาพและระหว่าง Patch การใช้ Transformer ในการประมวลผลภาพช่วยเพิ่มประสิทธิภาพในการเข้าใจลักษณะและโครงสร้างของข้อมูลภาพได้ดีขึ้น โดยเฉพาะกับงานที่มีความซับซ้อนสูง ซึ่งใช้โครงสร้าง 2D CNN หรือ 3D + 2D CNN ร่วมกับ Transformer (Wang et al., 2022; Wiriyathamabhum, 2020) รายละเอียดดังภาคผนวก ก

4.3 การพัฒนาแบบจำลองขั้นสุดท้าย

แบบจำลองการเรียนรู้เชิงลึกแบบผสมผสาน (Spatial-temporal) ประกอบด้วยชั้นต่าง ๆ ได้แก่ 3D CNN, 2D CNN, Bi-GRU, Attention, Batch normalization, ReLU, GAP, Flatten, Dense และ Dropout ซึ่งมีองค์ประกอบของแบบจำลองแสดงดังตารางที่ 4-1

ตารางที่ 4-1 แสดงองค์ประกอบของแบบจำลองขั้นสุดท้าย

Groups	Layers	Parameters setting	Inputs	Outputs
Spatial encode	Input		29,112,112,3	29,112,112,3
	Conv3D	filters=64, kernel_size=(3,5,5), strides=(1,2,2)	29,112,112,3	27,54,54,64
	BatchNormalization		27,54,54,64	27,54,54,64
	ReLU		27,54,54,64	27,54,54,64
	Conv2D	filters=64, kernel_size=(3,3), strides=(1,1)	27,54,54,64	27,52,52,64
	BatchNormalization		27,52,52,64	27,52,52,64
	ReLU		27,52,52,64	27,52,52,64
	Conv2D	filters=128, kernel_size=(3,3), strides=(2,2)	27,52,52,64	27,25,25,128
	BatchNormalization		27,25,25,128	27,25,25,128
	ReLU		27,25,25,128	27,25,25,128
	Conv2D	filters=256, kernel_size=(3,3), strides=(2,2)	27,25,25,128	27,12,12,256

ตารางที่ 4-1 แสดงองค์ประกอบของแบบจำลองขั้นสุดท้าย (ต่อ)

Groups	Layers	Parameters setting	Inputs	Outputs
Spatial encode	BatchNormalization		27,12,12,256	27,12,12,256
	ReLU		27,12,12,256	27,12,12,256
	Conv2D	filters=512, kernel_size=(3,3), strides=(2,2)	27,12,12,256	27,5,5,512
	BatchNormalization		27,5,5,512	27,5,5,512
	ReLU		27,5,5,512	27,5,5,512
	TimeDistributed	GlobalAveragePooling2D	27,5,5,512	27,512
Temporal encode	Bidirectional	GRU: units=512, return_sequences=True, dropout=0.2	27,512	27,1024
	Bidirectional	GRU: units=512, return_sequences=True, dropout=0.2	27,1024	27,1024
	Dense	units=1024, activation='tanh'	27,1024	27,1024
	Softmax	axis=1	27,1024	27,1024
	tf.math.multiply		27,1024	27,1024
	tf.math.reduce_sum	axis=1	27,1024	1024
	Flatten		1024	1024
Classification	Dropout	rate=0.5	1024	1024
	Dense	units=500, activation='softmax'	1024	500


ผู้วิจัยได้ทำการพัฒนาขั้นตอนวิธีการจดจำคำพูดด้วยภาพ ด้วยภาษา Python ซึ่งเหมาะกับการวิเคราะห์ข้อมูลและการพัฒนาแบบจำลองปัญญาประดิษฐ์ ร่วมกับ TensorFlow และ Keras เพื่อสร้างและฝึกฝนแบบจำลองการเรียนรู้เชิงลึก (Deep Learning) ที่นำเสนอ โดยใช้เครื่องมือ Jupyter Notebook ในสภาพแวดล้อมของ Anaconda Navigator บนเครื่องคอมพิวเตอร์ที่ติดตั้งระบบปฏิบัติการ Windows 10 แสดงรายละเอียดคุณสมบัติของเครื่องคอมพิวเตอร์ที่ผู้วิจัยใช้ในการทำการวิจัย แสดงดังตารางที่ 4-2

ตารางที่ 4-2 แสดงรายละเอียดคุณสมบัติของเครื่องคอมพิวเตอร์

No.	Groups	List	Feature / Version
1.	Hardware	CPU	AMD Ryzen 9 5950X, 3.4 GHz
		Memory	RAM DDR-4 64 GB
		Storage	SSD 2 TB
		GPU	NVIDIA RTX 3090, 1.755 GHz, VRAM 24 GB
2.	Software	Anaconda Navigator	2.6.4
		Jupyter Notebook	7.0.8

ตารางที่ 4-2 แสดงรายละเอียดคุณสมบัติของเครื่องคอมพิวเตอร์ (ต่อ)

No.	Groups	List	Feature / Version
3.	Library	cuda toolkit	11.2.2
		cudnn	8.1.0.77
		python	3.10.13
		keras	2.10.0
		tensorflow	2.10.1
		opencv-python	4.11.0.86
		mediapipe	0.10.21
		vit-keras	0.1.2



ภาพที่ 4-4 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองที่นำเสนอ

4.4 การทดสอบประสิทธิภาพ

4.4.1 Confusion Matrix เป็นเครื่องมือที่ใช้ในการประเมินประสิทธิภาพของแบบจำลองในการจำแนกประเภท (Classification model) โดยแสดงผลการทำนายของแบบจำลองเปรียบเทียบกับผลลัพธ์จริงแสดงในรูปแบบของตารางเมทริกซ์ ซึ่งช่วยให้สามารถเข้าใจได้ว่าแบบจำลองสามารถทำนายได้ถูกต้องหรือผิดในแต่ละหมวดหมู่เป็นอย่างไร แสดงดังตารางที่ 4-3

ตารางที่ 4-3 แสดง Confusion Matrix แบบ predict-actual

		Actually	
		Positive (1)	Negative (0)
Predicted	Positive (1)	True Positive (TP)	False Positive (FP)
	Negative (0)	False Negative (FN)	True Negative (TN)

โดยที่:

True Positive (TP) คือ เหตุการณ์ที่ทำนายว่า “จริง” แล้วได้ผลลัพธ์ว่า “จริง”

True Negative (TN) คือ เหตุการณ์ที่ทำนายว่า “ไม่จริง” แล้วได้ผลลัพธ์ว่า “ไม่จริง”

False Positive (FP) คือ เหตุการณ์ที่ทำนายว่า “จริง” แล้วได้ผลลัพธ์ว่า “ไม่จริง”

False Negative (FN) คือ เหตุการณ์ที่ทำนายว่า “ไม่จริง” แล้วได้ผลลัพธ์ว่า “จริง”

4.4.1.1 Accuracy คือ ค่าความถูกต้องในการทำนายกลุ่มเป้าหมายโดยพิจารณาเฉพาะที่ทำนายถูกต้องทั้งหมด ซึ่งสามารถคำนวณได้ดังสมการที่ 4-1

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)} \dots\dots\dots (4 - 1)$$

4.4.1.2 Precision คือ ค่าความแม่นยำในการทำนายในกลุ่มเป้าหมายโดยพิจารณาเฉพาะที่แบบจำลองทำนายเป็นจริงเท่านั้น (Predict Positive) ซึ่งสามารถคำนวณได้ดังสมการที่ 4-2

$$Precision = \frac{TP}{(TP + FP)} \dots\dots\dots (4 - 2)$$

4.4.1.3 Recall คือ ค่าความแม่นยำในการทำนายในกลุ่มเป้าหมายโดยพิจารณาเฉพาะที่เหตุการณ์ที่เป็นจริงเท่านั้น (Actual Positive) ซึ่งสามารถคำนวณได้ดังสมการที่ 4-3

$$Recall = \frac{TP}{(TP + FN)} \dots\dots\dots (4 - 3)$$

4.4.1.4 F1-score คือ ค่าที่วัดความสามารถของแบบจำลองจากผลเฉลี่ยของ precision และ recall ซึ่งสามารถคำนวณได้ดังสมการที่ 4-4

$$F1 - score = \frac{2 \cdot (Precision \cdot Recall)}{2 \cdot (Precision + Recall)} \dots\dots\dots (4 - 4)$$

4.4.2 FLOPS (Floating Point Operations Per Second) คือ หน่วยวัดประสิทธิภาพในการคำนวณทางคณิตศาสตร์ที่ใช้ตัวเลขทศนิยม (Floating-point numbers) โดยเฉพาะในงานที่ต้องการการคำนวณที่ซับซ้อนของแบบจำลองการเรียนรู้เชิงลึก โดยมีสมการสำหรับการคำนวณ FLOPS ของแต่ละชั้นของแบบจำลองที่นำเสนอ สามารถคำนวณ FLOPS ได้ดังสมการต่อไปนี้

4.4.2.1 การคำนวณ FLOPS ของชั้น 3D CNN ดังสมการที่ 4-5

$$FLOPS_{C3D} = 2 \times (C_{in} \times K_t \times K_h \times K_w \times C_{out} \times O_t \times O_h \times O_w) \cdots (4-5)$$

4.4.2.2 การคำนวณ FLOPS ของชั้น 2D CNN ดังสมการที่ 4-6

$$FLOPS_{C2D} = 2 \times (C_{in} \times K_h \times K_w \times C_{out} \times O_h \times O_w) \cdots (4-6)$$

4.4.2.3 การคำนวณ FLOPS ของชั้น Batch Normalization ดังสมการที่ 4-7

$$FLOPS_{BN} = 4 \times (O_h \times O_w \times C_{out}) \cdots (4-7)$$

4.4.2.4 การคำนวณ FLOPS ของชั้น ReLU ดังสมการที่ 4-8

$$FLOPS_{ReLU} = O_h \times O_w \times C_{out} \cdots (4-8)$$

4.4.2.5 การคำนวณ FLOPS ของชั้น Global Average Pooling ดังสมการที่ 4-9

$$FLOPS_{GAP} = O_h \times O_w \times C_{out} \cdots (4-9)$$

4.4.2.6 การคำนวณ FLOPS ของชั้น Bi-GRU ดังสมการที่ 4-10

$$FLOPS_{BiGRU} = 2 \times (6 \times H \times (H + I) \times T) \cdots (4-10)$$

4.4.2.7 การคำนวณ FLOPS ของชั้น Fully Connected หรือ Dense ดังสมการที่ 4-11

$$FLOPS_{FC} = 2 \times I \times O \cdots (4-11)$$

โดยที่:

- C_{in} คือ จำนวนช่องสัญญาณของอินพุต (Input Channels)
- C_{out} คือ จำนวนช่องสัญญาณของเอาต์พุต (Output Channels)
- K_t, K_h, K_w คือ ขนาดของแกนกรอง (Kernel Size) ใน 3 มิติ (เวลา, ความสูง, ความกว้าง)
- O_t, O_h, O_w คือ ขนาดของเอาต์พุต (เวลา, ความสูง, ความกว้าง)
- H คือ จำนวนยูนิตใน GRU
- I คือ จำนวนฟีเจอร์ของอินพุต (Input Features)
- T คือ จำนวน Time steps (จำนวนเฟรม)
- คูณ 2 เนื่องจากการคำนวณแต่ละครั้งมีทั้งการคูณและการบวก
- คูณ 4 เนื่องจากการคำนวณของ Batch Normalization ประกอบด้วย 4 ขั้นตอน: หาค่าเฉลี่ย, คำนวณความแปรปรวน, นอร์มัลไลซ์ค่า, และสเกล
- คูณ 6 เพราะใน GRU มีการคำนวณ 6 ชุดน้ำหนัก: Update Gate, Reset Gate, และ Hidden State (แต่ละตัวมีทั้ง W และ U)

4.5 ผลการทดลอง

สามารถแบ่งการทดลองออกเป็น 2 กลุ่มการทดลอง ประกอบด้วย 1) การทดลองตามชุดข้อมูล และ 2) การทดลองแบบปรับพารามิเตอร์ ซึ่งมีรายละเอียดดังนี้


4.5.1 การทดลองตามชุดข้อมูล

สามารถแบ่งการทดลองออกเป็น 3 การทดลองตามชุดข้อมูล ประกอบด้วย 1) การทดลองกับชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง 2) การทดลองกับชุดข้อมูลแบบสุ่ม และ 3) การทดลองกับชุดข้อมูลทั้งหมด

4.5.1.1 การทดลองกับชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง (Homophones Dataset) ซึ่งผลการทดลองเปรียบเทียบระหว่างแบบจำลองที่นำเสนอ กับ Baseline โดยใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score, Accuracy และ FLOPS แสดงรายละเอียดดังตารางที่ 4-4 และภาพที่ 4-5

ตารางที่ 4-4 แสดงผลการทดลองกับชุดข้อมูล Homophones

No.	Spatial encode	Temporal encode	RNN (units)	Attention (units)	Precision	Recall	F1-score	Accuracy	Flops (G, 1×10^9)	Total Params (M, 1×10^6)
1	3D CNN (3 layer)		-	-	0.53	0.50	0.50	0.50	16.47	1.21
2	3D + 2D CNN (4 layer)	GRU (2 Layer)	512	-	0.69	0.67	0.67	0.67	7.02	5.83
3	VGG16	Bi-GRU (2 Layer) + Attention	512	1024	0.51	0.50	0.50	0.50	222.70	23.72
4	3D ResNet-18	Bi-GRU (2 Layer) + Attention	512	1024	0.72	0.72	0.71	0.72	77.75	26.48
5	3D + 2D CNN (4 layer)	ViT-B16	-	-	0.33	0.30	0.28	0.30	48.53	88.00
6	3D + 2D CNN (4 layer)	Bi-GRU (2 Layer) + Attention	512	1024	0.71	0.69	0.69	0.69	7.05	10.61



ภาพที่ 4-5 แสดงกราฟ ROC สำหรับแบบจำลองที่นำเสนอกับแบบจำลอง Baseline บนชุดข้อมูล Homophones


การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-4 แบบจำลอง 3D + 2D CNN + RNN + Attention (ลำดับที่ 4 และ 6) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น แต่อย่างไรก็ตาม แบบจำลองที่ใช้โครงสร้าง Transformers (ViT-B16) ไม่เหมาะกับงานวิจัยนี้ เนื่องจากมีประสิทธิภาพต่ำประกอบกับพารามิเตอร์จำนวนมาก ทั้งนี้ แบบจำลอง 3D ResNet-18 + Bi-GRU + Attention (ลำดับที่ 4) มีประสิทธิภาพสูงสุด แต่ต้องแลกมาด้วยค่า FLOPS และจำนวนพารามิเตอร์ที่สูง ซึ่งในขณะที่แบบจำลองที่นำเสนอ (ลำดับที่ 6) มีค่า Accuracy ต่ำกว่าอยู่ 0.03 (0.72 - 0.69) แต่ใช้ทรัพยากรในการประมวลผลน้อยกว่ามาก โดยสามารถลดค่า FLOPS ลง 90.93% และลดจำนวนพารามิเตอร์ลง 59.93% ซึ่งจากการทดลองแสดงให้เห็นว่า โครงสร้างแบบจำลองที่ซับซ้อนอย่างเช่น ViT-B16 และความต้องการในการประมวลผลที่สูงอย่างเช่น VGG16 ไม่ได้ให้ผลลัพธ์ที่ดีเสมอไป แต่กับโครงสร้างที่ซับซ้อนน้อยกว่าเช่น แบบจำลองที่นำเสนอ (ลำดับที่ 6) ที่ใช้โครงสร้าง 2D CNN เพียงแค่ 4 ชั้น แต่กลับให้ผลลัพธ์ที่แตกต่างกันเล็กน้อยเมื่อเปรียบเทียบกับแบบจำลองที่ใช้โครงสร้าง ResNet-18 (ลำดับที่ 4) ที่ประกอบไปด้วย 2D CNN จำนวนถึง 16 ชั้น ก็ตาม

4.5.1.2 การทดลองกับชุดข้อมูลแบบสุ่ม (Random Dataset) ซึ่งผลการทดลองเปรียบเทียบระหว่างแบบจำลองที่นำเสนอ กับ Baseline โดยใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score, Accuracy และ FLOPS แสดงรายละเอียดดังตารางที่ 4-5 และภาพที่ 4-6

ตารางที่ 4-5 แสดงผลการทดลองกับชุดข้อมูล Random

No.	Spatial encode	Temporal encode	RNN (units)	Attention (units)	Precision	Recall	F1-score	Accuracy	Flops (G, 1×10^9)	Total Params (M, 1×10^6)
1	3D CNN (3 layer)		-	-	0.58	0.57	0.57	0.57	7.92	1.22
2	3D + 2D CNN (4 layer)	Bi-GRU (2 Layer)	512	-	0.81	0.79	0.79	0.79	7.02	12.25
3	2D CNN (3 layer)	GRU (2 Layer) + Attention	512	1	0.73	0.72	0.72	0.72	7.28	3.32
4	3D ResNet-18	Bi-GRU (2 Layer) + Attention	512	1024	0.85	0.84	0.84	0.84	77.75	26.50
5	3D CNN (1 layer)	ViT-B16 (Transformers)	-	-	0.41	0.36	0.35	0.36	29.96	86.42
6	3D + 2D CNN (4 layer)	Bi-GRU (2 Layer) + Attention	512	1024	0.84	0.83	0.83	0.83	7.05	10.63



ภาพที่ 4-6 แสดงกราฟ ROC สำหรับแบบจำลองที่นำเสนอเทียบกับแบบจำลอง Baseline บนชุดข้อมูล Random การวิเคราะห์และสรุปผลการทดลอง


จากตารางที่ 4-5 แบบจำลอง 3D + 2D CNN + RNN + Attention (ลำดับที่ 4 และ 6) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น โดยเฉพาะเมื่อใช้ Attention ร่วมกับ RNN ซึ่งช่วยเพิ่มประสิทธิภาพของแบบจำลอง แต่อย่างไรก็ตาม แบบจำลองที่ใช้โครงสร้าง Transformers (ViT-B16) ไม่เหมาะกับงานวิจัยนี้ เนื่องจากมีประสิทธิภาพต่ำและใช้พารามิเตอร์จำนวนมาก ทั้งนี้ แบบจำลอง

3D ResNet-18 + Bi-GRU + Attention (ลำดับที่ 4) มีประสิทธิภาพสูงสุด แต่ต้องแลกมาด้วยค่า FLOPS และจำนวนพารามิเตอร์ที่สูง ซึ่งในขณะที่แบบจำลองที่นำเสนอ (ลำดับที่ 6) มีค่า Accuracy ต่ำกว่าอยู่ 0.01 (0.84 - 0.83) แต่ใช้ทรัพยากรในการประมวลผลน้อยกว่ามาก โดยสามารถลดค่า FLOPS ลง 90.93% และลดจำนวนพารามิเตอร์ลง 59.89% ซึ่งจากการทดลองแสดงให้เห็นว่า โครงสร้างแบบจำลองที่ซับซ้อนอย่างเช่น ViT-B16 ไม่ได้ให้ผลลัพธ์ที่ดีเสมอไป แต่กับโครงสร้างที่ซับซ้อนน้อยกว่าเช่น แบบจำลองที่นำเสนอ (ลำดับที่ 6) ที่ใช้โครงสร้าง 2D CNN เพียงแค่ 4 ชั้น แต่กลับให้ผลลัพธ์ที่ใกล้เคียงกับแบบจำลองที่ใช้โครงสร้าง ResNet-18 (ลำดับที่ 4) ที่ประกอบไปด้วย 2D CNN จำนวนถึง 16 ชั้น ก็ตาม

4.5.1.3 การทดลองกับชุดข้อมูลทั้งหมด (All Dataset) ซึ่งผลการทดลองเปรียบเทียบระหว่างแบบจำลองที่นำเสนอ กับ Baseline โดยใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score, Accuracy และ FLOPS แสดงรายละเอียดดังตารางที่ 4-6 และภาพที่ 4-7

ตารางที่ 4-6 แสดงผลการทดลองกับชุดข้อมูล All

No.	Spatial encode	Temporal encode	RNN (units)	Attention (units)	Precision	Recall	F1-score	Accuracy	Flops (G, 1×10^9)	Total Params (M, 1×10^6)
1	3D CNN (3 layer)		-	-	0.50	0.49	0.48	0.49	16.47	1.34
2	3D + 2D CNN (4 layer)	Bi-GRU (2 Layer)	512	-	0.71	0.69	0.69	0.69	7.03	23.30
3	2D CNN (3 layer)	GRU (2 Layer) + Attention	512	1	0.67	0.67	0.67	0.67	14.08	3.44
4	3D ResNet-18	Bi-GRU (2 Layer) + Attention	512	1024	0.75	0.74	0.74	0.74	77.75	26.91
5	3D + 2D CNN (4 layer)	ViT-B16	-	-	0.36	0.32	0.30	0.32	48.53	88.33
6	3D + 2D CNN (4 layer)	Bi-GRU (2 Layer) + Attention	512	1024	0.75	0.75	0.74	0.75	7.05	11.04



ภาพที่ 4-7 แสดงกราฟ ROC สำหรับแบบจำลองที่นำเสนอกับแบบจำลอง Baseline บนชุดข้อมูล All การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-6 แบบจำลอง 3D + 2D CNN + RNN + Attention (ลำดับที่ 4 และ 6) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น โดยเฉพาะเมื่อใช้ Attention ร่วมกับ RNN ซึ่งช่วยเพิ่มประสิทธิภาพของแบบจำลอง แต่อย่างไรก็ตาม แบบจำลองที่ใช้โครงสร้าง Transformers (ViT-B16) ไม่เหมาะกับงานวิจัยนี้ เนื่องจากมีประสิทธิภาพต่ำและใช้พารามิเตอร์จำนวนมาก ทั้งนี้ แบบจำลองที่นำเสนอ 3D + 2D CNN + Bi-GRU + Attention (ลำดับที่ 6) มีประสิทธิภาพสูงสุด ซึ่งเมื่อเปรียบเทียบกับ 3D ResNet-18 + Bi-GRU + Attention (ลำดับที่ 4) ที่มีประสิทธิภาพใกล้เคียงกัน พบว่า สามารถลดค่า FLOPS ลง 90.93% และลดจำนวนพารามิเตอร์ลง 58.97% ซึ่งจากการทดลองแสดงให้เห็นว่า โครงสร้างแบบจำลองที่ซับซ้อนอย่างเช่น ViT-B16 และ ResNet-18 ไม่ได้ให้ผลลัพธ์ที่ดีเสมอไป แต่กับโครงสร้างที่ซับซ้อนน้อยกว่าเช่น แบบจำลองที่นำเสนอ (ลำดับที่ 6) ก็ให้ประสิทธิภาพที่เหนือกว่าอย่างมีนัยสำคัญ

4.5.2 การทดลองแบบปรับพารามิเตอร์ (Ablation study)

สามารถแบ่งออกเป็น 6 การทดลอง ประกอบด้วย การทดลองเปรียบเทียบระหว่างชุดข้อมูลสีและขาวดำ, การทดลองเปรียบเทียบจำนวน Unit ของ RNN, การทดลองเปรียบเทียบระหว่าง LSTM, GRU และ Bi-GRU, การทดลองเปรียบเทียบจำนวน Layer ของ RNN, การทดลองเปรียบเทียบจำนวน Unit ของ Attention และ การทดลองเปรียบเทียบแบบจำลองขั้นสุดท้าย

4.5.2.1 ผลการทดลองเปรียบเทียบระหว่างชุดข้อมูลสีและขาวดำ บนชุดข้อมูลแบบสุ่ม (Random Dataset) และใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score และ Accuracy รายละเอียดดังตารางที่ 4-7

ตารางที่ 4-7 แสดงผลการทดลองเปรียบเทียบระหว่างชุดข้อมูลสีและขาวดำ

No.	Encode		RNN Units	Type	Precision	Recall	F1-score	Accuracy
	Spatial	Temporal						
1	3D CNN (3 Layer)		-	Gray	0.57	0.56	0.55	0.56
2			-	RGB	0.58	0.57	0.57	0.57
3	3D CNN (1 Layer)	ViT-B16 (Pretrain)	-	Gray	0.38	0.30	0.29	0.30
4			-	RGB	0.41	0.36	0.35	0.36
5	2D CNN (3 Layer)	GRU (2 Layer)	256	Gray	0.66	0.65	0.65	0.65
6			256	RGB	0.69	0.68	0.68	0.68
7		LSTM (2 Layer)	256	Gray	0.65	0.64	0.64	0.64
8			256	RGB	0.69	0.68	0.68	0.68

การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-7 แบบจำลอง CNN + RNN (ลำดับที่ 5-8) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น แต่อย่างไรก็ตาม แบบจำลองที่ใช้โครงสร้าง Transformers (ViT-B16) ไม่เหมาะสมกับงานวิจัยนี้ เนื่องจากมีประสิทธิภาพต่ำทั้งชุดข้อมูลสี (RGB) และขาวดำ (GRAY) ทั้งนี้ แบบจำลอง 2D CNN + RNN (ลำดับที่ 6 และ 8) มีประสิทธิภาพสูงสุด (Accuracy = 0.68) ซึ่งจากการทดลองแสดงให้เห็นว่า แบบจำลองที่ฝึกฝนและทดสอบจากชุดข้อมูลสี (RGB) ให้ประสิทธิภาพที่เหนือกว่าแบบจำลองที่ฝึกฝนและทดสอบจากชุดข้อมูลขาวดำ (GRAY) ในทุกกรณี

4.5.2.2 ผลการทดลองเปรียบเทียบจำนวน Unit ของ RNN บนชุดข้อมูลแบบสุ่ม (Random Dataset) สีและใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score และ Accuracy รายละเอียดดังตารางที่ 4-8

ตารางที่ 4-8 แสดงผลการทดลองเปรียบเทียบจำนวน Unit ของ RNN

No.	Encode		RNN Units	Attention Units	Precision	Recall	F1-score	Accuracy
	Spatial	Temporal						
1	2D CNN (3 Layer)	GRU (2 Layer)	50	-	0.67	0.66	0.65	0.66
2			100	-	0.64	0.61	0.61	0.61
3			256	-	0.69	0.68	0.68	0.68
4			512	-	0.70	0.69	0.69	0.69
5			1,024	-	0.68	0.67	0.67	0.67

ตารางที่ 4-8 แสดงผลการทดลองเปรียบเทียบจำนวน Unit ของ RNN (ต่อ)

No.	Encode		RNN Units	Attention Units	Precision	Recall	F1-score	Accuracy
	Spatial	Temporal						
6	2D CNN (3 Layer)	GRU (2 Layer) + Attention	512	1	0.73	0.72	0.72	0.72
7	3D ResNet-18	Bi-GRU (2 Layer)	512	1	0.82	0.81	0.81	0.81
8		+ Attention	1,024	1	0.79	0.78	0.78	0.78

การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-8 แบบจำลอง CNN + RNN + Attention (ลำดับที่ 6-8) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น โดยเฉพาะเมื่อใช้ Attention ร่วมกับ RNN ซึ่งช่วยเพิ่มประสิทธิภาพของแบบจำลอง ทั้งนี้ แบบจำลอง 3D ResNet-18 + Bi-GRU + Attention (ลำดับที่ 7) มีประสิทธิภาพสูงสุด (Accuracy = 0.81) ซึ่งจากการทดลองแสดงให้เห็นว่า แบบจำลองที่มีโครงสร้าง Attention ร่วมกับ RNN มีประสิทธิภาพที่เหนือกว่าอย่างมีนัยสำคัญ และหากพิจารณาจำนวน Units ของ RNN พบว่าหากแบบจำลองใดกำหนด Units ของ RNN เท่ากับ 512 จะให้ประสิทธิภาพที่เหนือกว่าแบบจำลองที่มีโครงสร้างเดียวกันในทุกกรณี

4.5.2.3 ผลการทดลองเปรียบเทียบระหว่าง LSTM, GRU และ Bi-GRU บนชุดข้อมูลแบบสุ่ม (Random Dataset) สีและใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score และ Accuracy รายละเอียดดังตารางที่ 4-9

ตารางที่ 4-9 แสดงผลการทดลองเปรียบเทียบระหว่าง LSTM, GRU และ Bi-GRU

No.	Encode		RNN Units	Attention Units	Precision	Recall	F1-score	Accuracy
	Spatial	Temporal						
1	2D CNN (3 Layer)	LSTM (1 Layer) + Attention	512	1	0.70	0.69	0.69	0.69
2		GRU (1 Layer) + Attention	512	1	0.72	0.71	0.71	0.71
3		Bi-GRU (1 Layer) + Attention	512	1	0.68	0.67	0.67	0.67

การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-9 แบบจำลอง 2D CNN + GRU + Attention (ลำดับที่ 2) มีประสิทธิภาพสูงสุด (Accuracy = 0.71) ซึ่งจากการทดลองแสดงให้เห็นว่า แบบจำลองที่มีโครงสร้าง GRU ที่มีโครงสร้างซับซ้อนน้อยกว่า LSTM และ Bi-GRU แต่กลับให้ประสิทธิภาพที่เหนือกว่าอย่างมีนัยสำคัญ

4.5.2.4 ผลการทดลองเปรียบเทียบจำนวน Layer ของ RNN บนชุดข้อมูลแบบสุ่ม (Random Dataset) และชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง (Homophones Dataset) ซึ่งใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score และ Accuracy รายละเอียดดังตารางที่ 4-10

ตารางที่ 4-10 แสดงผลการทดลองเปรียบเทียบจำนวน Layer ของ RNN

No.	Encode		RNN Units	Attention Units	Precision	Recall	F1-score	Accuracy
	Spatial	Temporal						
1	2D CNN (3 Layer)	GRU (1 Layer) + Attention	512	1	0.72	0.71	0.71	0.71
2		GRU (2 Layer) + Attention	512	1	0.73	0.72	0.72	0.72
3	3D ResNet-18	GRU (2 Layer) + Attention	512	1	0.81	0.80	0.80	0.80
4		Bi-GRU (2 Layer) + Attention	512	1	0.82	0.81	0.81	0.81
5		Bi-GRU (3 Layer) + Attention	512	1	0.80	0.79	0.79	0.79
6	VGG-16 (Pretrain)	GRU (1 Layer)	256	-	0.48	0.46	0.46	0.46
7	MobileNetV2 (Pretrain)	GRU (1 Layer)	256	-	0.26	0.26	0.25	0.26
8	3D + 2D CNN (3 layer)	Bi-GRU (2 Layer)	512	1	0.81	0.80	0.80	0.80
9		+ Attention	512	1	0.83	0.83	0.83	0.83
10	3D + 2D CNN (4 layer)	GRU (1 Layer)	512	-	0.68	0.66	0.67	0.66
11		Bi-GRU (1 Layer)	512	-	0.64	0.63	0.63	0.63
12		GRU(2 Layer)	512	-	0.69	0.67	0.67	0.67
13		Bi-GRU (2 Layer)	512	-	0.67	0.65	0.65	0.65

การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-10 แบบจำลอง CNN + RNN + Attention (ลำดับที่ 2, 4, 8 และ 9) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น โดยเฉพาะเมื่อใช้ Attention ร่วมกับ RNN ซึ่งช่วยเพิ่มประสิทธิภาพของแบบจำลอง ทั้งนี้ แบบจำลอง 3D + 2D CNN + Bi-GRU + Attention (ลำดับที่ 9) มีประสิทธิภาพสูงสุด (Accuracy = 0.83) ซึ่งจากการทดลองแสดงให้เห็นว่า แบบจำลองที่มีโครงสร้าง RNN จำนวน 2 ชั้น จะมีประสิทธิภาพที่เหนือกว่าแบบจำลองที่มีโครงสร้าง RNN จำนวน 1 ชั้น หรือ 3 ชั้น อย่างมีนัยสำคัญ

4.5.2.5 ผลการทดลองเปรียบเทียบจำนวน Unit ของ Attention บนชุดข้อมูลแบบสุ่ม (Random Dataset) และชุดข้อมูลที่มีการขั้วริมฝีปากที่คล้ายคลึง (Homophones Dataset) ซึ่งใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score และ Accuracy รายละเอียดดังตารางที่ 4-11

ตารางที่ 4-11 แสดงผลการทดลองเปรียบเทียบจำนวน Unit ของ Attention

No.	Encode		Class	RNN Units	Attention Units	Precision	Recall	F1-score	Accuracy
	Spatial	Temporal							
1	3D ResNet-18	Bi-GRU (2 Layer) + Attention	100	512	1	0.82	0.81	0.81	0.81
2			78	512	1,024	0.72	0.72	0.71	0.72
3			100	512	1,024	0.85	0.84	0.84	0.84
4	VGG-16 (Pretrain)		78	512	1,024	0.51	0.50	0.50	0.50
5			100	512	1,024	0.62	0.61	0.61	0.61
6	3D + 2D CNN (4 layer)		100	512	1	0.83	0.83	0.83	0.83
7			78	512	1,024	0.71	0.69	0.69	0.69
8			100	512	1,024	0.84	0.83	0.83	0.83

การวิเคราะห์และสรุปผลการทดลอง


จากตารางที่ 4-11 แบบจำลอง 3D ResNet-18 + Bi-GRU + Attention (ลำดับที่ 3) มีประสิทธิภาพสูงสุด (Accuracy = 0.84) ซึ่งจากการทดลองแสดงให้เห็นว่า แบบจำลองที่มีจำนวน Units ของ Attention เป็น 1,024 จะมีประสิทธิภาพที่เหนือกว่าแบบจำลองที่มีจำนวน Units ของ Attention เป็น 1 อย่างมีนัยสำคัญ

4.5.2.6 ผลการทดลองเปรียบเทียบแบบจำลองขั้นสุดท้าย บนชุดข้อมูลทั้งหมด (All Dataset) ซึ่งใช้ตัวชี้วัดประสิทธิภาพ Precision, Recall, F1-score และ Accuracy รายละเอียดดังตารางที่ 4-12

ตารางที่ 4-12 แสดงผลการทดลองเปรียบเทียบแบบจำลองขั้นสุดท้าย


No.	Encode		Class	RNN Units	Attention Units	Precision	Recall	F1-score	Accuracy	Flops (G, 1×10^9)	Total Params (M, 1×10^6)
	Spatial	Temporal									
1	2D CNN (3 layer)	GRU (2 Layer) + Attention	500	512	1	0.67	0.67	0.67	0.67	14.08	3.44
2	VGG16 (Pretrain)	Bi-GRU (2 Layer)	500	512	1,024	0.48	0.48	0.47	0.48	222.70	24.15
3	3D ResNet-18	+ Attention	500	512	1,024	0.75	0.74	0.74	0.74	77.75	26.91
4	3D + 2D CNN (4 layer)	+ Attention	500	512	1,024	0.75	0.75	0.74	0.75	7.05	11.04
5		GRU (2 Layer) + Attention	500	512	512	0.72	0.71	0.71	0.71	7.03	5.28
6		Bi-GRU (2 Layer)	500	512	-	0.71	0.69	0.69	0.69	7.03	23.31
7		VIT-B16 (Pretrain)	500	-	-	0.36	0.32	0.30	0.32	48.52	88.33

4.5.2.6.1 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 2D CNN, GRU และ Attention (แบบจำลองลำดับที่ 1 ตารางที่ 4-12) แสดงดังภาพที่ 4-8




ภาพที่ 4-8 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 2D CNN, GRU และ Attention

4.5.2.6.2 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง VGG16, Bi-GRU และ Attention (แบบจำลองลำดับที่ 2 ตารางที่ 4-12) แสดงดังภาพที่ 4-9




ภาพที่ 4-9 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง VGG16, Bi-GRU และ Attention

4.5.2.6.3 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, ResNet-18, Bi-GRU และ Attention (แบบจำลองลำดับที่ 3 ตารางที่ 4-12) แสดงดังภาพที่ 4-10




ภาพที่ 4-10 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D+2D CNN, Bi-GRU และ Attention

4.5.2.6.4 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN, Bi-GRU และ Attention (แบบจำลองลำดับที่ 4 ตารางที่ 4-12) แสดงดังภาพที่ 4-11




ภาพที่ 4-11 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN, Bi-GRU และ Attention

4.5.2.6.5 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN, GRU และ Attention (แบบจำลองลำดับที่ 5 ตารางที่ 4-12) แสดงดังภาพที่ 4-12




ภาพที่ 4-12 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN, GRU และ Attention

4.5.2.6.6 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN และ Bi-GRU (แบบจำลองลำดับที่ 6 ตารางที่ 4-12) แสดงดังภาพที่ 4-13



ภาพที่ 4-13 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN และ Bi-GRU

4.5.2.6.7 การเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN และ Vit-B16 (แบบจำลองลำดับที่ 7 ตารางที่ 4-12) แสดงดังภาพที่ 4-14



ภาพที่ 4-14 แสดงการเปรียบเทียบระหว่าง train loss และ validation loss ของแบบจำลองผสมผสานระหว่าง 3D CNN, 2D CNN และ ViT-B16

การวิเคราะห์และสรุปผลการทดลอง

จากตารางที่ 4-12 แบบจำลองที่นำเสนอ 3D + 2D CNN + Bi-GRU + Attention (ลำดับที่ 4) มีประสิทธิภาพสูงกว่าแบบจำลองอื่น (Accuracy = 0.75) แต่อย่างไรก็ตาม แบบจำลองที่ใช้โครงสร้าง Transformers (ViT-B16) ไม่เหมาะกับงานวิจัยนี้ เนื่องจากมีประสิทธิภาพต่ำและใช้พารามิเตอร์จำนวนมาก ทั้งนี้ เมื่อเปรียบเทียบกับ 3D ResNet-18 + Bi-GRU + Attention (ลำดับที่ 3) ที่มีประสิทธิภาพใกล้เคียงกัน พบว่า สามารถลดค่า FLOPS ลง 90.93% และลดจำนวนพารามิเตอร์ลง 58.97% ซึ่งจากการทดลองแสดงให้เห็นว่า โครงสร้างแบบจำลองที่ซับซ้อนอย่างเช่น

ViT-B16 และ ResNet-18 ไม่ได้ให้ผลลัพธ์ที่ดีเสมอไป แต่กับโครงสร้างที่ซับซ้อนน้อยกว่าเช่น แบบจำลองที่นำเสนอ (ลำดับที่ 6) ก็ให้ประสิทธิภาพที่เหนือกว่าอย่างมีนัยสำคัญ อีกทั้งได้ทำการทดลองปรับเปลี่ยนโครงสร้าง Temporal encode ของแบบจำลองที่นำเสนอ (ลำดับที่ 4) เป็น GRU + Attention (ลำดับที่ 5), Bi-GRU (ลำดับที่ 6), ViT-B16 (ลำดับที่ 7) พบว่า โครงสร้าง Bi-GRU + Attention ที่ผู้วิจัยนำเสนอยังมีประสิทธิภาพสูงสุด



บทที่ 5

สรุปผลการทดลอง

การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพนั้น ผู้วิจัยขอสรุปผลการทดลองออกเป็น 2 กลุ่ม ประกอบด้วย 1) การทดลองตามชุดข้อมูล และ 2) การทดลองแบบปรับพารามิเตอร์ ซึ่งมีรายละเอียดดังนี้

5.1 การทดลองตามชุดข้อมูล

แบบจำลองที่มีโครงสร้าง CNN + RNN + Attention ให้ประสิทธิภาพสูงกว่าแบบจำลองอื่น โดยเฉพาะเมื่อใช้ Attention ร่วมกับ RNN ซึ่งช่วยเพิ่มประสิทธิภาพของแบบจำลอง แต่อย่างไรก็ตาม แบบจำลองที่ใช้โครงสร้าง Transformers (ViT-B16) ไม่เหมาะกับงานวิจัยนี้ เนื่องจากมีประสิทธิภาพต่ำและใช้พารามิเตอร์จำนวนมาก ทั้งนี้ แบบจำลอง 3D ResNet-18 + Bi-GRU + Attention มีประสิทธิภาพสูงบนชุดข้อมูล Homophones (78 คำ) และชุดข้อมูล Random (100 คำ) เมื่อเปรียบเทียบประสิทธิภาพกับแบบจำลอง Baseline ทั้งหมด สำหรับชุดข้อมูลดังกล่าว แบบจำลองที่นำเสนอ 3D + 2D CNN + Bi-GRU + Attention มีค่า Accuracy ต่ำกว่าอยู่ที่ 0.03 และ 0.01 ตามลำดับ แต่ใช้ทรัพยากรในการประมวลผลน้อยกว่า ซึ่งสามารถลดค่า FLOPS ลงประมาณ 91% และลดจำนวนพารามิเตอร์ลงประมาณ 60% และสำหรับชุดข้อมูล All แบบจำลองที่นำเสนอ 3D + 2D CNN + Bi-GRU + Attention ให้ประสิทธิภาพสูงเมื่อเปรียบเทียบประสิทธิภาพกับแบบจำลอง Baseline ทั้งหมด อีกทั้งยังใช้ทรัพยากรในการประมวลผลน้อยกว่า ซึ่งสามารถลดค่า FLOPS ลงประมาณ 91% และลดจำนวนพารามิเตอร์ลงประมาณ 60% เมื่อเปรียบเทียบกับแบบจำลอง 3D ResNet-18 + Bi-GRU + Attention ที่มีประสิทธิภาพใกล้เคียงกัน ซึ่งจากการทดลองแสดงให้เห็นว่า โครงสร้างแบบจำลองที่นำเสนอมีความซับซ้อนของแบบจำลองที่น้อยกว่า (เมื่อเปรียบเทียบจากจำนวนพารามิเตอร์) และใช้ทรัพยากรในการประมวลผลน้อยกว่า (เมื่อเปรียบเทียบจาก FLOPS) โดยให้ประสิทธิภาพที่เทียบเท่าหรือดีกว่าบนชุดข้อมูล LRW (เมื่อเปรียบเทียบประสิทธิภาพจาก Precision, Recall, F1-score และ Accuracy)

5.2 การทดลองแบบปรับพารามิเตอร์ (Ablation study)

แบบจำลองที่มีโครงสร้าง CNN + RNN ให้ประสิทธิภาพที่เหนือกว่าแบบจำลองอื่นบนชุดข้อมูลที่ฝึกฝนและทดสอบสี (RGB) โดยเฉพาะเมื่อใช้โครงสร้างแบบจำลอง Attention ร่วมกับ RNN ซึ่งช่วยเพิ่มประสิทธิภาพของแบบจำลอง และจากการทดลองพบว่า การกำหนดค่า Units ของ GRU ต้องเป็น 512 Units จำนวนชั้น (Layer) ของ GRU ต้องเท่ากับ 2 ชั้น รวมถึงกำหนดค่าของ Attention

Units ต้องเป็น 1,024 Units เพื่อให้แบบจำลองที่นำเสนอมีประสิทธิภาพสูงสุด อีกทั้งได้ทำการทดลองปรับเปลี่ยนโครงสร้าง Temporal encode ของแบบจำลองที่นำเสนอ เป็น GRU + Attention, Bi-GRU และ ViT-B16 พบว่า แบบจำลองที่ผู้วิจัยนำเสนอที่ใช้โครงสร้าง Temporal encode เป็น Bi-GRU + Attention ยังคงมีประสิทธิภาพสูงสุดเมื่อเปรียบเทียบกับแบบจำลองที่ได้ทำการปรับเปลี่ยนโครงสร้าง Temporal encode แล้วอย่างมีนัยสำคัญ

5.3 ปัญหาและอุปสรรค

5.3.1 เนื่องจากชุดข้อมูล LRW (Lip Reading in the Wild) ซึ่งเป็นชุดข้อมูล lipreading ที่เปิดเผยต่อสาธารณะในภาษาอังกฤษจากช่อง BBC ซึ่งประกอบไปด้วยจำนวน 500 คำ จำนวนวิดีโอทั้งสิ้น 538,766 วิดีโอ โดยแบ่งออกเป็น Train dataset จำนวน 488,766 วิดีโอ Validation และ Test dataset อย่างละ 25,000 วิดีโอ ซึ่งอัตราส่วนระหว่าง Validation และ Test dataset ต่อ Train dataset คิดเป็นแค่ประมาณ 10% ของวิดีโอทั้งหมด ทำให้แบบจำลองสามารถเกิด Overfitting ได้ง่าย

5.3.2 เนื่องจากวิดีโอทั้งหมดมีขนาดเท่ากับ $538,766 \times 112 \times 112 \times 29 \times 3 = 587,970,421,248$ พิกเซล (โดยที่ 112 คือ ขนาดเฟรมวิดีโอ, 29 คือ จำนวนเฟรม และ 3 คือ ช่องสี) ทำให้ต้องการหน่วยความจำของการ์ดจอ (Virtual RAM) ปริมาณมาก เพื่อใช้ในการประมวลผลเพื่อปรับปรุงพารามิเตอร์ (Backpropagation) ซึ่งส่งผลต่อการกำหนดค่าของ Batch ที่จะปรับปรุงพารามิเตอร์คราวละกี่เฟรม ข้อมูลในระหว่างการฝึกฝนแบบจำลอง ขอยกตัวอย่างเช่น แบบจำลองที่มีโครงสร้างของ Vision Transformers จะสามารถกำหนดค่าของ Batch ได้ไม่เกินกว่า 8 เป็นต้น ซึ่งอาจส่งผลให้แบบจำลองไม่สามารถเรียนรู้ข้อมูลได้อย่างครอบคลุมและมีประสิทธิภาพเท่าที่ควร

บรรณานุกรม

- Bregler, C., & Konig, Y. (1994, 19-22 April 1994). "Eigenlips" for robust speech recognition. Proceedings of ICASSP '94. IEEE International Conference on Acoustics, Speech and Signal Processing,
- Chen, H., Du, J., Hu, Y., Dai, L., Lee, C.-H., & Yin, B. (2020). Lip-reading with Hierarchical Pyramidal Convolution and Self-Attention. *ArXiv, abs/2012.14360*.
- Cheng, S., Ma, P., Tzimiropoulos, G., Petridis, S., Bulat, A., Shen, J., & Pantic, M. (2019). Towards Pose-Invariant Lip-Reading. *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 4357-4361.
- Cho, K., Merrienboer, B. v., Gülçehre, Ç., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. Conference on Empirical Methods in Natural Language Processing,
- Chung, J. S., Senior, A. W., Vinyals, O., & Zisserman, A. (2016). Lip Reading Sentences in the Wild. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 3444-3453.
- Chung, J. S., & Zisserman, A. (2016). Lip Reading in the Wild. Asian Conference on Computer Vision,
- Cootes, T. F., Edwards, G. J., & Taylor, C. J. (2001). Active appearance models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 23(6), 681-685. <https://doi.org/10.1109/34.927467>
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T.,...Houlsby, N. (2020). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ArXiv, abs/2010.11929*.
- Feng, D., Yang, S., Shan, S., & Chen, X. (2020). Learn an Effective Lip Reading Model without Pains. *ArXiv, abs/2011.07557*.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>

- Kass, M., Witkin, A., & Terzopoulos, D. (1988). Snakes: Active contour models. *International Journal of Computer Vision*, 1(4), 321-331. <https://doi.org/10.1007/BF00133570>
- Koumparoulis, A., & Potamianos, G. (2022). Accurate and Resource-Efficient Lipreading with Efficientnetv2 and Transformers. *ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 8467-8471.
- Luo, M., Yang, S., Shan, S., & Chen, X. (2020). Pseudo-Convolutional Policy Gradient for Sequence-to-Sequence Lip-Reading. *2020 15th IEEE International Conference on Automatic Face and Gesture Recognition (FG 2020)*, 273-280.
- Ma, P., Martínez, B., Petridis, S., & Pantic, M. (2020). Towards Practical Lipreading with Distilled and Efficient Models. *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 7608-7612.
- Ma, P., Wang, Y., Shen, J., Petridis, S., & Pantic, M. (2020). Lip-reading with Densely Connected Temporal Convolutional Networks. *2021 IEEE Winter Conference on Applications of Computer Vision (WACV)*, 2856-2865.
- Ma, X., Yan, L., & Zhong, Q. (2016, 27-29 July 2016). Lip feature extraction based on improved jumping-snake model. 2016 35th Chinese Control Conference (CCC),
- Martínez, B., Ma, P., Petridis, S., & Pantic, M. (2020). Lipreading Using Temporal Convolutional Networks. *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 6319-6323.
- Petajan, E. (1984). Automatic Lipreading to Enhance Speech Recognition (Speech Reading).
- Petridis, S., Stafylakis, T., Ma, P., Cai, F., Tzimiropoulos, G., & Pantic, M. (2018). End-to-End Audiovisual Speech Recognition. *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 6548-6552.
- Potamianos, G., Neti, C., Luetten, J., & Matthews, I. (2004). Audio-Visual Automatic Speech Recognition: An Overview.
- Ren, S., Du, Y., Lv, J., Han, G., & He, S. (2021). Learning from the Master: Distilling Cross-modal Advanced Knowledge for Lip Reading. *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 13320-13328.

- Stafylakis, T., & Tzimiropoulos, G. (2017). Combining Residual Networks with LSTMs for Lipreading. *ArXiv, abs/1703.04105*.
- Sujatha, P., & Krishnan, M. R. (2012, 22-24 Feb. 2012). Lip feature extraction for visual speech recognition using Hidden Markov Model. 2012 International Conference on Computing, Communication and Applications,
- Vaswani, A., Shazeer, N. M., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N.,...Polosukhin, I. (2017). Attention is All you Need. *Neural Information Processing Systems*,
- Wang, H., Pu, G., & Chen, T. (2022). A Lip Reading Method Based on 3D Convolutional Vision Transformer. *IEEE Access*, 10, 77205-77212.
- Wark, T., Sridharan, S., & Chandran, V. (1998, 20-20 Aug. 1998). An approach to statistical lip modelling for speaker identification via chromatic feature extraction. *Proceedings. Fourteenth International Conference on Pattern Recognition (Cat. No.98EX170)*,
- Wiryathammabhum, P. (2020). SpotFast Networks with Memory Augmented Lateral Transformers for Lipreading. *ArXiv, abs/2005.10903*.
- Xianghua, F., Fuyou, Z., Haixia, W., & Xiao, L. (2012, 23-25 May 2012). The system of face detection based on OpenCV. 2012 24th Chinese Control and Decision Conference (CCDC),
- Xiao, J., Yang, S., Zhang, Y., Shan, S., & Chen, X. (2020). Deformation Flow Based Two-Stream Network for Lip Reading. *2020 15th IEEE International Conference on Automatic Face and Gesture Recognition (FG 2020)*, 364-370.
- Yang, S., Zhang, Y., Feng, D., Yang, M., Wang, C., Xiao, J.,...Chen, X. (2018). LRW-1000: A Naturally-Distributed Large-Scale Benchmark for Lip Reading in the Wild. *2019 14th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2019)*, 1-8.
- Zhao, X., Yang, S., Shan, S., & Chen, X. (2020). Mutual Information Maximization for Effective Lip Reading. *2020 15th IEEE International Conference on Automatic Face and Gesture Recognition (FG 2020)*, 420-427.

ภาคผนวก ก


1. Lip Reading in the Wild Agreement (LRW)

BBC Commercial confidential BBC Research & Development 'Lip Reading in the Wild - Words' research project into lip reading and related accessibility Permission to Use for Researchers BBC TERMS: Help. There are a few rules for you. They tell you what you can do with our content for this 'Lip Reading in the Wild' research project ('Project'). What does content mean? We mean the BBC's dataset we're providing for the 'Project' named above, which is made up of BBC programme content created by the BBC, and which we're making available to you to download from a link provided by the BBC or by the university hosting and managing the content (or in any other way we decide). We do not guarantee that this link or our content will always be available, or that it is accurate, free of viruses and bugs, or the information it can be relied upon. You use our content entirely at your own risk. What can I use it for? Provided you keep to these rules, the BBC gives its limited permission for the named researcher (researcher) to use the BBC's content free of charge for 'Academic Research Purposes' for this Project for 12 months starting on the date both you and the BBC sign this 'Permission to Use for Research' form. You are responsible for your own costs in using part in the Project. You must delete all BBC content when this permission ends – please see section 6 for more information. 'Academic Research Purposes' means solely these activities for this Project: - using our content for individual research and private study; - using a small number of extracts from our content for academic demonstrations or academic conferences to involve, not paying guests to demonstrate your research for the Project in a technical context. But any of the extracts we do not include images of children, other people's logos or trade marks, sports or music. If any extracts are of recognizable living adult individuals (either individually or through a combination of images, text, analysis/comments/interpretations), you must keep to a minimum your use of extracts that identify individuals and you must not use them in any way that might adversely affect those individuals. Ask the BBC Contact (the BBC person who signs this form) if you are not sure if you can use an image or extract. Using a small number of still images (photos) or transcriptions of extracts from our content in academic papers, but you MUST ask the BBC Contact for permission first. You must tell the BBC Contact which images and extracts you would like to use. If the BBC gives its permission in writing, you can then include the permitted images and extracts in your academic paper and publish it in print or online as a pdf file. For the research community to illustrate the results of your research into the Project (that the images and extracts must never be used as part of an online demonstration). Academic papers must be made available to the research community for individual research and private study purposes only, and must contain this accreditation wording: 'For non-commercial individual research and private study use only. BBC content included courtesy of the BBC.' Creative Commons or similar license terms must not be attached to the BBC content in academic papers. - using our content to build a research prototype to compare with your organization's own existing technology. This work must be done separately from your organization's commercial product development. The BBC's content must not be used for training any existing or new technology, algorithms or models that will be sold commercially. And it must not be used to train technology to improve or enhance your operational systems. It can only be used for comparative or benchmarking purposes. What must I NOT use it for? Don't use our content for anything else. These terms do not give you permission to use content for any other purpose, for any other project, or for commercial purposes including sales, product promotion and making a profit. You must ask our permission to use our content for other purposes before you start using it. Please contact the BBC Contact. And if we don't give our permission, you must not use our content for other purposes. Don't use our content for harmful or offensive purposes. There are things that may harm or offend, military use and surveillance; misleading, misleading or defaming (damaging people's reputations), promoting pornography, tobacco or weapons; BBC Project Permission to Use for Researchers Terms 'Lip Reading version' BBC © 2023	BBC Commercial confidential putting children at risk, anything illegal. We using hate speech, inciting terrorism or breaching privacy law; anything that would harm the BBC's reputation or are not in line with the BBC's Editorial Guidelines. Don't use our content if we ask you not to. That includes removing any part of our content in your device/systems/events/publications immediately when we ask you to, to which we can do at any time without giving our reasons. In exceptional cases you may have to recall a published paper, stop using our content at a demonstration or conference, or remove our content from your research results (including, where reasonably possible, if the device/systems/events/publications are controlled by someone else). Don't exaggerate your relationship with the BBC. You can't say we endorse, promote, support or approve of you. And don't say you have exclusive access to our content (because you don't). Don't associate our content with advertising or sponsorship. That means you can't put any other content between the links to our content and the content itself (so no ads or short videos people have to click before the academic paper), and advertisements next to or over our content; put any advertisements in a document or webpage that contains mostly our content; put advertisements of a related subject alongside our content; add extra content that means you'd earn money from our content. Don't be misleading about where our content came from. You can't remove or alter the copyright notice, BBC logos, or statements or imply that someone else made it. Don't pretend to be the BBC. That includes using our brands, trade marks or logos without our permission; using or mentioning our content in press releases and other marketing materials; making money from our content. You can't charge people to view our images, for example; sharing our content (for example, no uploading to social media sites). Content ownership. The BBC does not transfer ownership of any of our content to anyone else (not to you, your supervisor, your organization and including when it is included in research results, prototypes, publications and demonstrations). To the extent that copyright, database rights or any other form of intellectual property rights come into existence as a result of your use of our content, we will own those future rights in our content and you will assign those intellectual property rights to us. You own the right to use our content without any right to the BBC. Copy. If we ask you, you must provide one copy of your research results and you give us permanent permission to use the parts of the research that you own in all media throughout the world in perpetuity free of charge for our public service purposes, for further research with our co-abstract partners, and to reuse your work. You must also provide the web address for all websites where the content is displayed, and you must tell us immediately about any changes to the web address. You must not make copies of our content or give our content to anyone else or let anyone else use our content. Can the BBC extend or cancel my permission? You must stop using our content when the Project ends. But this permission can be extended if the BBC and you both agree in writing. And the BBC can cancel this permission (including any extension) and additional permission to use images and extracts in section 2) at any time without giving our reasons. If you don't stick to these BBC terms, we may also refuse requests to take part in other projects. If we cancel this permission, or when it ends or if you no longer need to use our content for the Project, you must stop using our content immediately and permanently delete all copies of it from all devices/systems/events/publications including, where reasonably possible, from any devices/systems/events/publications controlled by someone else (for example, cloud servers). You do not have to delete our content from your published academic papers, unless we have asked you to stop using our content. Personal data - We must both act in line with the Data Protection Act 2018 and any other applicable data protection law and guidance ('Data Protection Law'), and make sure that our sub-processors (data controller, processor, personal data and supervisory authority) have the meanings set out in the Data Protection Law. - If you process personal data contained in our content or extracted from our content ('BBC Personal Data'), you must use it only where necessary to take part in the Project and in line with our instructions as data controller. We process this data (providing it to you on the basis that the BBC has a legitimate interest in promoting further use of the BBC Personal Data for journalistic, artistic and literary purposes, and in the public interest). - The BBC, as data controller, will handle your name and address and any other personal data you provide to us on this form in line with Data Protection Law and the BBC Privacy Policy for the performance of this contract. - If you process BBC Personal Data for your own purposes, the Academic Research Purposes, you will be a data controller of it in your own right. We will not be joint controllers and Article 26 of the General Data Protection Regulations (EU) 2016/679 does not apply. - For information on data protection, see the Information Commissioner's website: https://ico.org.uk/. BBC Project Permission to Use for Researchers Terms 'Lip Reading version' BBC © 2023
BBC Commercial confidential Data security. You may only store the BBC content securely on your organization's servers in the United Kingdom or the European Economic Area (EEA) or in the cloud servers based in the UK or EEA of a reputable cloud services provider (but not anywhere else or in any cloud location). All access passwords must be kept safe and must only be shared with the people named on this form. You must tell the BBC Information Security at informationsecurity@bbc.co.uk immediately (not later than 74 hours) if you know of, or suspect, that the BBC content or the personal data in the content has been used unlawfully or in a way that is not permitted in these terms, or is used by anyone other than you, or is damaged or lost. If requested by the BBC or a Supervisory Authority, you will provide reasonable assistance at your own expense. FOIA and confidentiality. If the BBC receives a request for information under the Freedom of Information Act 2000 (FOIA) and requests your help in responding to it, you will give us your help by your own within 5 business days (Monday to Friday except on bank holidays) of asking. The BBC alone decides how to reply to requests it receives. If you receive a FOIA request about the BBC or the BBC content, you must tell the BBC or straightaway you must not reply to it yourself (unless your organization is subject to FOIA, tell the BBC when you start the Project. If your organization is subject to FOIA, The BBC will give immediate assistance with any request for BBC information you receive under FOIA). The password or username we give you to gain access to our content (and anything else we mark as confidential or you might know if not formal) is the BBC's confidential information and you must not tell anyone else about it or use it for any purpose other than the Project. If you want to use our confidential information for anything else, you must get our written permission first. Machine learning (ML)/Artificial intelligence (AI). When you use the BBC's content for the Project, you must adhere to AI/ML ethics principles that include designing, developing and implementing ML/AI systems responsibly, avoiding discrimination and unfair/biased and unequal treatment of users, and transparency about ML services and data models. What you have to do: use the content only in accordance with these rules, and display it accurately. Add a credit if it doesn't already have one (to show where you got the content from (e.g. "BBC's copyright content reproduced courtesy of the British Broadcasting Corporation"). If the BBC suffers any loss or damage from any act, omission or information coming from you or your organization in relation to this Project, your organization (including you) will be liable to the BBC to the fullest extent possible at law for that loss or damage suffered by the BBC. A thing we have to say. Aside from what we're responsible for when there's a mishap, we're not liable for anything that happens to you if you use our content. Mishaps. We do our best to make our content the best it can be. So if something does go wrong, we are responsible only if our negligence causes death or injury. Otherwise, we're not liable for anything that happens if you rely on advice, data, commentary, opinions or any other content; there are errors, omissions, inaccuracies, delays, bugs or viruses; we turn off or remove content; the thing that happens couldn't reasonably have been foreseen; the thing that happens wouldn't usually result from the mishap; or you and we hadn't agreed that this thing would probably happen in the event of a mishap. And finally. These BBC terms replace all previous agreements between you and us about using this content for this Project and no other BBC terms of use apply. This is a contract between your organization (including you) and us, and you must not transfer it to anyone else. No one else has any rights to enforce its terms. Any changes to its terms must be in writing and signed by both of us. English law governs these BBC terms, and any English courts can make judgments about them. Our contract is made available to you by the firm's Broadcasting Corporation, a public Corporation incorporated by Royal Charter under the laws of the United Kingdom whose principal office is at Broadcasting House, Portland Place, London W1A 1AA. ABOUT YOU: Name of researcher: Mr. Teerapong Ngamprongwong Name of your professor or supervisor (if you are not a member of staff of your organization): Assistant Professor Dr. Luop Poomsupan Name of organization: King Mongkut's University of Technology North Bangkok (KMUTNB) Registration/principal postal address of organization: 10400 Contact email address: s30406285603@kmutnb.ac.th, kumpo@kmutnb.ac.th ☒ I agree to the above BBC terms Date: March 10, 2024 (Please select to show you understand and agree to these BBC terms. You must be authorised by your organisation to enter into this contract.) BBC Project Permission to Use for Researchers Terms 'Lip Reading version' BBC © 2023	BBC Commercial confidential THE BBC'S PERMISSION: Signed by the BBC:  BBC Contact: Phil Cooper Title and Department: Lead R&D Development Producer, BBC Research & Development Email: phil.cooper@bbc.co.uk Date: Monday, 12 March 2024 March 10, 2024 BBC ref/contract no.: 1001 19562 BBC Project Permission to Use for Researchers Terms 'Lip Reading version' BBC © 2023

ภาพที่ ก-1 Lip Reading in the Wild Agreement (LRW)


2. โครงสร้างแบบจำลอง Baseline ทั้ง 4 แบบจำลองแสดงดังนี้

2.1 แบบจำลอง 3D CNN แสดงโครงสร้างแบบจำลองดังภาพที่ ก-2




ภาพที่ ก-2 แสดงแบบจำลอง 3D CNN ใน Baseline

2.2 แบบจำลอง 3D + 2D CNN และ Bi-GRU แสดงโครงสร้างแบบจำลองดังภาพที่ ก-3




ภาพที่ ก-3 แสดงแบบจำลอง 3D + 2D CNN และ Bi-GRU ใน Baseline

2.3 แบบจำลอง 2D CNN + GRU + Attention แสดงโครงสร้างแบบจำลองดังภาพที่ ก-4



ภาพที่ ก-4 แสดงแบบจำลอง 2D CNN + GRU + Attention ใน Baseline

2.4 แบบจำลอง 3D + 2D CNN + ViT-B16 แสดงโครงสร้างแบบจำลองดังภาพที่ ก-5



ภาพที่ ก-5 แสดงแบบจำลอง 3D + 2D CNN + ViT-B16 ใน Baseline

3. ชุดข้อมูลมาตรฐาน LRW (Lip Reading in the Wild) โดยแบ่งข้อมูลออกเป็น 3 ชุดข้อมูล แสดงดังตารางที่ ก-1 ถึง ก-3

ตารางที่ ก-1 ชุดข้อมูลที่มีการขยับริมฝีปากที่คล้ายคลึง (Homophones Dataset) จำนวน 78 คำ

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
1	ABOUT	1,000	50	50	1,100	40	MONTH	1,000	50	50	1,100
2	ACTION	1,000	50	50	1,100	41	MONTHS	1,000	50	50	1,100
3	ALLOW	849	50	50	949	42	NUMBER	1,000	50	50	1,100
4	ALLOWED	812	50	50	912	43	NUMBERS	1,000	50	50	1,100
5	AMERICA	924	50	50	1,024	44	OFFICE	1,000	50	50	1,100
6	AMERICAN	1,000	50	50	1,100	45	OFTEN	947	50	50	1,047
7	AMONG	907	50	50	1,007	46	OPPOSITION	858	50	50	958
8	AROUND	1,000	50	50	1,100	47	PERSON	1,000	50	50	1,100
9	BENEFIT	1,000	50	50	1,100	48	PERSONAL	846	50	50	946
10	BENEFITS	1,000	50	50	1,100	49	POSITION	1,000	50	50	1,100
11	BETTER	1,000	50	50	1,100	50	PRESS	954	50	50	1,054
12	BILLION	1,000	50	50	1,100	51	PRICE	1,000	50	50	1,100
13	CLAIMS	890	50	50	990	52	PROBLEM	1,000	50	50	1,100
14	COMPANIES	1,000	50	50	1,100	53	PROBLEMS	1,000	50	50	1,100
15	COMPANY	1,000	50	50	1,100	54	REPORT	1,000	50	50	1,100
16	COURSE	1,000	50	50	1,100	55	REPORTS	1,000	50	50	1,100
17	COURT	1,000	50	50	1,100	56	RIGHT	1,000	50	50	1,100
18	ELECTION	1,000	50	50	1,100	57	RUSSIA	1,000	50	50	1,100
19	FIGHT	1,000	50	50	1,100	58	RUSSIAN	1,000	50	50	1,100
20	GAMES	964	50	50	1,064	59	SCHOOL	1,000	50	50	1,100
21	GIVEN	1,000	50	50	1,100	60	SCHOOLS	1,000	50	50	1,100
22	GIVING	990	50	50	1,090	61	SEEMS	1,000	50	50	1,100
23	GREAT	1,000	50	50	1,100	62	SERVICE	1,000	50	50	1,100
24	GROUND	1,000	50	50	1,100	63	SERVICES	1,000	50	50	1,100
25	HAPPEN	1,000	50	50	1,100	64	SPEND	834	50	50	934
26	HAPPENED	1,000	50	50	1,100	65	SPENT	887	50	50	987
27	HISTORY	1,000	50	50	1,100	66	SYRIA	1,000	50	50	1,100
28	HOUSE	1,000	50	50	1,100	67	SYRIAN	894	50	50	994
29	HOUSING	1,000	50	50	1,100	68	TAKEN	1,000	50	50	1,100
30	INDUSTRY	1,000	50	50	1,100	69	TAKING	1,000	50	50	1,100
31	LEVEL	1,000	50	50	1,100	70	TALKS	1,000	50	50	1,100
32	LEVELS	1,000	50	50	1,100	71	TERMS	1,000	50	50	1,100
33	LIVING	1,000	50	50	1,100	72	THREAT	1,000	50	50	1,100
34	MAKES	916	50	50	1,016	73	WANTED	1,000	50	50	1,100
35	MATTER	859	50	50	959	74	WANTS	1,000	50	50	1,100
36	MEANS	1,000	50	50	1,100	75	WHERE	1,000	50	50	1,100
37	MEETING	1,000	50	50	1,100	76	WHILE	932	50	50	1,032
38	MILLION	1,000	50	50	1,100	77	WORDS	941	50	50	1,041
39	MISSING	887	50	50	987	78	WORST	870	50	50	970

ตารางที่ ก-2 ชุดข้อมูลแบบสุ่ม (Random Dataset) จำนวน 100 คำ

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
1	ACCORDING	1,000	50	50	1,100	51	MEDICAL	886	50	50	986
2	ACCUSED	1,000	50	50	1,100	52	MEETING	1,000	50	50	1,100
3	ACTION	1,000	50	50	1,100	53	MILLION	1,000	50	50	1,100
4	ACTUALLY	1,000	50	50	1,100	54	MINUTES	1,000	50	50	1,100
5	AFRICA	1,000	50	50	1,100	55	MISSING	887	50	50	987
6	ANOTHER	1,000	50	50	1,100	56	MONTHS	1,000	50	50	1,100
7	AROUND	1,000	50	50	1,100	57	NUMBERS	1,000	50	50	1,100
8	ATTACKS	946	50	50	1,046	58	OFFICIALS	965	50	50	1,065
9	BECOME	1,000	50	50	1,100	59	OPERATION	851	50	50	951
10	BEFORE	1,000	50	50	1,100	60	OPPOSITION	858	50	50	958
11	BEING	1,000	50	50	1,100	61	PARTY	1,000	50	50	1,100
12	BETTER	1,000	50	50	1,100	62	PLACE	1,000	50	50	1,100
13	BUDGET	1,000	50	50	1,100	63	PLANS	1,000	50	50	1,100
14	BUILD	814	50	50	914	64	POINT	1,000	50	50	1,100
15	BUSINESS	1,000	50	50	1,100	65	PRETTY	1,000	50	50	1,100
16	CALLED	1,000	50	50	1,100	66	PRICES	1,000	50	50	1,100
17	CANCER	833	50	50	933	67	PRISON	956	50	50	1,056
18	CANNOT	859	50	50	959	68	PRIVATE	1,000	50	50	1,100
19	CENTRAL	1,000	50	50	1,100	69	PROVIDE	823	50	50	923
20	CHILDREN	1,000	50	50	1,100	70	PUBLIC	1,000	50	50	1,100
21	CLAIMS	890	50	50	990	71	QUESTION	1,000	50	50	1,100
22	CONCERNS	864	50	50	964	72	REASON	1,000	50	50	1,100
23	CONTROL	1,000	50	50	1,100	73	RECENT	1,000	50	50	1,100
24	COULD	1,000	50	50	1,100	74	RECORD	1,000	50	50	1,100
25	CRIME	1,000	50	50	1,100	75	REFERENDUM	1,000	50	50	1,100
26	DIFFERENT	1,000	50	50	1,100	76	RESULT	1,000	50	50	1,100
27	DIFFICULT	1,000	50	50	1,100	77	RIGHT	1,000	50	50	1,100
28	EARLY	999	50	50	1,099	78	SECRETARY	1,000	50	50	1,100
29	EMERGENCY	809	50	50	909	79	SEVEN	1,000	50	50	1,100
30	ENGLAND	1,000	50	50	1,100	80	SINGLE	991	50	50	1,091
31	EUROPE	1,000	50	50	1,100	81	SITUATION	1,000	50	50	1,100
32	EVERYBODY	950	50	50	1,050	82	SOMETHING	1,000	50	50	1,100
33	FINAL	1,000	50	50	1,100	83	SPEAKING	1,000	50	50	1,100
34	FOOTBALL	1,000	50	50	1,100	84	SPEND	834	50	50	934
35	FORMER	1,000	50	50	1,100	85	STAFF	1,000	50	50	1,100
36	FUTURE	1,000	50	50	1,100	86	STAND	1,000	50	50	1,100
37	GEORGE	1,000	50	50	1,100	87	STATE	1,000	50	50	1,100
38	GERMANY	1,000	50	50	1,100	88	STATEMENT	945	50	50	1,045
39	GROWING	1,000	50	50	1,100	89	STRONG	1,000	50	50	1,100
40	HEALTH	1,000	50	50	1,100	90	SYRIA	1,000	50	50	1,100
41	HEARD	1,000	50	50	1,100	91	THIRD	1,000	50	50	1,100

ตารางที่ ก-2 ชุดข้อมูลแบบสุ่ม (Random Dataset) จำนวน 100 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
42	HISTORY	1,000	50	50	1,100	92	UNDER	1,000	50	50	1,100
43	HOMES	1,000	50	50	1,100	93	UNDERSTAND	1,000	50	50	1,100
44	IRELAND	1,000	50	50	1,100	94	UNION	1,000	50	50	1,100
45	ISLAMIC	1,000	50	50	1,100	95	UNTIL	1,000	50	50	1,100
46	JUDGE	842	50	50	942	96	WELCOME	1,000	50	50	1,100
47	LEGAL	917	50	50	1,017	97	WELFARE	874	50	50	974
48	LONGER	930	50	50	1,030	98	WOMEN	1,000	50	50	1,100
49	MANCHESTER	1,000	50	50	1,100	99	WORKERS	1,000	50	50	1,100
50	MEANS	1,000	50	50	1,100	100	WORKING	1,000	50	50	1,100

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
1	ABOUT	1,000	50	50	1,100	251	LOOKING	1,000	50	50	1,100
2	ABSOLUTELY	959	50	50	1,059	252	MAJOR	1,000	50	50	1,100
3	ABUSE	1,000	50	50	1,100	253	MAJORITY	1,000	50	50	1,100
4	ACCESS	1,000	50	50	1,100	254	MAKES	916	50	50	1,016
5	ACCORDING	1,000	50	50	1,100	255	MAKING	1,000	50	50	1,100
6	ACCUSED	1,000	50	50	1,100	256	MANCHESTER	1,000	50	50	1,100
7	ACROSS	1,000	50	50	1,100	257	MARKET	1,000	50	50	1,100
8	ACTION	1,000	50	50	1,100	258	MASSIVE	824	50	50	924
9	ACTUALLY	1,000	50	50	1,100	259	MATTER	859	50	50	959
10	AFFAIRS	942	50	50	1,042	260	MAYBE	1,000	50	50	1,100
11	AFFECTED	810	50	50	910	261	MEANS	1,000	50	50	1,100
12	AFRICA	1,000	50	50	1,100	262	MEASURES	944	50	50	1,044
13	AFTER	1,000	50	50	1,100	263	MEDIA	1,000	50	50	1,100
14	AFTERNOON	1,000	50	50	1,100	264	MEDICAL	886	50	50	986
15	AGAIN	1,000	50	50	1,100	265	MEETING	1,000	50	50	1,100
16	AGAINST	1,000	50	50	1,100	266	MEMBER	814	50	50	914
17	AGREE	1,000	50	50	1,100	267	MEMBERS	1,000	50	50	1,100
18	AGREEMENT	852	50	50	952	268	MESSAGE	1,000	50	50	1,100
19	AHEAD	1,000	50	50	1,100	269	MIDDLE	962	50	50	1,062
20	ALLEGATIONS	1,000	50	50	1,100	270	MIGHT	1,000	50	50	1,100
21	ALLOW	849	50	50	949	271	MIGRANTS	877	50	50	977
22	ALLOWED	812	50	50	912	272	MILITARY	1,000	50	50	1,100
23	ALMOST	1,000	50	50	1,100	273	MILLION	1,000	50	50	1,100
24	ALREADY	1,000	50	50	1,100	274	MILLIONS	971	50	50	1,071
25	ALWAYS	1,000	50	50	1,100	275	MINISTER	1,000	50	50	1,100
26	AMERICA	924	50	50	1,024	276	MINISTERS	1,000	50	50	1,100
27	AMERICAN	1,000	50	50	1,100	277	MINUTES	1,000	50	50	1,100
28	AMONG	907	50	50	1,007	278	MISSING	887	50	50	987
29	AMOUNT	1,000	50	50	1,100	279	MOMENT	1,000	50	50	1,100
30	ANNOUNCED	1,000	50	50	1,100	280	MONEY	1,000	50	50	1,100

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
31	ANOTHER	1,000	50	50	1,100	281	MONTH	1,000	50	50	1,100
32	ANSWER	969	50	50	1,069	282	MONTHS	1,000	50	50	1,100
33	ANYTHING	1,000	50	50	1,100	283	MORNING	1,000	50	50	1,100
34	AREAS	1,000	50	50	1,100	284	MOVING	1,000	50	50	1,100
35	AROUND	1,000	50	50	1,100	285	MURDER	1,000	50	50	1,100
36	ARRESTED	1,000	50	50	1,100	286	NATIONAL	1,000	50	50	1,100
37	ASKED	905	50	50	1,005	287	NEEDS	1,000	50	50	1,100
38	ASKING	1,000	50	50	1,100	288	NEVER	1,000	50	50	1,100
39	ATTACK	1,000	50	50	1,100	289	NIGHT	1,000	50	50	1,100
40	ATTACKS	946	50	50	1,046	290	NORTH	1,000	50	50	1,100
41	AUTHORITIES	1,000	50	50	1,100	291	NORTHERN	1,000	50	50	1,100
42	BANKS	1,000	50	50	1,100	292	NOTHING	1,000	50	50	1,100
43	BECAUSE	1,000	50	50	1,100	293	NUMBER	1,000	50	50	1,100
44	BECOME	1,000	50	50	1,100	294	NUMBERS	1,000	50	50	1,100
45	BEFORE	1,000	50	50	1,100	295	OBAMA	927	50	50	1,027
46	BEHIND	1,000	50	50	1,100	296	OFFICE	1,000	50	50	1,100
47	BEING	1,000	50	50	1,100	297	OFFICERS	1,000	50	50	1,100
48	BELIEVE	1,000	50	50	1,100	298	OFFICIALS	965	50	50	1,065
49	BENEFIT	1,000	50	50	1,100	299	OFTEN	947	50	50	1,047
50	BENEFITS	1,000	50	50	1,100	300	OPERATION	851	50	50	951
51	BETTER	1,000	50	50	1,100	301	OPPOSITION	858	50	50	958
52	BETWEEN	1,000	50	50	1,100	302	ORDER	1,000	50	50	1,100
53	BIGGEST	1,000	50	50	1,100	303	OTHER	1,000	50	50	1,100
54	BILLION	1,000	50	50	1,100	304	OTHERS	1,000	50	50	1,100
55	BLACK	853	50	50	953	305	OUTSIDE	1,000	50	50	1,100
56	BORDER	995	50	50	1,095	306	PARENTS	1,000	50	50	1,100
57	BRING	1,000	50	50	1,100	307	PARLIAMENT	1,000	50	50	1,100
58	BRITAIN	1,000	50	50	1,100	308	PARTIES	1,000	50	50	1,100
59	BRITISH	1,000	50	50	1,100	309	PARTS	1,000	50	50	1,100
60	BROUGHT	1,000	50	50	1,100	310	PARTY	1,000	50	50	1,100
61	BUDGET	1,000	50	50	1,100	311	PATIENTS	1,000	50	50	1,100
62	BUILD	814	50	50	914	312	PAYING	812	50	50	912
63	BUILDING	1,000	50	50	1,100	313	PEOPLE	1,000	50	50	1,100
64	BUSINESS	1,000	50	50	1,100	314	PERHAPS	1,000	50	50	1,100
65	BUSINESSES	830	50	50	930	315	PERIOD	1,000	50	50	1,100
66	CALLED	1,000	50	50	1,100	316	PERSON	1,000	50	50	1,100
67	CAMERON	1,000	50	50	1,100	317	PERSONAL	846	50	50	946
68	CAMPAIGN	1,000	50	50	1,100	318	PHONE	1,000	50	50	1,100
69	CANCER	833	50	50	933	319	PLACE	1,000	50	50	1,100
70	CANNOT	859	50	50	959	320	PLACES	1,000	50	50	1,100
71	CAPITAL	969	50	50	1,069	321	PLANS	1,000	50	50	1,100

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
72	CASES	1,000	50	50	1,100	322	POINT	1,000	50	50	1,100
73	CENTRAL	1,000	50	50	1,100	323	POLICE	1,000	50	50	1,100
74	CERTAINLY	947	50	50	1,047	324	POLICY	1,000	50	50	1,100
75	CHALLENGE	898	50	50	998	325	POLITICAL	1,000	50	50	1,100
76	CHANCE	1,000	50	50	1,100	326	POLITICIANS	1,000	50	50	1,100
77	CHANGE	1,000	50	50	1,100	327	POLITICS	1,000	50	50	1,100
78	CHANGES	1,000	50	50	1,100	328	POSITION	1,000	50	50	1,100
79	CHARGE	829	50	50	929	329	POSSIBLE	1,000	50	50	1,100
80	CHARGES	980	50	50	1,080	330	POTENTIAL	811	50	50	911
81	CHIEF	1,000	50	50	1,100	331	POWER	1,000	50	50	1,100
82	CHILD	1,000	50	50	1,100	332	POWERS	914	50	50	1,014
83	CHILDREN	1,000	50	50	1,100	333	PRESIDENT	1,000	50	50	1,100
84	CHINA	1,000	50	50	1,100	334	PRESS	954	50	50	1,054
85	CLAIMS	890	50	50	990	335	PRESSURE	1,000	50	50	1,100
86	CLEAR	1,000	50	50	1,100	336	PRETTY	1,000	50	50	1,100
87	CLOSE	1,000	50	50	1,100	337	PRICE	1,000	50	50	1,100
88	CLOUD	1,000	50	50	1,100	338	PRICES	1,000	50	50	1,100
89	COMES	1,000	50	50	1,100	339	PRIME	1,000	50	50	1,100
90	COMING	1,000	50	50	1,100	340	PRISON	956	50	50	1,056
91	COMMUNITY	1,000	50	50	1,100	341	PRIVATE	1,000	50	50	1,100
92	COMPANIES	1,000	50	50	1,100	342	PROBABLY	1,000	50	50	1,100
93	COMPANY	1,000	50	50	1,100	343	PROBLEM	1,000	50	50	1,100
94	CONCERNS	864	50	50	964	344	PROBLEMS	1,000	50	50	1,100
95	CONFERENCE	828	50	50	928	345	PROCESS	1,000	50	50	1,100
96	CONFLICT	917	50	50	1,017	346	PROTECT	923	50	50	1,023
97	CONSERVATIVE	1,000	50	50	1,100	347	PROVIDE	823	50	50	923
98	CONTINUE	1,000	50	50	1,100	348	PUBLIC	1,000	50	50	1,100
99	CONTROL	1,000	50	50	1,100	349	QUESTION	1,000	50	50	1,100
100	COULD	1,000	50	50	1,100	350	QUESTIONS	1,000	50	50	1,100
101	COUNCIL	1,000	50	50	1,100	351	QUITE	1,000	50	50	1,100
102	COUNTRIES	1,000	50	50	1,100	352	RATES	956	50	50	1,056
103	COUNTRY	1,000	50	50	1,100	353	RATHER	1,000	50	50	1,100
104	COUPLE	1,000	50	50	1,100	354	REALLY	1,000	50	50	1,100
105	COURSE	1,000	50	50	1,100	355	REASON	1,000	50	50	1,100
106	COURT	1,000	50	50	1,100	356	RECENT	1,000	50	50	1,100
107	CRIME	1,000	50	50	1,100	357	RECORD	1,000	50	50	1,100
108	CRISIS	1,000	50	50	1,100	358	REFERENDUM	1,000	50	50	1,100
109	CURRENT	841	50	50	941	359	REMEMBER	978	50	50	1,078
110	CUSTOMERS	856	50	50	956	360	REPORT	1,000	50	50	1,100
111	DAVID	1,000	50	50	1,100	361	REPORTS	1,000	50	50	1,100
112	DEATH	1,000	50	50	1,100	362	RESPONSE	957	50	50	1,057

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
113	DEBATE	1,000	50	50	1,100	363	RESULT	1,000	50	50	1,100
114	DECIDED	858	50	50	958	364	RETURN	821	50	50	921
115	DECISION	1,000	50	50	1,100	365	RIGHT	1,000	50	50	1,100
116	DEFICIT	882	50	50	982	366	RIGHTS	1,000	50	50	1,100
117	DEGREES	951	50	50	1,051	367	RULES	880	50	50	980
118	DESCRIBED	1,000	50	50	1,100	368	RUNNING	1,000	50	50	1,100
119	DESPITE	1,000	50	50	1,100	369	RUSSIA	1,000	50	50	1,100
120	DETAILS	1,000	50	50	1,100	370	RUSSIAN	1,000	50	50	1,100
121	DIFFERENCE	867	50	50	967	371	SAYING	1,000	50	50	1,100
122	DIFFERENT	1,000	50	50	1,100	372	SCHOOL	1,000	50	50	1,100
123	DIFFICULT	1,000	50	50	1,100	373	SCHOOLS	1,000	50	50	1,100
124	DOING	1,000	50	50	1,100	374	SCOTLAND	1,000	50	50	1,100
125	DURING	1,000	50	50	1,100	375	SCOTTISH	1,000	50	50	1,100
126	EARLY	999	50	50	1,099	376	SECOND	1,000	50	50	1,100
127	EASTERN	1,000	50	50	1,100	377	SECRETARY	1,000	50	50	1,100
128	ECONOMIC	1,000	50	50	1,100	378	SECTOR	1,000	50	50	1,100
129	ECONOMY	1,000	50	50	1,100	379	SECURITY	1,000	50	50	1,100
130	EDITOR	1,000	50	50	1,100	380	SEEMS	1,000	50	50	1,100
131	EDUCATION	1,000	50	50	1,100	381	SENIOR	1,000	50	50	1,100
132	ELECTION	1,000	50	50	1,100	382	SENSE	1,000	50	50	1,100
133	EMERGENCY	809	50	50	909	383	SERIES	841	50	50	941
134	ENERGY	1,000	50	50	1,100	384	SERIOUS	1,000	50	50	1,100
135	ENGLAND	1,000	50	50	1,100	385	SERVICE	1,000	50	50	1,100
136	ENOUGH	1,000	50	50	1,100	386	SERVICES	1,000	50	50	1,100
137	EUROPE	1,000	50	50	1,100	387	SEVEN	1,000	50	50	1,100
138	EUROPEAN	1,000	50	50	1,100	388	SEVERAL	1,000	50	50	1,100
139	EVENING	1,000	50	50	1,100	389	SHORT	1,000	50	50	1,100
140	EVENTS	847	50	50	947	390	SHOULD	1,000	50	50	1,100
141	EVERY	1,000	50	50	1,100	391	SIDES	850	50	50	950
142	EVERYBODY	950	50	50	1,050	392	SIGNIFICANT	954	50	50	1,054
143	EVERYONE	913	50	50	1,013	393	SIMPLY	1,000	50	50	1,100
144	EVERYTHING	1,000	50	50	1,100	394	SINCE	1,000	50	50	1,100
145	EVIDENCE	1,000	50	50	1,100	395	SINGLE	991	50	50	1,091
146	EXACTLY	903	50	50	1,003	396	SITUATION	1,000	50	50	1,100
147	EXAMPLE	1,000	50	50	1,100	397	SMALL	1,000	50	50	1,100
148	EXPECT	1,000	50	50	1,100	398	SOCIAL	1,000	50	50	1,100
149	EXPECTED	1,000	50	50	1,100	399	SOCIETY	1,000	50	50	1,100
150	EXTRA	936	50	50	1,036	400	SOMEONE	915	50	50	1,015
151	FACING	977	50	50	1,077	401	SOMETHING	1,000	50	50	1,100
152	FAMILIES	1,000	50	50	1,100	402	SOUTH	1,000	50	50	1,100
153	FAMILY	1,000	50	50	1,100	403	SOUTHERN	901	50	50	1,001

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
154	FIGHT	1,000	50	50	1,100	404	SPEAKING	1,000	50	50	1,100
155	FIGHTING	1,000	50	50	1,100	405	SPECIAL	1,000	50	50	1,100
156	FIGURES	1,000	50	50	1,100	406	SPEECH	1,000	50	50	1,100
157	FINAL	1,000	50	50	1,100	407	SPEND	834	50	50	934
158	FINANCIAL	1,000	50	50	1,100	408	SPENDING	1,000	50	50	1,100
159	FIRST	1,000	50	50	1,100	409	SPENT	887	50	50	987
160	FOCUS	943	50	50	1,043	410	STAFF	1,000	50	50	1,100
161	FOLLOWING	1,000	50	50	1,100	411	STAGE	948	50	50	1,048
162	FOOTBALL	1,000	50	50	1,100	412	STAND	1,000	50	50	1,100
163	FORCE	1,000	50	50	1,100	413	START	1,000	50	50	1,100
164	FORCES	1,000	50	50	1,100	414	STARTED	1,000	50	50	1,100
165	FOREIGN	1,000	50	50	1,100	415	STATE	1,000	50	50	1,100
166	FORMER	1,000	50	50	1,100	416	STATEMENT	945	50	50	1,045
167	FORWARD	1,000	50	50	1,100	417	STATES	1,000	50	50	1,100
168	FOUND	1,000	50	50	1,100	418	STILL	1,000	50	50	1,100
169	FRANCE	1,000	50	50	1,100	419	STORY	1,000	50	50	1,100
170	FRENCH	1,000	50	50	1,100	420	STREET	1,000	50	50	1,100
171	FRIDAY	1,000	50	50	1,100	421	STRONG	1,000	50	50	1,100
172	FRONT	1,000	50	50	1,100	422	SUNDAY	999	50	50	1,099
173	FURTHER	1,000	50	50	1,100	423	SUNSHINE	1,000	50	50	1,100
174	FUTURE	1,000	50	50	1,100	424	SUPPORT	1,000	50	50	1,100
175	GAMES	964	50	50	1,064	425	SYRIA	1,000	50	50	1,100
176	GENERAL	1,000	50	50	1,100	426	SYRIAN	894	50	50	994
177	GEORGE	1,000	50	50	1,100	427	SYSTEM	1,000	50	50	1,100
178	GERMANY	1,000	50	50	1,100	428	TAKEN	1,000	50	50	1,100
179	GETTING	1,000	50	50	1,100	429	TAKING	1,000	50	50	1,100
180	GIVEN	1,000	50	50	1,100	430	TALKING	1,000	50	50	1,100
181	GIVING	990	50	50	1,090	431	TALKS	1,000	50	50	1,100
182	GLOBAL	937	50	50	1,037	432	TEMPERATURES	1,000	50	50	1,100
183	GOING	1,000	50	50	1,100	433	TERMS	1,000	50	50	1,100
184	GOVERNMENT	1,000	50	50	1,100	434	THEIR	1,000	50	50	1,100
185	GREAT	1,000	50	50	1,100	435	THEMSELVES	1,000	50	50	1,100
186	GREECE	1,000	50	50	1,100	436	THERE	1,000	50	50	1,100
187	GROUND	1,000	50	50	1,100	437	THESE	1,000	50	50	1,100
188	GROUP	1,000	50	50	1,100	438	THING	1,000	50	50	1,100
189	GROWING	1,000	50	50	1,100	439	THINGS	1,000	50	50	1,100
190	GROWTH	1,000	50	50	1,100	440	THINK	1,000	50	50	1,100
191	GUILTY	861	50	50	961	441	THIRD	1,000	50	50	1,100
192	HAPPEN	1,000	50	50	1,100	442	THOSE	1,000	50	50	1,100
193	HAPPENED	1,000	50	50	1,100	443	THOUGHT	1,000	50	50	1,100
194	HAPPENING	1,000	50	50	1,100	444	THOUSANDS	1,000	50	50	1,100

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
195	HAVING	1,000	50	50	1,100	445	THREAT	1,000	50	50	1,100
196	HEALTH	1,000	50	50	1,100	446	THREE	1,000	50	50	1,100
197	HEARD	1,000	50	50	1,100	447	THROUGH	1,000	50	50	1,100
198	HEART	905	50	50	1,005	448	TIMES	1,000	50	50	1,100
199	HEAVY	1,000	50	50	1,100	449	TODAY	1,000	50	50	1,100
200	HIGHER	894	50	50	994	450	TOGETHER	1,000	50	50	1,100
201	HISTORY	1,000	50	50	1,100	451	TOMORROW	1,000	50	50	1,100
202	HOMES	1,000	50	50	1,100	452	TONIGHT	1,000	50	50	1,100
203	HOSPITAL	1,000	50	50	1,100	453	TOWARDS	1,000	50	50	1,100
204	HOURS	1,000	50	50	1,100	454	TRADE	831	50	50	931
205	HOUSE	1,000	50	50	1,100	455	TRIAL	1,000	50	50	1,100
206	HOUSING	1,000	50	50	1,100	456	TRUST	818	50	50	918
207	HUMAN	1,000	50	50	1,100	457	TRYING	1,000	50	50	1,100
208	HUNDREDS	1,000	50	50	1,100	458	UNDER	1,000	50	50	1,100
209	IMMIGRATION	946	50	50	1,046	459	UNDERSTAND	1,000	50	50	1,100
210	IMPACT	1,000	50	50	1,100	460	UNION	1,000	50	50	1,100
211	IMPORTANT	1,000	50	50	1,100	461	UNITED	1,000	50	50	1,100
212	INCREASE	1,000	50	50	1,100	462	UNTIL	1,000	50	50	1,100
213	INDEPENDENT	988	50	50	1,088	463	USING	1,000	50	50	1,100
214	INDUSTRY	1,000	50	50	1,100	464	VICTIMS	1,000	50	50	1,100
215	INFLATION	820	50	50	920	465	VIOLENCE	1,000	50	50	1,100
216	INFORMATION	1,000	50	50	1,100	466	VOTERS	958	50	50	1,058
217	INQUIRY	1,000	50	50	1,100	467	WAITING	836	50	50	936
218	INSIDE	936	50	50	1,036	468	WALES	1,000	50	50	1,100
219	INTEREST	1,000	50	50	1,100	469	WANTED	1,000	50	50	1,100
220	INVESTMENT	817	50	50	917	470	WANTS	1,000	50	50	1,100
221	INVOLVED	1,000	50	50	1,100	471	WARNING	957	50	50	1,057
222	IRELAND	1,000	50	50	1,100	472	WATCHING	824	50	50	924
223	ISLAMIC	1,000	50	50	1,100	473	WATER	1,000	50	50	1,100
224	ISSUE	1,000	50	50	1,100	474	WEAPONS	1,000	50	50	1,100
225	ISSUES	1,000	50	50	1,100	475	WEATHER	1,000	50	50	1,100
226	ITSELF	1,000	50	50	1,100	476	WEEKEND	1,000	50	50	1,100
227	JAMES	848	50	50	948	477	WEEKS	1,000	50	50	1,100
228	JUDGE	842	50	50	942	478	WELCOME	1,000	50	50	1,100
229	JUSTICE	926	50	50	1,026	479	WELFARE	874	50	50	974
230	KILLED	1,000	50	50	1,100	480	WESTERN	1,000	50	50	1,100
231	KNOWN	1,000	50	50	1,100	481	WESTMINSTER	883	50	50	983
232	LABOUR	1,000	50	50	1,100	482	WHERE	1,000	50	50	1,100
233	LARGE	1,000	50	50	1,100	483	WHETHER	1,000	50	50	1,100
234	LATER	1,000	50	50	1,100	484	WHICH	1,000	50	50	1,100
235	LATEST	1,000	50	50	1,100	485	WHILE	932	50	50	1,032

ตารางที่ ก-3 ชุดข้อมูลทั้งหมด (All Dataset) จำนวน 500 คำ (ต่อ)

No.	Word	Train	Test	Val	Total	No.	Word	Train	Test	Val	Total
236	LEADER	1,000	50	50	1,100	486	WHOLE	1,000	50	50	1,100
237	LEADERS	1,000	50	50	1,100	487	WINDS	919	50	50	1,019
238	LEADERSHIP	811	50	50	911	488	WITHIN	1,000	50	50	1,100
239	LEAST	1,000	50	50	1,100	489	WITHOUT	1,000	50	50	1,100
240	LEAVE	1,000	50	50	1,100	490	WOMEN	1,000	50	50	1,100
241	LEGAL	917	50	50	1,017	491	WORDS	941	50	50	1,041
242	LEVEL	1,000	50	50	1,100	492	WORKERS	1,000	50	50	1,100
243	LEVELS	1,000	50	50	1,100	493	WORKING	1,000	50	50	1,100
244	LIKELY	1,000	50	50	1,100	494	WORLD	1,000	50	50	1,100
245	LITTLE	1,000	50	50	1,100	495	WORST	870	50	50	970
246	LIVES	1,000	50	50	1,100	496	WOULD	1,000	50	50	1,100
247	LIVING	1,000	50	50	1,100	497	WRONG	1,000	50	50	1,100
248	LOCAL	1,000	50	50	1,100	498	YEARS	1,000	50	50	1,100
249	LONDON	1,000	50	50	1,100	499	YESTERDAY	1,000	50	50	1,100
250	LONGER	930	50	50	1,030	500	YOUNG	1,000	50	50	1,100

ประวัติผู้เขียน

ชื่อ	นายธีรพงศ์ งามพร้อมวงศ์
ชื่อวิทยานิพนธ์	การพัฒนาแบบจำลองเรียนรู้แบบลึกเชิงพื้นที่และเวลาสำหรับการจดจำคำพูดด้วยภาพ Development of Spatio-temporal Deep Learning Model for Visual speech recognition
สาขาวิชา	วิทยาการคอมพิวเตอร์
ประวัติ	สำเร็จการศึกษาในระดับปริญญาตรี หลักสูตรวิศวกรรมศาสตรบัณฑิต สาขาวิศวกรรมคอมพิวเตอร์ มหาวิทยาลัยสงขลานครินทร์ และเข้ารับการศึกษต่อในระดับปริญญาโท หลักสูตรวิทยาศาสตรมหาบัณฑิต สาขาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ประยุกต์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ ประจำปีการศึกษา 2565